

# 基于时间序列分析和卡尔曼滤波算法的风电场风速预测优化模型

潘迪夫<sup>1</sup>, 刘辉<sup>1</sup>, 李燕飞<sup>2</sup>

(1. 中南大学 交通运输工程学院, 湖南省 长沙市 410075;

2. 轨道交通安全教育部重点实验室(中南大学), 湖南省 长沙市 410075)

## A Wind Speed Forecasting Optimization Model for Wind Farms Based on Time Series Analysis and Kalman Filter Algorithm

PAN Di-fu<sup>1</sup>, LIU Hui<sup>1</sup>, LI Yan-fei<sup>2</sup>

(1. School of Traffic & Transportation Engineering, Central South University, Changsha 410075, Hunan Province, China;

2. Key Laboratory of Traffic Safety on the Track (Central South University), Ministry of Education, Changsha 410075, Hunan Province, China)

**ABSTRACT:** To improve the wind speed forecasting accuracy for wind farm and solve the problem of time delay of forecasting by time series model, the authors propose a hybrid algorithm integrating time series analysis with Kalman filter. The basic thinking of this algorithm is as following: firstly, by use of time series analysis theory the non-stationary modeling for wind speed signals of wind farm is proceeded to obtain the model equation conforming to its variation law; secondly, by means of the obtained model equation the state equation and observational equation for Kalman filter are deduced; thirdly, the wind speed is forecasted by Kalman forecasting recurrence equation; finally, the forecasting for varying wind speed measured in a certain wind farm is conducted to validate the proposed hybrid algorithm. Case study results show that by using this hybrid algorithm the forecasting accuracy of wind speed can be improved and the time delay in the forecasting is well solved.

**KEY WORDS:** hybrid algorithm; Kalman filter; time series; wind farm

**摘要:** 为提高风电场风速的预测精度, 解决时序模型预测延时的问题, 文章提出了一种时间序列分析和卡尔曼滤波相结合的混合算法。基本思路为: 首先利用时间序列分析理论, 对风电场风速信号进行非平稳建模, 得到符合其变化规律的模型方程; 其次通过得到的模型方程推导出卡尔曼滤波法的状态方程和观测方程; 然后依靠卡尔曼预测递推方程进行预测; 最后

对某实测风速信号进行预测。实例分析表明: 采用该混合算法可以提高预测精度, 而且较好地解决了预测延时问题。

**关键词:** 混合算法; 卡尔曼滤波; 时间序列; 风电场

## 0 引言

近年来, 风力发电技术发展迅速, 被公认为是一种理想的可再生能源发电方式。风力发电的输出功率与风电场风速有很大关系, 呈现出很强的随机性。对风电场风速进行较为准确的预测, 对于电力部门及时调整调度计划, 衡量风电场的容量可信度, 进而确定合适的风电上网价格, 具有重要的现实意义。

风电场风速预测的方法很多, 成熟的有回归分析法和最小二乘法, 以及近年来迅速发展的神经网络法(artificial neural network, ANN)<sup>[1]</sup>、时间序列分析法(time series analysis)<sup>[2-4]</sup>、卡尔曼滤波法(Kalman filter)<sup>[5-6]</sup>、遗传算法<sup>[7]</sup>、小波分析<sup>[8-9]</sup>及其他算法<sup>[10-13]</sup>。这些预测方法各有特点和适用的场合, 已经在许多工程领域得到了很好的应用。本文选择时间序列分析和卡尔曼滤波进行混合建模。

时间序列分析建模最大的优点在于不必深究信号序列的产生背景, 序列本身所具有的时序性和自相关性已经为建模提供了足够的信息, 只需要有限的样本序列, 就可以建立起相当高精度的预测模型, 但其存在低阶模型预测精度低、高阶模型参数

基金项目: “十一五” 国家科技支撑计划重点项目(2006BAC07B03)。

估计难度大的不足。而卡尔曼滤波预测法存在动态修改预测权值的优点,依靠预测递推方程可以获得较高的精度,但同样存在建立卡尔曼状态方程和测量方程较困难的不足。为此,本文提出了一种混合算法,首先利用时间序列分析建立一个能反映序列信号变化规律的低阶模型,从该低阶模型的预测方程入手,直接推导出卡尔曼滤波的状态和测量方程,利用卡尔曼预测迭代方程可以实现信号的预测,这恰好避免了建立高阶时间序列模型和推导卡尔曼状态和测量方程困难的问题。

## 1 采用时间序列分析法预测风速

### 1.1 时序差分自回归滑动平均模型

时序模型主要包括稳定模型和非稳定模型。常用的稳定模型有自回归(auto regressive, AR)模型、滑动平均(moving average, MA)模型、自回归滑动平均(auto regressive moving average, ARMA)模型几种。非稳定模型有差分自回归滑动平均(auto regressive integrated moving average, ARIMA)模型等,以及由常见模型递推加权改进的非平稳模型。其中, ARIMA( $p, d, q$ )模型的表达式为

$$f(B)k^d \hat{X}_t^0 = q(B)a_t$$

其中

$$f(B) = 1 - f_1 B - f_2 B^2 - \dots - f_p B^p$$

$$q(B) = 1 - q_1 B - q_2 B^2 - \dots - q_q B^q$$

$$k = 1 - B$$

式中:  $\{\hat{X}_t^0\} (t=1, 2, 3, L)$  为时间序列;  $\{a_t\}$  是均值为 0、方差为  $\sigma_a^2$  的正态白噪声过程;  $f_i (i=1, 2, L, p)$  和  $q_j (j=1, 2, L, q)$  为模型的待估系数;  $B$  为后移差分算子。

常用的建模方法有 Box-Jenkins 法、Pandit-Wu S.M 法以及长自回归法等,本文选择 Pandit-Wu S.M 法进行时间序列的分析建模。先根据数据的自相关系数  $\hat{r}_k$  和偏相关系数  $\hat{f}_{kk}$  进行模型识别。如选用 ARMA 模型,则在模型定阶时用 ARMA( $p, p-1$ ) ( $p=2, 3, 4, L$ ) 模型取代 ARMA( $p, q$ ) ( $p=1, 2, 3, L$ ;  $q=1, 2, 3, L$ ) 模型来进行逐步拟合,选择最小信息准则(Akaike information criterion, AIC)进行模型定阶。这样只要定出  $p$  就可以确定  $q=p-1$ ,可以缩短建模时间。选择矩估计进行模型参数估计,得出模型方程表达式。

### 1.2 实例分析

将我国某风电场 1 号测风点实测数据(每分钟

采样 1 点)作为样本序列  $\{Z_t\}$ ,运用时间序列法进行建模。先取得样本序列  $\{Z_t\}$  的前 200 个数据,记为序列  $\{X_t\}$ ,如图 1 所示。求得序列  $\{X_t\}$  的前 20 个自相关系数,如图 2 所示。由图 2 可以看出,自相关系数不能快速衰减为零,可初步推断原始风速序列非平稳。同时对序列  $\{X_t\}$  运用非参数游程检验法检验平稳性,得出的结论与通过分析其自相关系数得出的结论一致,即序列  $\{X_t\}$  数据非平稳。




图 1  $\{X_t\}$  序列曲线

Fig. 1 The curve of  $\{X_t\}$  series




图 2  $\{X_t\}$  序列对应的前 20 个自相关系数

Fig. 2 The first twenty self-correlation coefficients for  $\{X_t\}$  series

对  $\{X_t\}$  序列进行差分处理,1 阶差分后得到  $\{Y_t\}$  序列,如图 3 所示,求得其前 20 个自相关系数数值,如图 4 所示。由图 4 可知,经过 1 阶差分处理后数据的相关系数呈现出不断振荡的特征,说明已经表现出平稳性。同理,可运用游程检验法加以确定。




图 3  $\{Y_t\}$  序列曲线

Fig. 3 The curve of  $\{Y_t\}$  series




图 4  $\{Y_t\}$  序列对应的前 20 个自相关系数

Fig. 4 The first twenty self-correlation coefficients for  $\{Y_t\}$  series

此外,要注意模型是否满足平稳性条件和可逆性条件。根据 AIC 准则定阶,  $\{Y_t\}$  序列最终确定模型为 AR(3),由此可知  $\{X_t\}$  序列的时序模型为 ARIMA(3,1,0)模型。计算获得该模型方程为

$$(1+0.359B+0.2091B^2+0.2179B^3)kX(t)=a_t \quad (1)$$

$$(1+0.359B+0.2091B^2+0.2179B^3)(1-B)X(t)=a_t \quad (2)$$

$$X(t)=0.641X(t-1)+0.1499X(t-2)-0.0088X(t-3)+0.2179X(t-4)+a_t \quad (3)$$

式中  $a_t$  为模型残差。则预测方程为

$$X(t)=0.641X(t-1)+0.1499X(t-2)-0.0088X(t-3)+0.2179X(t-4) \quad (4)$$

至此，可使用式(4)进行预测，得到原始风速曲线和预测风速曲线，如图 5 所示。可以看出，使用时间序列分析法进行建模预测是可行的，模型基本掌握了风速数据的变化规律，但预测存在明显的延时性，而且预测精度不高，绝对平均误差为 10.25%。




图 5 使用时间序列法得到的 1 号测风点采样风速预测结果

Fig. 5 Forecasting results of wind speed sampled from No.1 measurement point using time series method

## 2 采用混合算法预测风速

### 2.1 卡尔曼滤波基本原理

一般的线性离散系统可表示为<sup>[14-15]</sup>

$$X(k+1)=F(k+1,k)X(k)+G(k+1,k)w(k) \quad (5)$$

$$Z(k+1)=H(k+1)X(k+1)+v(k+1) \quad (6)$$

式中： $X(k)$  为  $n$  维状态向量； $Z(k)$  为  $m$  维观测向量； $w(k)$  为  $p$  维系统噪声向量； $v(k)$  为  $m$  维测量噪声向量； $F(k+1,k)$  称为从  $k$  时刻到  $k+1$  时刻的状态转移矩阵； $G(k+1,k)$  称为从  $k$  时刻到  $k+1$  时刻的激励转移矩阵； $H(k+1)$  为  $k+1$  时刻的预测输出转移矩阵。式(5)称为状态方程，式(6)称为测量方程。

卡尔曼滤波理论上分为 3 个主要内容：滤波问题、预测问题和平滑问题，本文仅研究预测问题。要将卡尔曼滤波用于预测，首先必须推导出预测递推方程，一般使用正交定理，采用数学归纳法进行推导<sup>[14]</sup>。最终得到的预测递推方程如下<sup>[15]</sup>：

$$\hat{X}(k+1|k+1)=F(k+1,k)\hat{X}(k|k)+$$

$$K(k+1)[Z(k+1)-H(k+1)F(k+1,k)\hat{X}(k|k)] \quad (7)$$

$$K(k+1)=P(k+1|k)H^T(k+1) \cdot$$

$$[H(k+1)P(k+1|k)H^T(k+1)+R(k+1)]^{-1} \quad (8)$$

$$P(k+1|k)=F(k+1,k)P(k|k)F^T(k+1,k)+$$

$$G(k+1,k)Q(k)G^T(k+1,k) \quad (9)$$

$$P(k+1|k+1)=[I-K(k+1)H(k+1)]P(k+1|k) \quad (10)$$

式中： $\hat{X}(k+1|k+1)$  表示对  $k+1$  时刻的状态估计； $K(k+1)$  为  $k+1$  时刻的卡尔曼增益矩阵； $P(k+1|k)$  表示从  $k$  时刻到  $k+1$  时刻的单步预测误差协方差矩阵； $P(k+1|k+1)$  为  $k+1$  时刻滤波预测的误差协方差矩阵； $Q(k)$  是关于  $w(k)$  的协方差矩阵； $R(k)$  是关于  $v(k)$  的协方差矩阵； $I$  为单位矩阵。式(7)~(10)分别为最优滤波估计方程、最优增益矩阵方程、单步预测误差协方差方程和滤波预测的误差协方差方程。在实际的算法设计中， $R(k)$  和  $Q(k)$  的数值可以取经验值。

### 2.2 卡尔曼状态和测量方程的推导

由式(7)可知，卡尔曼滤波预测的核心优势是根据最新的测量值修正前一时刻的估计值，具有动态加权修正的特性。要实现卡尔曼预测，首先必须推导出正确的状态方程和测量方程。原始的风速信号为一维序列，但使用时间序列分析建模得到的 ARIMA(3,1,0)模型方程(3)却包含 4 个时间延迟。所以要设法将式(3)转化成矩阵的形式<sup>[15]</sup>。设  $X_1(k)=X(k)$ ， $X_2(k)=X(k-1)$ ， $X_3(k)=X(k-2)$ ， $X_4(k)=X(k-3)$ 。并将式(3)改写成如下形式：

$$X(k+1)=0.641X(k)+0.1499X(k-1)-0.0088X(k-2)+0.2179X(k-3)+a_{k+1} \quad (11)$$

则有

$$X_1(k+1)=0.641X_1(k)+0.1499X_2(k)-0.0088X_3(k)+0.2179X_4(k)+a_{k+1} \quad (12)$$

由于  $X_2(k+1)=X_1(k)$ ， $X_3(k+1)=X_2(k)$ ， $X_4(k+1)=X_3(k)$ ，可得

$$\begin{bmatrix} X_1(k+1) \\ X_2(k+1) \\ X_3(k+1) \\ X_4(k+1) \end{bmatrix} = \begin{bmatrix} 0.641 & 0.1499 & -0.0088 & 0.2179 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} X_1(k) \\ X_2(k) \\ X_3(k) \\ X_4(k) \end{bmatrix} + \begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \end{bmatrix} w(k+1) \quad (13)$$

易知： $Z(k+1)=X(k+1)+v(k+1)$  ( $v(k+1)$  为测量附加噪声，为建模方便，可以假设为白噪声)，则测

量方程为

$$\mathbf{Z}(k+1) = [1, 0, 0, 0] \begin{bmatrix} X_1(k+1) \\ X_2(k+1) \\ X_3(k+1) \\ X_4(k+1) \end{bmatrix} + \mathbf{v}(k+1) \quad (14)$$

### 2.3 实例分析

将式(13)、(14)与式(5)、(6)对比, 可得到  $F(k+1, k)$ 、 $G(k+1, k)$ 、 $H(k+1)$  的具体值。确定相关的初始状态  $\mathbf{X}(0|0)$ 、 $\mathbf{P}(0|0)$ , 就可使用递推方程(7)~(10)进行迭代预测, 但在实践中很难准确掌握初始状态  $\mathbf{X}(0|0)$ 、 $\mathbf{P}(0|0)$ 。卡尔曼预测在递推过程中不断用新的信息对状态进行修正, 所以当预测时间足够长时, 初始值  $\mathbf{X}(0|0)$ 、 $\mathbf{P}(0|0)$  对预测的影响将衰减为零<sup>[3-4]</sup>。考虑到收敛的速度和参考工程习惯<sup>[3,15]</sup>, 取初始值如下:  $\mathbf{X}(0|0)=[0]$ 、 $\mathbf{P}(0|0)=10\mathbf{I}$ 。

取  $\mathbf{R}(k)=[1]$  ( $k=1, 2, 3, L$ ),  $\mathbf{Q}(k)=[1]$  ( $k=1, 2, 3, L$ ), 应用 Matlab 软件容易实现混合算法的递推预测, 得到原始风速曲线和预测风速曲线, 如图 6 所示。由图 6 可以看出, 使用混合算法进行预测不仅使预测精度得到了提高, 绝对平均误差为 4.35%, 而且时间序列分析法的预测延时问题也得到了较好的解决。为进一步验证该算法, 对同一测风场 2 号测风点的一段实测数据按照混合思路建模, 得到预测结果如图 7 所示。该段数据比 1 号测风点的数据波动性和跳跃性更大, 且数据呈现局部周期性, 但该算法依然能有效实现预测, 绝对平均误差为 4.92%。

不管是时间序列分析法还是本文采用的混合算法, 对于跳跃性较大的风速预测的效果还不理想, 从图 6、图 7 中可以清楚地看到这一点。这个问题可通过如下方法解决: 先对风速数据进行移动平均处理, 将部分高阶数据滤去, 再使用混合算法




图 6 采用混合算法得到的 1 号测风点采样风速预测结果  
Fig. 6 Forecasting results of wind speed sampled from No. 1 measurement point using hybrid algorithm




图 7 采用混合算法得到的 2 号测风点采样风速预测结果  
Fig. 7 Forecasting results of wind speed sampled from No. 2 measurement point using hybrid algorithm

对滑动平均处理过的数据进行预测; 然后求出移动平均处理过的数据和实测极大风速数据的相关系数; 最后将得到的预测数据根据相关系数进行加权修正, 就可以得到跳跃数据的相对准确的预测值。实际上, 目前很多学者在进行建模时所用的样本数据均是处理过的数据(如每小时平均风速), 这就不会出现较大跳跃信号难以预测的问题。

### 3 结论

(1) 本文提出的混合算法有效弥补了单纯时间序列法建模预测的不足。1.2 节建立的模型是时序建模中的简单模型, 直接采用该模型进行预测精度非常有限。但经过 2.2 节简单的数学转换, 就将预测的工作转给卡尔曼滤波算法, 由卡尔曼滤波算法的几个简单递推方程直接完成预测。实际上混合算法所增加的模型计算量就是 2.2 节所阐述的内容, 而该部分转换的实现编程非常简单, 几乎没有增加建模的计算量, 而且没有提高所建时序模型的阶次, 但混合算法的预测精度却极大地提高了。所以混合算法在模型预测精度、建模计算量、模型阶次上均有很好的表现。

(2) 通过本文阐述的混合建模步骤可知, 借助时间序列分析方法, 可以简单有效地推导出卡尔曼滤波状态方程和测量方程。为那些希望采用卡尔曼滤波理论进行预测, 但又难以获得满意的卡尔曼基本方程的工程技术人员提供了一种有效的思路。

(3) 该混合算法与其他智能算法相比, 最突出的优点是建模简单, 可以获得模型的显式表达式。小波算法在构造合适的小波基上存在较大的困难, 对于一般技术人员来说, 要实际应用存在较高的门槛。神经网络建模的缺点是其建模的“黑箱”性, 人们难以理解网络的学习和决策过程, 这不利于对模型的进一步优化。比较而言, 本文提出的混合算法具有明显优势。



## 参考文献

- [1] Li Shu-hui, Wunsch D C, Giesselmann M G, et al. Using neural networks to estimate wind turbine power generation[J]. IEEE Trans on Energy Conversion, 2001, 16(3): 276-282.
- [2] Billinton R, Chen H, Ghajar R. Time-series models for reliability evaluation of power systems including wind energy[J]. Microelectronics and Reliability, 1996, 36(9): 1253-1261.
- [3] 丁明, 张立军, 吴义纯. 基于时间序列分析的风电场风速预测模型[J]. 电力自动化设备, 2005, 25(8): 32-34.  
Ding Ming, Zhang Lijun, Wu Yichun. Wind speed forecast model for wind farms based on time series analysis[J]. Electric Power Automation Equipment, 2005, 25(8): 32-34(in Chinese).
- [4] 杨秀媛, 肖洋, 陈树勇. 风电场风速和发电功率预测研究[J]. 中国电机工程学报, 2005, 25(11): 1-5.  
Yang Xiuyuan, Xiao Yang, Chen Shuyong. Wind speed forecast model for wind farms based on time series analysis[J]. Proceedings of the CSEE, 2005, 25(11): 1-5(in Chinese).
- [5] 马静波, 杨洪耕. 自适应卡尔曼滤波在电力系统短期负荷预测中的应用[J]. 电网技术, 2005, 29(1): 75-79.  
Ma Jingbo, Yang Honggeng. Application of adaptive Kalman filter in power system short-time load forecasting[J]. Power System Technology, 2005, 29(1): 75-79(in Chinese).
- [6] 李明干, 孙健利, 刘沛. 基于卡尔曼滤波的电力系统短期负荷预测[J]. 继电器, 2004, 32(4): 9-12.  
Li Minggan, Sun Jianli, Liu Pei. Short-term load forecast of power system based on Kalman filter[J]. Relay, 2004, 32(4): 9-12(in Chinese).
- [7] 金群, 李欣然. 遗传算法参数设置及其在负荷建模中的应用[J]. 电力自动化设备, 2006, 26(5): 23-27.  
Jin Qun, Li Xinran. GA parameter setting and its application in load modeling[J]. Electric Power Automation Equipment, 2006, 26(5): 23-27(in Chinese).
- [8] 邵能灵, 侯志俭, 李涛, 等. 基于小波分析的电力系统短期负荷预测方法[J]. 中国电机工程学报, 2003, 23(1): 45-50.  
Tai Nengling, Hou Zhijian, Li Tao, et al. New principle based on wavelet transform for power system short-term load forecasting [J]. Proceedings of the CSEE, 2003, 23(1): 45-50(in Chinese).
- [9] 谢宏, 陈志业, 牛东晓, 等. 基于小波分解与气象因素影响的电力系统日负荷预测模型研究[J]. 中国电机工程学报, 2001, 21(5): 5-10.  
Xie Hong, Chen Zhiye, Niu Dongxiao, et al. The research of daily load forecasting model based on wavelet decomposing and climatic influence[J]. Proceedings of the CSEE, 2001, 21(5): 5-10(in Chinese).
- [10] 张伏生, 汪鸿, 韩梯, 等. 基于偏最小二乘回归分析的短期负荷预测[J]. 电网技术, 2003, 27(3): 37-40.  
Zhang Fusheng, Wang Hong, Han Ti, et al. Short-term load forecasting based on partial least-squares regression[J]. Power System Technology, 2003, 27(3): 37-40(in Chinese).
- [11] 游仕洪, 程浩忠, 谢宏. 应用模糊线性回归模型预测中长期电力负荷[J]. 电力自动化设备, 2006, 26(3): 51-53.  
You Shihong, Cheng Haozhong, Xie Hong. Mid- and long-term load forecast based on fuzzy linear regression model[J]. Electric Power Automation Equipment, 2006, 26(3): 51-53(in Chinese).
- [12] 李天云, 刘自发. 电力系统负荷的混沌特性及预测[J]. 中国电机工程学报, 2000, 20(11): 36-40.  
Li Tianyun, Liu Zifa. The chaotic property of power load and its forecasting[J]. Proceedings of the CSEE, 2000, 20(11): 36-40(in Chinese).
- [13] 蒋传文, 袁智强, 侯志俭, 等. 高嵌入维混沌负荷序列预测方法研究[J]. 电网技术, 2004, 28(3): 25-28.  
Jiang Chuanwen, Yuan Zhiqiang, Hou Zhijian, et al. Research of forecasting method on chaotic load series with high embedded dimension[J]. Power System Technology, 2004, 28(3): 25-28(in Chinese).
- [14] 王志贤. 最优状态估计和系统辨识[M]. 西安: 西北工业大学出版社, 2004.
- [15] [美] Lonnie C. Ludeman. 邱天爽, 李婷, 毕英伟等, 译. 随机过程——滤波、估计和检测[M]. 北京: 电子工业出版社, 2005.

收稿日期: 2007-10-16.

作者简介:

潘迪夫(1957—), 男, 教授, 研究方向为智能测控技术、电力牵引及其自动化;

刘 辉(1983—), 男, 硕士研究生, 研究方向为智能控制与信息技术, 模式识别算法和信号处理, E-mail: [liuhui8302@yahoo.com.cn](mailto:liuhui8302@yahoo.com.cn);

李燕飞(1981—), 女, 硕士研究生, 研究方向为轨道空气动力学技术。

(责任编辑 沈杰)

## 灾区用电量大幅上升 国家电网全力保障电力供应

随着遭受雪灾的各省份逐步恢复生产, 用电量大幅上升, 国家电网公司采取了多项措施来保障电力供应。进入 3 月份, 江西电网的最高用电负荷比去年同期增长了 50% 以上。为保障电网安全运行, 电力部门加强了老化设备的技术改造, 同时加紧建设湖北连接江西的电力通道。国家电网江西电力公司生产技术部主任李政说, 这条通道可以将三峡送江西的电力从现在的 1 GW 增加到 2 GW, 让电网的运行更加可靠。在受灾最严重的湖南郴州, 虽然供电已经恢复, 但抢修时很多线路都是临时连接上的, 为此, 电力部门加快了检查维修, 确保 3 月底前全部恢复稳定。在福建和重庆, 电力部门为重点企业和工程开辟了“绿色通道”, 重庆电力公司还派技术人员到雪灾中让电于民的企业检查处理故障, 保证企业 24 小时生产, 把雪灾造成的损失降到最低。