

基于频域分解的短期风电负荷预测

温锦斌¹ 王 昕¹ 李立学¹ 郑益慧¹ 周荔丹² 邵凤鹏³

(1. 上海交通大学 电工与电子技术中心 上海 200240

2. 上海交通大学 电力传输与功率变换控制教育部重点实验室 电气工程系 上海 200240

3. 吉林省电力有限公司延边供电公司 延边 133000)

摘要 为了克服风电的不规则性和提高风电负荷预测的精度,将频域分解的方法运用在风电负荷预测中可以找到风电的部分规律和在一定程度上克服风电的不规则性。通过对原始负荷数据的频域分解,将数据分解成日周期、周周期、低频和高频四个部分。日周期的部分用神经网络的方法训练和预测。低频部分用一元线性回归的方法预测。高频部分用提升小波和神经网络相结合的方法训练和预测。最后将各部分的预测结果加起来,这样就实现了风电负荷的高精度预测。本文中用实际数据进行仿真,实验结果表明,基于频域分解的方法可以比较好地找到风电的规律,有利于通过不同的方法对不同的部分进行短期负荷预测,很大程度地提高预测的精度,测试表明该方法用于风电负荷预测是有效可行的。

关键词: 频域分解 提升小波 风电 负荷预测

中图分类号: TM715

Short-Term Wind Power Load Forecasting Based on Frequency Domain Decomposition

Wen Jinbin¹ Wang Xin¹ Li Lixue¹ Zheng Yihui¹ Zhou Lidan² Shao Fengpeng³

(1. Center of Electrical & Electronic Technology Shanghai Jiao Tong University Shanghai 200240 China 2. Key Laboratory of Control of Power Transmission and Conversion

Ministry of Education Shanghai Jiao Tong University Shanghai 200240 China

3. Yanji Power Supply Company, Jilin Electric Power Co. Ltd Yanbian 133000 China)

Abstract In order to overcome the irregularity of wind power and improve wind power load forecasting accuracy. The frequency domain decomposition methods use in wind power load forecasting can find the wind power law and overcome the irregularity of wind power on a certain extent. With the frequency domain decomposition method, the original load data will be decompose into daily cycle, week cycle, the low and high frequency four parts. Part of the daily cycle will use neural network methods for training and prediction. The low-frequency part will use a linear regression method. The method of combining lifting wavelet and neural network will be used in training and forecasting the high-frequency part. Finally, the various parts of the forecasting results add up to achieve high-precision wind power load forecasting. In this paper, the actual data are used for simulation, the experimental results show that the method based on the frequency domain decomposition, can more easily find the wind power law, benefit short term load forecasting by different methods in different part, greatly improve the precision of forecasting. The test shows that the method used for the wind power load forecast is feasible and effective.

Keywords: Frequency domain decomposition, lifting wavelet, wind power, load forecasting.

1 引言

风能是理想的清洁能源, 风能发电避免了火力发电对大气的污染、水力发电对生态环境的影响。随着风电技术的不断发展和风电场的规模不断扩大, 为了保证电力系统的稳定运行和供电可靠性, 必须对风电系统进行有效的规划和调度^[1]。由于风电本身所特有的间歇性和不确定性, 增加了电网调度的难度, 为了解决风电场的发电量不确定问题, 电网必须提供足够的旋转备用容量, 而旋转备用容量的增加间接地增加了风力发电的整体运营成本, 所以需要对风电场的输出功率进行预测, 通过对风电场发电量进行准确的预测, 可以大幅降低电网旋转备用容量, 从而有效降低风力发电系统的运行成本, 为电网调度运行提供可靠依据^[2]。

负荷预测的核心问题是预测的技术方法, 或者说是预测的数学模型。随着现代科学技术的快速发展, 负荷预测技术的研究在不断深化, 各种各样的负荷预测方法不断涌现, 从经典的单耗法^[3], 统计分析法^[4], 到目前的灰色预测法^[5], 专家系统法^[6]和模糊数学法^[7], 甚至到神经网络法, 优选组合法^[8]和小波分析法, 它们都有各自的研究特点和使用条件, 也都可以应用于风电的负荷预测, 在很多文献中都有详细的介绍。

上述方法都有各自的优点也有很多局限性, 文献[3]提到了单耗法, 单耗法在预测生产用电上的效果比较好, 但不适合风电的负荷预测。文献[4]将统计分析法应用于风电负荷预测中, 该方法比较适合风电负荷预测, 但是需要较多的统计数据。文献[5]中提到的灰色预测法可以用少量的数据进行预测, 然而预测的精度不高。近年来, 由于神经网络具有以任意精度逼近输入输出间非线性关系的特性, 因此在风电功率预测中得到广泛应用, 但是由于风电的间歇性和不确定性, 使得风电功率非常不规则, 这样会使 BP 网在训练中陷入局部最小, 导致预测精度低。因此, 如何根据风电的强随机性和不稳定特性, 使用一种新的方法来提高对风电功率预测的精度, 是目前急需解决的问题。

针对以上提出的问题, 本文提出了一种基于频域分解的风电负荷预测方法, 通过频域分解的方法, 可以将无规律、随机的风电负荷曲线, 分解成有不同规律的多个曲线的组合, 然后对不同规律, 采用不同的方法进行预测, 从而提高预测的精度。该方法首先对原始数据用频域分解的方法进行分解, 可

以得到日周期、周周期、低频和高频四个部分, 日周期的部分规律性很明显, 可以用神经网络的方法训练和预测。由于风电基本没有周周期的部分, 因此分解出来后, 周周期的部分都是零。低频部分是非常光滑的曲线, 用一元线性回归的方法预测的精度就能达到很高。高频部分规律性还是比较不明显, 所以在本文中先用提升小波对其分解, 可以使原来波动比较大的曲线变得比较平缓, 有利于神经网络的训练和预测, 大大提高了高频的预测精度。本文根据我国某风电场的真实数据, 运用 Matlab 对其进行仿真, 仿真结果表明该方法可行, 具有很高的预测精度。

2 频域分解

设建模的历史负荷数据所在的时间域为 D^- , 在制定建模时域 D^- 的负荷时间序列 $P(t)$ 可作如下傅里叶分解:

$$P(t) = a_0 + \sum_{i=1}^{N-1} (a_i \cos \omega_i t + b_i \sin \omega_i t) \quad (1)$$

式中, N 为负荷序列的长度。根据傅里叶分解的性质, 分解后得到的信号是彼此正交的。用这种方法, 把负荷 $P(t)$ 分解成角频率为 $\omega_i = \frac{i}{N} \times 2\pi$ ($i=1, 2, \dots, N-1$) 的分量。依据负荷变化周期性的特点, 可以分解出日周期的部分, 即每天有的规律。周周期的部分, 即每周有的规律。由后面周周期分析结果可知, 由于风电负荷月周期的规律基本没有, 所以在本文的频域分解中就不加入月周期。综上所述, 可将 $P(t)$ 重构成高频、低频、日周期和周周期 4 个部分, 具体为

$$P(t) = a_0 + D(t) + W(t) + L(t) + H(t) \quad (2)$$

式中, 日周期分量 $a_0 + D(t)$ 和周周期分量 $W(t)$ 是按固定周期变化的负荷分量; $L(t)$ 为低频分量, $H(t)$ 为高频分量。

本文中引入取模运算, 用 $\text{mod}(m, n)$ 表示 m 除以 n 的余数。以电力负荷日 144 点采样为例。

(1) $D(t)$ 的周期为 144, 它在负荷中以 24h 为周期变化的分量, $a_0 + D(t)$ 即为负荷的日周期分量。日周期分量 $a_0 + D(t)$ 包括的角频率集合

$$\Omega_{\text{day}} = \{\omega_0\} \cup \left\{ \omega_i \left| \text{mod} \left(144, \frac{2\pi}{\omega_i} \right) = 0 \right. \right\}$$

(2) $W(t)$ 的周期为 7×144 , 是负荷的周周期分

量; 周周期分量 $W(t)$ 包括的角频率集合为

$$\Omega_{\text{week}} = \left\{ \omega_i \left| \text{mod} \left(7 \times 144, \frac{2\pi}{\omega_i} \right) = 0 \text{ 且 } \text{mod} \left(144, \frac{2\pi}{\omega_i} \right) \neq 0 \right. \right\}$$

(3) 去除 a_0 , $D(t)$, $W(t)$, 剩余分量可分为 $L(t)$ 和 $H(t)$ 。 $L(t)$ 是剩余分量中低频分量的总和, 它反映了气象因素等慢变相关因素对负荷的影响; $H(t)$ 是剩余分量中高频分量的总和, 主要体现了负荷变化的随机性。剩余低频分量 $L(t)$ 和高频分量 $H(t)$ 包括的角频率集合分别为

$$\Omega_{\text{low}} = \left\{ \omega_i \left| \frac{2\pi}{\omega_i} \geq 144 \text{ 且 } \omega_i \notin \Omega_{\text{day}} \cup \Omega_{\text{week}} \right. \right\}$$

和

$$\Omega_{\text{high}} = \left\{ \omega_i \left| \frac{2\pi}{\omega_i} < 144 \text{ 且 } \omega_i \notin \Omega_{\text{day}} \cup \Omega_{\text{week}} \right. \right\}$$

计算的目标是获得傅里叶分解后的系数 a_i , b_i 。根据傅里叶分解(级数展开)和傅里叶变换的关系, 可以得到傅里叶展开的系数和傅里叶变换得到的频谱间的关系。以下是离散傅里叶变换(DFT)和离散傅里叶逆变换(IDFT)之间的变换核

$$X(\omega_k) = \sum_{n=0}^{N-1} x(n) e^{-j \left(\frac{2\pi}{N} \right) nk} \quad (3)$$

$$x(n) = \frac{1}{N} \sum_{k=0}^{N-1} X(\omega_k) e^{j \left(\frac{2\pi}{N} \right) nk} \quad (4)$$

根据傅里叶正变换关系, 傅里叶分解后的系数 a_i , b_i 和傅里叶变换后的频谱 $X(\omega_i)$ 之间有如下关系:

$$X(\omega_i) = N(a_i - jb_i) \quad (5)$$

因此, 对原有的负荷序列进行离散傅里叶变换后, 可以由频谱值得求系数 a_i 、 b_i 。

但最终目的还是把原始序列分离, 得到 $a_0 + D(t)$, $W(t)$, $L(t)$, $H(t)$ 等四个序列, 从而对预测进行评价。求得系数 a_i , b_i 后, 还要进行一定的计算。

从欧拉公式 $e^{j\theta} = \cos \theta + j \sin \theta$ 入手, 利用傅里叶逆变换过程, 求得分解后的序列。式(4)中

$$X(\omega_k) e^{j \frac{2\pi nk}{N}} = N(a_k \cos \omega_k + b_k \sin \omega_k) + jN(a_k \sin \omega_k - b_k \cos \omega_k) \quad (6)$$

根据上式的推导, 可以利用傅里叶逆变换算子, 求得分解后的序列。

3 提升小波

小波提升的核心就是更新算法和预测算法, 通过预测算法可以得到高频信息, 而通过更新算子可以得到正确的低频信息。提升样式可以实现原位计算和整数提升, 并且变换的中间结果是交织排列的。其中原位计算和整数提升在硬件实现中很有价值。

3.1 小波提升的步骤

(1) 分裂: 分裂是将信号分割成相互关联的奇偶两部分, 即 e_{j-1} (偶部分) 和 o_{j-1} (奇部分)

$$\begin{cases} \text{Split}(s_j) = (e_{j-1}, o_{j-1}) \\ e_{j-1} = \{e_{j-1,k} = s_{j,2k}\} \\ o_{j-1} = \{o_{j-1,k} = s_{j,2k+1}\} \end{cases} \quad (7)$$

(2) 预测: 预测就是用 e_{j-1} 预测 o_{j-1} , 实际值 o_{j-1} 与预测值 $P(e_{j-1})$ 的差值 d_{j-1} 反映了两者的逼近程度, 称为细节系数或小波系数, 对应于原信号 s_j 的高频部分。预测过程如下:

$$d_{j-1} = o_{j-1} - P(e_{j-1}) \quad (8)$$

式中, 预测算子 P 可用预测函数 P_k 来表示, 函数 P_k 可取为 e_{j-1} 中的对应数据本身:

$$P_k(e_{j-1,k}) = e_{j-1,k} = s_{j,2k} \quad (9)$$

或 e_{j-1} 中的对应数据的相邻数据的平均值:

$$P_k(e_{j-1,k}) = \frac{e_{j-1,k} + e_{j-1,k+1}}{2} = \frac{s_{j,2k} + s_{j,2k+1}}{2} \quad (10)$$

(3) 更新: 经过分裂步骤产生子集的某些整体特征可能与原始数据并不一致, 为了保持原始数据的这些整体特征, 需要一个更新的过程。将更新过程用算子 U 来代替, 其过程如下:

$$s_{j-1} = e_{j-1} + U(d_{j-1}) \quad (11)$$

式中, s_{j-1} 为 s_j 的低频部分; 与预测函数一样, 更新算子也可以取不同函数, 如

$$U_k(d_{k-1}) = \frac{d_{j-1,k}}{2} \quad (12)$$

或

$$U_k(d_{k-1}) = \frac{d_{j-1,k-1} + d_{j-1,k}}{4} + \frac{1}{2} \quad (13)$$

P 与 U 取不同的函数, 可构造出不同的小波变换。

3.2 分解与重构

经小波提升, 可将信号分解为低频部分 s_{j-1} 和

高频部分 d_{j-1} ; 对于低频数据子集 s_{j-1} 可以再进行相同的分裂、预测和更新, 把 s_{j-1} 进一步分解成 d_{j-2} 和 s_{j-2} ; \dots ; 如此下去, 经过 n 次分解后, 原始数据 s_j 的小波表示为 $\{s_{j-n}, d_{j-n}, d_{j-n+1}, \dots, d_{j-1}\}$ 。其中 s_{j-n} 代表了信号的低频部分, 而 $\{d_{j-n}, d_{j-n+1}, \dots, d_{j-1}\}$ 则是信号从低到高的部分系列。具体的流程图如图 1 所示, 其中 S 为原始信号, A_1 和 A_2 为低频信号, D_1 和 D_2 为高频信号。




图 1 提升小波分解的流程图

Fig.1 The flow chart of the lifting wavelet decomposition

4 基于频域分解方法的短期风电负荷预测模型

风机的发电量受风速、风向等因素的影响, 这些气象因素瞬息万变, 使风电功率数据本质上具有很强的非平稳性。本文运用频域分解的方法建立短期风电负荷预测的模型, 找到风电的部分规律, 针对不同的特点运用不同的预测方法对其进行预测, 以达到提高预测精度的目的, 负荷预测的模型如图 2 所示。

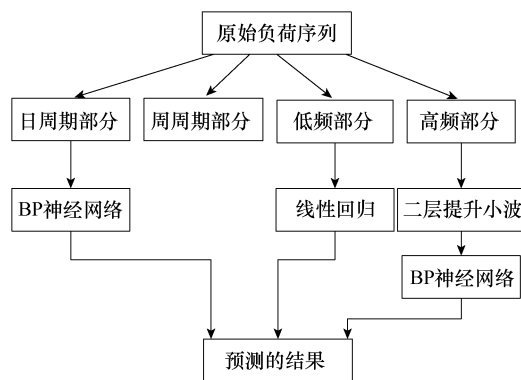


图 2 风电负荷预测模型

Fig.2 Wind power load forecasting model

具体步骤如下:

(1) 根据上文提到的频域分解的算法, 对原始负荷序列进行频域分解, 得到日周期、周周期、低频和高频四个部分。

(2) 日周期部分的预测: 通过频域分解后得到的日周期部分规律性非常明显, 结合 BP 神经网络对规律敏感的优势可以很好地来拟合该系统, 跟踪

效果很好。本文中采用单隐含层神经网络, 网络中间层的神经元传递函数采用 S 型的正切传递函数, 输出层神经元传递函数采用 S 型的对数传递函数。

(3) 周周期部分的预测: 由于风本身不具有周的规律性, 所以风电的输出功率也不会有周的规律性, 通过频域分解后得到的周周期部分全为零。

(4) 低频部分的预测: 通过频域分解后得到的低频部分是一段非常光滑的曲线, 这样就可以运用精度非常高的一元线性回归的预测方法, 即通过已知的两点预测下一点的值, 令 x_1 为已知 1, x_2 为已知 2, y 为需要预测的点, 公式如下:

$$y = 3x_2 - x_1 \quad (14)$$

(5) 高频分量的预测: 通过频域分解后得到的高频部分仍然没什么规律, 但是比还没滤去日周期和低频部分的原始负荷序列平缓, 有利于预测, 本文将高频分量通过提升小波分解, 并将其中得到的二层提升小波的低频部分输入到 BP 神经网络的数学模型中训练和预测, 因为经过提升小波分解后的低频部分比较平缓, 可以很大程度地提高预测算法的预测精度, 另外分解后得到的二层提升小波相对来说又比较细致, 可以保留比较多高频分量的形状, 精度更高。

5 实验结果

为了说明该方法的有效性, 根据上述思想, 本文选取我国北方某风电场的实际数据, 建立预测的模型。本文取 22 天的数据, 10min 一个点, 共 1584 个点。本文中将数据分为两部分, 其中前面 11 天 792 个点作为训练样本, 后面 11 天的 792 个点作为测试样本。图 3 为原始负荷序列。图 4 为通过频域分解后的四个部分。




图 3 原始风电负荷序列

Fig.3 The original wind power load sequence

下面首先利用前面 11 天 792 个点作为样本进行频域分解。正如上文所说, 图 4 中日周期部分规律很明显, 周周期部分全为零, 低频部分是一段光滑的曲线, 高频部分比较嘈杂, 但是比原始序列舒缓。

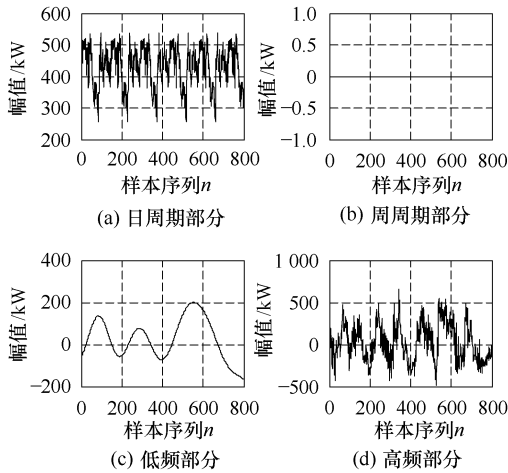


图 4 频域分解后的四个部分图

Fig.4 The chart of four parts after frequency domain decomposition

通过运用建立的数学模型对不同的部分采用不同方法训练和预测, 然后利用后面 11 天的 792 个点作为测试样本。可以分别得到预测结果图 5~图 8 所示。




图 5 日周期部分的预测结果图

Fig.5 The chart of daily cycle part forecasting result

如图 5 所示, 日周期部分的预测效果比较好, 相对误差为 5.49%。图 6 所示低频部分的预测效果非常好, 误差非常小。图 7 为高频部分经过二层提升小波分解后与原高频部分的对比图, 从图中可以看出, 分解后的信号图和分解前的信号图是基本重合的, 但是分解后的图没有了毛刺。图 8 是高频部分经提升小波分解后的二层小波经 BP 神经网络训练和预测后的预测结果图, 高频部分的预测效果也比较好, 相对误差为 6.25%。




图 6 低频部分的预测结果图

Fig.6 The chart of low frequency part forecasting result




图 7 高频部分经提升小波分解后的对比图

Fig.7 The comparison chart of the high-frequency part after lifting wavelet decomposition




图 8 高频部分的预测结果图

Fig.8 The chart of high frequency part forecasting result

各部分预测值相加就是最终的预测结果, 预测值与实际值的对比如图 9 所示。不同预测方法的相对误差列于下表中。




图 9 最后的预测结果图

Fig.9 The final forecasting result chart

表 不同预测方法的相对误差

Tab. The relative error of different forecasting methods

预测方法	BP	提升小波-支持向量机	频域分解方法
相对误差(%)	28.36	9.41	6.95

从各图和表中可以看出,通过运用频域分解的方法可以从毫无规律的风电功率中找出规律,方便使用预测方法进行训练和预测,使各部分预测的精度得以提高,因此可以使最后的预测精度得到很大的提高。

6 结论

针对由风的随机性和不确定性导致的风电功率曲线的毫无规律性,建立了基于频域分解方法的风电短期负荷预测模型,在此基础上针对性地运用不同方法对频域分解出的各部分进行训练和预测,其中用了 BP 神经网络、一元线性回归和提升小波与 BP 神经网络相结合的方法。该方法的数学模型较为简单,虽然涉及多个算法,但各算法都比较小;通过频域分解的方法可以找到一些风电负荷的规律,运用提升小波的分解可以基本去除高频部分的毛刺,这些方法都有利于预测方法的训练和预测;该模型计算速度快,最主要的相对于以往的各种方法,使风电负荷预测的精度提高到了很高的层次。

参考文献

[1] 李钊里. 富锦风电场一期工程接入对黑龙江省电网的影响[J]. 黑龙江电力, 2008, 30(3): 189-191.
Li Yili. Effect of connecting with power grid for first-stage construction of Fujin wind power plant on heilongjiang power grid[J]. Power of Heilongjiang, 2008, 30(3):189-191.

[2] 王丽婕, 廖晓钟, 高爽. 并网型大型风电场风力发电功率-时间序列的混沌属性分析[J]. 北京理工大学学报, 2007, 27(12): 1077-1080.
Wang Lijie, Liao Xiaozhong, Gao Shuang. Chaos characteristics analysis of wind power generation time series for a grid connecting wind farm [J]. Transactions of Beijing Institute of Technology, 2007, 27(12): 1077-1080.

[3] 王白玲. 电力负荷组合预测的理论方法及影响因素分析[D]. 北京: 华北电力大学, 2005.

[4] George Sideratos and Nikos D. Hatziaargyriou. An advanced statistical method for wind power forecasting [J]. IEEE Transactions on Power Systems, 2007, 22(1): 258-265.

[5] T H M El-Fouly, E F El-Saadany, M M A Salama. Grey predictor for wind energy conversion systems output power prediction[J]. IEEE Transactions on Power Systems, 2006, 21(3): 1450-1452.

[6] 于希宁, 牛成林, 李建强. 基于决策树和专家系统的短期电力负荷预测系统[J]. 华北电力大学学报, 2005, 32 (5): 57-61.
Yu Xining, Niu Chenglin, Li Jianqiang. Electric load forecast based on decision tree and expert system [J]. Journal of North China Electric Power University, 2005, 32 (5): 57-61.

[7] 杨期余, 汪卫华, 蓝信军. 长期电力负荷预测的模糊数学方法[J]. 湖南大学学报(自然科学版), 2002, 29 (6): 67-70.
Yang Qiyu, Wang Weihua, Lan Xinjun. A fuzzy mathematic method for long term load forecasting [J]. Journal of Hunan University (Natural Sciences Edition), 2002, 29(6): 67-70.

[8] 赵海青. 神经网络优选组合预测模型在电力负荷预测中的应用[J]. 运筹与管理, 2005, 14 (1): 115-118.
Zhao Haiqing. The application to power load forecasting of ANN optimization combinatorial predication model [J]. Operations Research and Management Science, 2005, 14(1): 115-118.

[9] J P S Catalão, H M I Pousinho, V M F Mendes. Hybrid wavelet-PSO-ANFIS approach short-term wind power forecasting in portugal [J]. IEEE Transactions on Sustainable Energy, 2011, 2(1): 50-59.

[10] 庞松岭, 穆钢, 王修权, 等. 基于负荷规律性分析

的支持向量机短期负荷预测方法[J]. 东北电力大学学报, 2006, 26(4): 1-6.

Pang Songling, Mu Gang, Wang Xiuquan, et al. Short term load forecasting method based on load regularity analysis for supporting vector machines[J]. Journal of Northeast Dianli University Natural Science Edition, 2006, 26(4): 1-6.

- [11] Hans Bludszuweit, Jos é Antonio Dom ínguez-Navarro, Andr é Llombart. Statistical analysis of wind power forecast error[J]. IEEE Transactions on Power Systems, 2008, 3(23):983-991.

- [12] Nima Amjady, Farshid Keynia, Hamidreza Zareipour. Wind power prediction by a new forecast engine composed of modified hybrid neural network and enhanced particle swarm optimization[J]. IEEE Transactions on Sustainable Energy, 2011, 3(2): 265-276.

- [13] Saurabh Tewari, Charles J Geyer, Ned Mohan. A statistical model for wind power forecast error and its application to the estimation of penalties in liberalized markets[J]. IEEE Transactions on Power

Systems, 2011, 26(4):2031-2039.

- [14] 王丽婕, 冬雷, 廖晓钟, 等. 基于小波分析的风电场短期发电功率预测[J]. 中国电机工程学报, 2009, 29(28): 30-33.

Wang Lijie, Dong Lei, Liao Xiaozhong, et al. Short-term power prediction of a wind farm based on wavelet analysis[J]. Proceedings of the CSEE, 2009, 29(28): 30-33.

- [15] 姜玉山, 刘嘉婧, 卢毅. 基于回归分析的频域分解短期负荷预测方法[J]. 电力需求侧管理, 2011, 13(5): 12-16.

Jiang Yushan, Liu Jiajing, Lu Yi. Short term load forecasting based on frequency analysis of regression [J]. Power Demand Side Management, 2011, 13(5): 12-16.

作者简介

温锦斌 男, 1988 年生, 硕士研究生, 研究方向为风力发电功率短期负荷预测。

王 昕 男, 1972 年生, 博士, 副教授, 研究方向为智能电网、可再生能源的分布式生产、传输、存储和接入技术。