

变尺度时间窗口和波动特征提取的短期风电功率组合预测

叶林¹, 滕景竹¹, 蓝海波², 仲悟之³, 吴林林⁴, 刘辉⁴, 王铮³

(1. 中国农业大学信息与电气工程学院, 北京市 100083; 2. 国网冀北电力有限公司, 北京市 100053;

3. 中国电力科学研究院, 北京市 100192; 4. 国网冀北电力有限公司电力科学研究院, 北京市 100045)

摘要: 精确的风电功率预测对保障大规模风电接入电网后电力系统的安全稳定运行具有重要意义。其中, 风速的随机变化是引起风电功率波动和影响风电功率预测精度的最主要原因。针对该问题, 提出一种基于变尺度时间窗口和波动特征提取的短期风电功率组合预测方法。首先, 通过多重分形谱分析不同天气类型下的风速特征。然后, 根据当前风速的特征量采用变尺度滑动时间窗口算法, 动态地进行特征提取, 由提取结果对风电历史数据进行分类, 在此基础上选择特定参数建立对应的功率预测模型。为使模型在功率大幅度波动时刻的预测结果更加精确, 提出了基于频谱分析的修正方法。最后, 将不同天气类型下的功率预测结果与修正结果进行时序组合。算例结果表明, 所述变尺度时间窗口与波动特征提取相结合的短期风电功率组合预测方法可有效提高风速波动剧烈的风电场的风电功率预测精度。

关键词: 风电功率预测; 特征提取; 变尺度时间窗口; 组合预测

0 引言

随着风电在电力系统中的渗透率逐步提高, 其波动性、间歇性及随机性所引起的有功调度和系统可靠性等问题越来越突出, 准确的短期风电功率预测不仅可以优化常规电源的日发电计划、冷热备用容量及调整检修计划, 同时也有助于减轻风电接入对电网的冲击, 提高电网运行可靠性^[1-2]。

风速随机变化引起的风电功率波动是含风力发电的电力系统稳定、控制问题的主要不确定因素^[3-4]。但风速的波动变化并不是完全随机的, 仍然具有一定的规律性。因此, 研究不同气象条件下风速及其所对应的风电功率的变化规律对风电场的功率预测尤为重要。国内短期风电功率预测的主要方法多集中于时序法、神经网络法等, 这些方法通过历史风速和功率数据之间的线性或非线性关系建立模型, 进而对风电功率进行预测, 建模过程忽略了模型对风速具体特征的关联, 易产生功率预测系统误差。为解决功率预测模型的精度问题, 本文尝试依据不同天气条件对风速进行特征提取和分类预测, 进而

建立组合模型来提高模型的泛化性和风电功率的预测精度。

目前, 基于不同风速特征的风电功率预测尚未形成一套完整的理论体系。文献[5]将天气分型(weather patterns, WP)与系统聚类相结合对风电场进行超短期功率预测, 然而该方法需要考虑大量原始气象信息。文献[6]基于数值天气预报将风速大体分为5类, 建立了风电功率概率预测模型, 但并未考虑到实际工程应用中不同类型对预测精度的影响。文献[7]寻找相似日并用于电力负荷预测中, 但是时间尺度过大易产生误差。总之, 前述研究均是基于气象信息聚类或通过设定参数和阈值范围对风速进行分类, 仅抓住风速波动的历史统计特征, 这种特征不能完全体现风速波动的内在原因和过程特征, 故对下一时刻的风速不具有可预测性, 即不能有效反映风速与功率波动的变化关系。此外, 上述文献都没有针对功率波动物理特性在时序上提出风速更为精细的划分方法。

通过对风速序列施加时间窗口进行多重分形分析以区分不同风速类型, 而选取合适的预测时间窗口宽度对风速特征辨识和分类等研究都至关重要^[8-9]。然而, 目前国内对风电功率预测时间窗口的研究文献较少。文献[10-11]对风速的爬坡事件的预测时间窗口进行研究, 采用统计方法寻求窗口宽度最优的预测时间窗口。但目前对于时间窗口宽度

收稿日期: 2016-12-01; 修回日期: 2017-04-13。

上网日期: 2017-06-27。

国家自然科学基金资助项目(51477174); 国家自然科学基金中英国际合作交流基金资助项目(51711530227); 国家电网公司科技项目(5201011600TS)。

的研究尚处于静态建模阶段,不能保证在每个预测时间窗口内都能有效、完整地捕获风速变化过程。此外,不同的单体功率预测模型对不同的风速波动情况各有优势,适当的组合能克服单体模型的局限性,消除单体功率预测方法可能存在的较大偏差,提高功率预测的准确性^[12-13]。

针对前述问题,本文提出基于变尺度时间窗口和波动特征提取的短期风电功率组合预测方法。利用多重分形理论(multifractal theory, MT)分析不同天气类型的风速特征,可以全面地描述风速波动的过程特征,不仅概括了统计方式所描述的波动特征,更反映了波动的物理特性。此外,其谱参数的变化直接反映了风速时序的变化,进而采用变尺度时间窗口进行特征提取。利用频谱分析法对风电场预测功率与实际功率之间的差进行修正。通过算例分析得出,本文方法可以提高功率预测精度,尤其适用于恶劣天气下的功率预测分析。

1 基于天气分型的短期风电功率预测研究思路

数值天气预报是短期风电功率预测最主要的输入。因此本文提出了依天气分型的方法进行功率预测,并对预测结果进行修正来提高风电功率预测的准确性,即通过统计实际工程中风速及其功率的波动特性,找到影响风电功率预测准确性的几种天气类型,并选择与其相对应的功率预测模型,降低预测误差。

本文研究思路如图 1 所示。

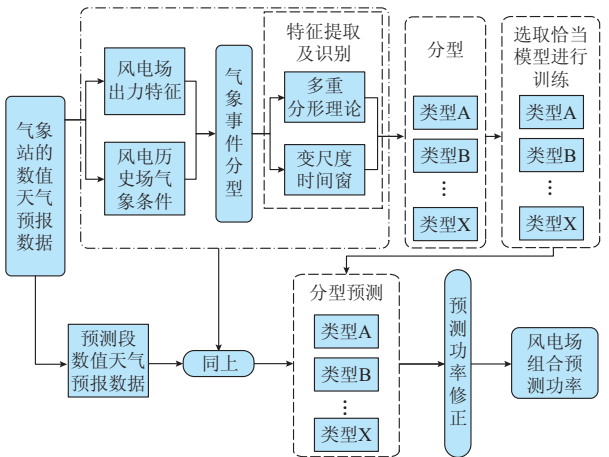


图 1 风电场组合预测的流程

Fig.1 Flow chart of wind farms combined prediction

首先,通过气象因素对风电场功率预测的影响对风速进行分类。其次,利用多重分形理论得到不同风速类型下的多重分形谱,并分析分形谱的形态

特征,提出表征其特征的特征量。然后,采用变尺度时间窗口根据当前的多重分形特征量动态地调整窗口的宽度,划分风速时间序列中不同的波动过程。最后,针对不同天气类型的特点选取不同参数分别建立模型。特别是针对波动剧烈时预测值在峰值附近的误差远远超过实际值的问题,本文提出了基于频谱分析的功率预测结果修正方法,从而得到最终的功率预测结果。依据不同波动类型建模和误差修正的组合预测方式,可以确保预测模型的结果保持较高的适应性和稳定性,尤其在风速波动剧烈时,以期得到更好的预测精度。

2 采用多重分形理论对风速进行分型

气象因素对风电场功率的幅值、波动性及预测的准确性有着重要的影响。气象因素主要包括风速、风向、气压、空气密度等^[14]。多数风机都具备自动偏航系统,且空气密度等变量在短时间内不会发生剧烈变化,因此风速是影响风电功率波动性最主要的因素^[15]。文献[6]考虑物理模型,经遍历数据研究,将风分成了 5 类。本文在此基础上进一步分析了风与功率预测的关系并进行分类。

首先,定义低出力阶段:

$$\begin{cases} v_i \in (0, v_{\text{cutin}}) & i = 1, 2, \dots, n \\ S_{v_i} = \frac{P_{v_i, \max} - P_{v_i, \min}}{|t_{v_i, \max} - t_{v_i, \min}|} < \xi \\ P_{\bar{v}} = \frac{1}{n} \sum_{i=1}^n P_{v_i} < \zeta \end{cases} \quad (1)$$

式中: v_i 为时间段 i 的风速; v_{cutin} 为切入风速,取值为 3~5 m/s; n 为总时间段数; ξ 和 ζ 分别为此阶段功率的波动系数^[16]及平均幅值的阈值(即满足预测误差小于 20% 时的预测功率值均小于 ζ),根据参考文献以及本文所用风电场的实际情况,分别选取 0.5 和 10; $P_{v_i, \max}$ 和 $P_{v_i, \min}$ 分别为该时间段预测功率 P_{v_i} 的最大值和最小值; $t_{v_i, \max}$ 和 $t_{v_i, \min}$ 分别为时间段 i 的长度最大值和最小值。

考虑到风速变化越大,功率预测误差越大^[17],因此将除低出力阶段以外的部分划分为小幅波动阶段和大幅波动阶段。小幅波动阶段按照发生比例又分为平缓波动阶段和小波动阶段,其中小波动阶段出力低,发生概率较小,由局部气流引起;平缓波动阶段则是风电场出力最主要的来源;考虑大波动阶段的功率时滞性,故将此阶段分为上升趋势阶段和下降趋势阶段。此外,当风速发生剧烈变化时,虽然发生次数很小,但是造成的影响却是最严重的,将此阶段单独分为尖峰阶段。

综上,在参考风过程变化的物理模型基础上,为

提高功率预测的精度,将风速划分为低出力阶段、小波动阶段、平缓波动阶段、上升趋势阶段、下降趋势阶段以及尖峰阶段。在特征提取时首先通过定义提取出低出力阶段,考虑到小波动阶段是由随机扰动和数值天气预报不准确引起的,难以挖掘该阶段的统计特征。因此下文只对其余 4 个阶段进行特征提取,剩下的部分则认为是小波动阶段。

2.1 多重分形理论

多重分形理论是定义在分型结构上由多个不同奇异指数 α 的子集构成的非均匀分布集合^[18],根据自相似性从序列局部出发研究整体特征的方法。可刻画风速时序 $\{V(t)\}$ 的局部分形特征,更真实地描绘复杂风速波动变化特征。目前鲜有文献将该方法应用到风电功率预测领域。

首先按 Mandelbrot 法^[19]验证风速时序 $\{V(t)\}$ 是否可用多重分形理论分析,具体内容见附录 A。

2.2 改进的盒计数法的计算

分形维是多重分形最主要的参量,它是对数据自相似性的一种数学描述,通常被用来分析没有规律的一段时间序列数据。设 L_a 是时间序列在其上的 Lipschitz 正则性为 a 的所有点的集合,传统分形维 $D(a)$ 的计算采用盒计数法,其定义^[20]为:

$$D(a) = \lim_{L \rightarrow 0} \frac{\ln N_a(L)}{\ln \frac{1}{L}} \quad (2)$$

式中: $N_a(L)$ 为用来覆盖边 L 所需边长为 $1/L$ 的小正方体的最小数目。

为了计算信号时间序列的分形维,采用式(3)的表达方式。

$$D(a) = 2 - H(\varphi) \quad (3)$$

式中: $H(\varphi)$ 为 Hurst 指数,表示数据自相似性的程度。

时间序列的 Hurst 指数位于 $[0, 1]$ 之间;当 $0 < H < 0.5$ 时,时间序列是分形布朗运动;当 $H = 0.5$ 时,表明时间序列可以用随机游走来描述;当 $0.5 < H < 1$ 时,表明时间序列存在长期记忆性和无周期循环。

对于随机序列,如 $\{V(t)\}$,传统盒计数法由等边长的正方形盒子所覆盖,而 Δt 的大小是固定的,会导致序列不能完全被覆盖,如附录 B 所示。因此引入 Hurst 指数使盒子可根据不同数据调整大小,使得时序曲线可以被相同宽度的 Δt 和不同高度的长方形盒子完全覆盖。Hurst 指数如下:

$$H(\varphi) = \lim_{\Delta t \rightarrow 0} \frac{\ln \varphi(\Delta t)}{\ln \Delta t} \quad (4)$$

$$\varphi(\Delta t) = \sum_{i=0}^{r-1} |f(t_i + \Delta t) - f(t_i)| \Delta t \quad (5)$$

式中: $f(t_i)$ 为时间 t_i 所对应的值; r 为序列长度。

$|f(t_i + \Delta t) - f(t_i)|$ 反映了数据在 Δt 的波动特性。将其代入式(3)得到分形维 $D(a)$ 的公式为:

$$D(a) = \lim_{\Delta t \rightarrow 0} \frac{2 \ln \varphi(\Delta t)}{\ln \Delta t} = \lim_{\Delta t \rightarrow 0} \frac{\ln \frac{\varphi(\Delta t)}{\Delta t^2}}{\ln \frac{1}{\Delta t}} \quad (6)$$

对权重指数 $q \in \mathbf{R}$, 定义尺度指数 $\tau(q)$ 如下:

$$\tau(q) = \min \left(q \left(a + \frac{1}{2} \right) D(a) \right) \quad (7)$$

多重分形谱 $f(\alpha)$ 与 $D(a)$ 满足勒让德变换:

$$\begin{cases} \alpha(q) = \frac{d\tau(q)}{dq} \\ f(\alpha) = q\alpha(q)\tau(q) \end{cases} \quad (8)$$

利用式(8)便可求得奇异性指数 α 和 $f(\alpha)$ 。

2.3 多重分形理论的主要参数

选取 3 个主要参数来描述不同波动特征下多重分形谱的表现形式。

1) 奇异性指数区间 $[\alpha_{\min}, \alpha_{\max}]$ 的宽度 $\Delta\alpha$:

$$\Delta\alpha = \alpha_{\max} - \alpha_{\min} \quad (9)$$

$\Delta\alpha$ 越大表示信号分布越不均匀,波动越剧烈,当波动的幅度变小时, $f(\alpha)$ 就有明显变窄的趋势。

2) 奇异谱函数的差 $\Delta f(\alpha)$:

$$\Delta f(\alpha) = f(\alpha_{\min}) - f(\alpha_{\max}) \quad (10)$$

$\Delta f(\alpha)$ 表示信号处于波峰、波谷位置数目的比例, $\Delta f(\alpha) > 0$ 表示风速更多地处于波峰,谱的顶部相对较圆滑, $\Delta f(\alpha) < 0$ 表示信号更多地处于波谷,谱的顶部相对较尖。

3) 奇异谱函数的对称性参数 S :

$$S = |\alpha_0 - \alpha_{\max}| - |\alpha_0 - \alpha_{\min}| \quad (11)$$

式中: α_0 为奇异谱函数 $f(\alpha)$ 取得最大值 f_{\max} 所对应的奇异性。

$S = 0$ 时,奇异谱是对称的; $S > 0$ 时,奇异谱峰值偏右,信号有增加的趋势; $S < 0$ 时,奇异谱峰值偏左,信号有减小的趋势。

3 基于变尺度滑动时间窗的特征提取

3.1 变尺度滑动时间窗算法

由上述参数及其所对应的风过程分析可知,多重分形理论可以更精细全面地描述时序的波动特性。但过多的参数不利于特征提取,通常将分形维作为波动序列提取的特征量,按相同的时间间隔对不同波动状态建立模型。但每一个波动过程的时间不一样,不能按照固定时间间隔来区分^[8-9]。因此,提出变尺度滑动时间窗口,如附录 C 图 C1 所示。附录 C 图 C2 为流程图,具体步骤如下。

步骤 1: 设总时间长度为 T_{all} , 在 $[0, T_{\text{all}}]$ 上设置系统参数, 即时间窗 $T_{w_i} (i=1, 2, \dots)$ 和时间步长 t_s 的大小, 并令初始 $T_{w_i} = t_s$ 。

步骤 2: 此时需判断当前时间窗 T_{w_i} 是否符合式(1), 若符合则为低出力阶段, 转到步骤 6; 如不符合转到步骤 3。

步骤 3: 读取当前时间窗的特征参数 $\alpha_i, f_i(\alpha), \Delta f_i(\alpha), S_i$; 通过 α 和 $\Delta f(\alpha)$ 判断曲线是否为函数, 若不是则为尖峰阶段, 转到步骤 6, 否则转到步骤 4。

步骤 4: 分析下一时间窗的特征值 $\alpha_{i+1}, \Delta f_{i+1}(\alpha), S_{i+1}$, 考察 $\Delta f_i(\alpha)$ 与 $\Delta f_{i+1}(\alpha)$ 及 S_i 与 S_{i+1} 的正负。若两组正负都相同则表明与前一时间窗有相同的上升或下降趋势, 此时考察 α_i 和 α_{i+1} 的差 $\Delta\alpha$, 若小于阈值 η (η 为对总时长上的数据进行多重分形得出的平均奇异指数值) 则与前时间窗段波动程度相当, 转步骤 6; 若不同则进入步骤 5。

步骤 5: 此时有两种情况, 即平缓波动阶段以及风速上升和下降的临界点。此时考虑下一时窗, 计算这 3 个小时时间窗的总方差 δ 。若 δ 小于 δ_0 (δ_0 为总时间长度上的数据的平均方差) 则处于平缓波动阶段, 转到步骤 6, 否则转到步骤 2。

步骤 6: 令 $i = i + 1$, 更新时窗 T_{w_i} 。

3.2 变尺度时间窗划分合理性检验

为了判断划分是否合理, 采用以下方法进行检验。

1) 设划分之后的总长度为 T , 在 $[0, T]$ 上有风速时序 $\{V(t)\}$, 且满足式(11), 则认为 $\{V(t)\}$ 是一个完整的变化过程, 令 $U(t) = \ln V(t) - \ln V(0)$ 。

$$E(|V(t, \Delta t)|^q) = \tau(q)(\Delta t)^{\tau(q)+1} \quad (12)$$

2) 将 $[0, T]$ 分割成 N 个长度为 Δt 的区间, 分割函数 S_q 如下:

$$S_q(T, \Delta t) = \sum_{i=0}^{N-1} |U(i\Delta t, \Delta t)|^q \quad (13)$$

式中: $i\Delta t$ 为包含于第 i 个盒子的长度, 由随机变量的矩特性及平稳增量得到。

$$\ln E(S_q(T, \Delta t)) = \tau(q) \ln \Delta t + \tau(q) \ln T \quad (14)$$

3) 改变固定窗口函数 $E(S_q(\Delta t))$ 为 $E(S_q(T, \Delta t))$:

$$E(S_q(T, \Delta t)) = E\left(\sum_{i=0}^{N-1} |V(i\Delta t, \Delta t)|^q\right) = NE(|V(\Delta t)|^q) \approx \frac{N}{M - \frac{\Delta t}{\sigma}} E\left(\sum_{i=0}^{M - \frac{\Delta t}{\sigma}} |V(i\Delta t, \Delta t)|^q\right) \quad (15)$$

式中: $V(i\Delta t, \Delta t) = V(i\Delta t + \Delta t) - V(i\Delta t)$; σ 为最小时间间隔, 由于本文所采用的数据时间分辨率为 15 min, 而波动性分析时间范围不宜过长, 所以这里

令 σ 为 5 个采样点的距离; $M = T/\sigma$ 为区间数。

根据式(12)和式(14)判断 $\ln E(S_q(\Delta t))$ 与 $\ln \Delta t$ 是否存在线性关系, 若 $\ln E(S_q(\Delta t))$ 与 $\ln \Delta t$ 存在线性关系, 则根据 $\tau(q)$ 和 q 线性关系判断是否是一个完整的波动过程。

4 风电场短期功率组合预测模型建立

目前已有研究表明, 以自回归滑动平均法 (ARMA) 为代表的时序法更适用于气象信息有限的平稳或小幅波动系统^[21]。为了提高计算效率, 考虑到低出力和小波动阶段的特点, 即风速小、波动幅度小, 与气象信息的相关性低, 采用 ARMA 对下一时刻的功率预测值进行预测。其他 4 种类型采用最小二乘支持向量机 (LSSVM) 作为基准模型进行预测。

4.1 LSSVM 训练

LSSVM 通过非线性映射函数 $\varphi(x)$ 将样本映射到高维的特征空间中, 记录的是训练样本输入与输出之间的非线性关系。所以当训练数据与预测数据属于同一类型时, 会使预测精度较大提高^[22]。LSSVM 的非线性函数为:

$$y(x) = \sum_{i=1}^l a_i K(x, x_i) + b \quad (16)$$

式中: a_i 为拉格朗日乘子; b 为偏差; $K(x, x_i)$ 为核函数, 具体预测步骤如下。

1) 对各数据的指标值进行标准化处理, 即将所有具有不同量纲指标的值规范化到 $[-1, 1]$ 。

2) 按照各分量的变化规律, 分别选用不同的 LSSVM 核函数及参数进行训练。

3) 根据训练数据得到的误差大小, 按照交叉验证的方法选择合适的核函数, 以及所对应的参数。

4) 用选择好的不同的核函数和不同参数进行训练, 并对预测结果进行检验。

5) 将预测段的相似数据输入已经训练好的模型进行预测, 得到最终的预测结果。

4.2 基于分型的功率预测值修正

采用上述方法对未来一天进行预测时, 在尖峰阶段的预测结果具有峰顶上去、峰谷低不下的特点, 除数值天气预报的误差以外还有模型本身的原因, 然而尖峰阶段的误差往往是影响最大的, 在实际工程中常因此导致考核不合格而影响电厂利益。为使风电功率预测的结果尤其是在尖峰时刻更加接近真实值, 需要在前文的基础上对预测功率做出修正。

因此, 本文在分析时域上不同风速类型下的风电功率预测以外, 还考虑了风电功率在频域上的统计特性。分析预测误差的功率谱特征, 选择合适的模型对原始功率预测结果进行滤波, 进而针对尖峰阶段“高不上去、低不下来”的特征进行反向补偿, 即

不是单纯滤波而是把滤掉的尖峰部分的值补偿到原始预测结果中进行修正。

谱分析法是从频域上对风电出力的时间序列进行分析。利用谱分析法可以更加简明地研究不同天气类型下出力的波动状况^[23]。谱分析修正功率方法的详细模型、相关概念和算法步骤在附录 D 中有详细介绍^[24]。

4.3 模型建立

通过采用多重分形理论和变尺度时间窗对风速波动特征分型对提高风电功率预测精度有重要意义。本文通过 LSSVM 模型对基于天气分型下的风速时序的各阶段分别进行预测,可以确定不同核参数的 LSSVM 模型针对不同天气下的相对有效性,选出不同特征下的最优模型进行组合,加强对不同风速的适应性,提高预测精度。

具体步骤如下:首先,按前文方法对风速时间序列进行分型;其次,按照各分量的变化规律,分别选用最优的 LSSVM 核函数及参数建立相应的预测模型;最后,考虑功率波动特性,在频域上进行分析,根据实际功率谱的趋势对预测功率进行修正,并在时序上将已经分开的模型在进行组合得到最终预测结果。建模过程如图 2 所示。

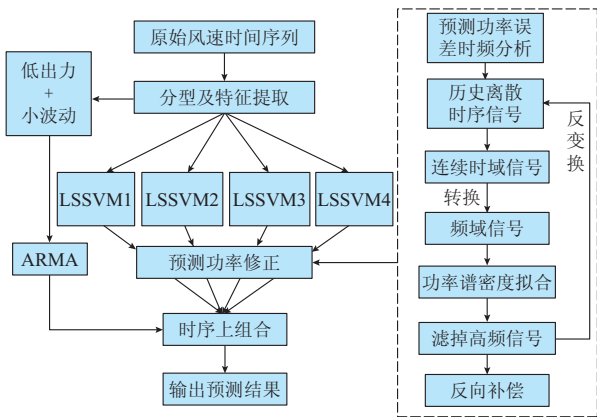


图 2 组合预测流程图

Fig.2 Flow chart of combined prediction

5 算例分析

国内风电场大多建在有显著季风性气候的地区,因此在对模型进行训练时不能直接使用全年数据统一建模。然而预测周期选取太短不能反映模型特点,若按月或者季节则会大大降低计算效率。实际工程项目中将 11 月至次年 3 月作为大风期,同年 4 月至 10 月作为小风期。本文以国内某风电场作为研究对象,该风电场的装机容量为 78 MW,时间分辨率为 15 min。选择 2014 年 12 月至 2015 年

2 月(大风期)作为训练段,选择 2015 年 3 月作为预测段;选择 2015 年 4 月至 6 月(小风期)作为训练段,选择 2015 年 5 月作为预测段。若待预测月份处于过渡期,如 11 月,那么采用去年同月和其相邻月份的历史数据作为训练模型。

采用国家电网公司 Q/GDW 588—2011《风电功率预测功能规范》给出的均方根误差(RMSE)以及平均绝对误差(MAE)对预测的结果进行误差分析。

5.1 基于天气分型的短期风电功率预测

在利用多重分形理论分析前,按照第 2 节所述,首先将风电的低出力波动阶段提取出来用 ARMA 进行预测,下一节仅对平缓波动阶段、尖峰波动阶段、趋势波动阶段进行分析。剩余则为小波动阶段,也采用 ARMA 进行预测。

5.1.1 多重分形分析

附录 E 图 E1 给出了几种典型的多重分形谱,其部分谱参数参见附录 E 表 E1。

图 E1(d)是遇到尖峰阶段,波形不是函数,有明显起伏,时序上不连贯且自相似性低。其他谱函数均为单峰,但形状又各不相同。图 E1(a)中参数 S 大于 0,谱峰值偏右,风速的大小在该阶段有增加的趋势。而 $\Delta f(\alpha)$ 代表了在波峰、波谷位置数目的比例, $\Delta f(\alpha)$ 都大于 0,说明在上升阶段也是振荡上升伴随有小幅度的下降。图 E1(c)中 $\Delta\alpha$ 最小,表明波动的起伏程度平缓。图 E1(b)与图 E1(a)相似,但谱峰值偏左,风速的大小在该阶段有减小的趋势。总的来说多重分形谱的形状是与原始时间序列的特征密切相关的^[19]。

5.1.2 变尺度滑动时间窗口分析

按文献[10]的方法选取最优时间窗宽为 2 h,即 8 个采样点。如附录 E 图 E2 所示,为了更明显地看出采用固定窗口和本文方法的区别,仅采用一天的数据对比,分别用固定时间窗口和变尺度滑动时间窗口的方法对该数据进行多重分形处理,得到波动函数 $\ln E(S_q(\Delta t))$ 与 $\ln \Delta t$ 的双对数关系。可以看出,采用变尺度时间窗口划分的方法使得窗口内每条曲线都是直线,即说明窗口内每一段数据都具有相似性,进一步体现该方法对风速时间序列识别和分类的有效性和准确性。

综上,将样本按照低出力、小波动、平缓波动、上升趋势、下降趋势和尖峰波动阶段分为 6 类。如图 3 所示,为显示清晰图表仅分别展示 1 200 个采样点的结果,附录 E 表 E2 为不同天气类型下样本数量。




图3 风速分型结果
Fig.3 Patterning results of wind speed

5.1.3 功率预测

上节对预测月的6种不同类型进行了区分,其中低出力和小波动阶段采用ARMA对下一时刻误差值进行预测。其他阶段采用LSSVM分别建模,训练段的输入参数均为风速和相应的实际功率,预测段的输入为风速,输出为预测功率值。附录E表E3为基于不同天气模型的预测精度统计情况并与单一的基于全年数据建模的预测结果对比。

采用单一模型与分型模型在大风期和小风期下的预测结果参见附录E图E3。可以看出,对于同一种算法,采用基于天气分型法要优于不分型的方法,尤其是在大风期,风速有明显大幅度的趋势变化时候。但是,在风电功率剧增和陡降的时刻误差仍然很大,因此,需要在已得到预测结果基础上,对波峰、波谷时刻的功率进行修正。将离散的功率预测结果转换为连续的时域信号后,再转换为频域信号,考虑不同天气下的实际功率的频率统计特性并对预测功

率进行修正,以提高整体预测精度。

5.2 基于频域功率修正

按照3.2节的分析,对处于峰顶以及峰谷时期的功率预测值进行修正。首先利用4.2节的算法将离散的预测功率时域信号转换为频域信号,如附录E图E4所示(为显示清晰,仅给出部分数据)。分别截取3月和5月份连续7天的波峰及波谷的预测误差进行频谱特性分析并对其后的3天数据进行修正。由于是短期预测功率修正,所以只考虑7天的预测误差作为修正标准,对其后3天预测数据进行修正。实际工程中可以得到前一天的实际功率值并进行滚动循环,符合短期预测的时间要求。根据样本数据预测误差水平,本文选取95%和90%置信度水平作为参考依据。

根据前文的方法,对功率误差的时域信号频谱拟合结果的参数值如附录E表E4所示。将得到的新的时域信息采用反变换,累加在原来预测的结果上最终得到修正之后的预测功率。

基于频谱分析修正后的结果见附录E图E5(c),预测功率的功率谱的所有点已经落在误差的95%置信区间内。除少数点外,绝大多数补偿后的预测误差处于小误差层。此外,附录E图E5(b)中(仅展示有剧烈波动的时刻)绘出了48h进行修正前后的风电功率预测值。

5.3 组合预测结果

由于前文的预测结果都是对分类之后的各部分进行预测,需要重新整合为原来的时序,进行整体的月精度统计。表1展示了4种不同类型下的预测结果及最终的月精度统计。为证明本文所提出的方法的通用性,将不分型建模的LSSVM和ARMA作为基本预测方法。由于用到了每个月的前7天数据进行修正,测试数据为2015年3月8日至3月31日,以及2015年7月8日至2015年7月31日,测试结果如表1所示。

表1 不同模型功率预测精度统计
Table 1 Prediction accuracy statistics of power for different models

风期	预测模型	低出力和小波动阶段		平缓波动阶段		趋势波动阶段		尖峰波动阶段		月精度统计	
		RMSE/%	MAE/%	RMSE/%	MAE/%	RMSE/%	MAE/%	RMSE/%	MAE/%	RMSE/%	MAE/%
大风期	LSSVM	15.558	10.274	16.413	12.193	17.085	13.954	24.032	23.824	18.272	15.061
	ARMA	15.444	10.286	18.478	13.395	18.632	17.395	24.964	23.279	19.379	16.089
	WP-LSSVM	15.278	9.623	15.350	11.944	16.081	13.577	18.348	18.260	16.264	13.351
	功率修正	15.418	9.483	15.410	10.452	15.066	12.084	17.710	15.815	15.901	11.959
小风期	LSSVM	14.296	9.223	14.557	11.623	14.782	11.839	21.273	18.587	14.752	12.818
	ARMA	14.317	9.209	14.849	14.209	21.001	18.309	24.907	17.560	20.519	14.822
	WP-LSSVM	13.933	8.870	14.931	10.203	13.802	12.203	16.289	14.959	14.014	11.559
	功率修正	13.933	8.870	14.031	10.203	13.562	12.078	14.649	13.841	13.971	11.248

图4给出了各模型的功率预测曲线,在低出力和小波动阶段,与LSSVM相比,ARMA的预测效果已达到要求,并且经过分型之后精度小幅提高,为不降低计算效率,该阶段采用ARMA足矣。同时与传统的LSSVM相比,采用本文所述模型的功率预测值更接近实际值。




图4 预测日的预测结果对比
Fig.4 Comparison of forecasting results for prediction day

附录E图E6给出了不同风速类型、不同模型下,各功率预测误差指标对参考方法(按全年数据统一建模的LSSVM)的变化情况。很明显对于其他类型,LSSVM较ARMA更加适合。而且经过天气分型之后的WP-LSSVM比单一模型训练的预测精度均有不同程度的提高。再经过对预测功率的修正,预测误差明显小于其他3种模型,尤其是在尖峰阶段和趋势上升阶段误差明显减小。这是因为大部分算法都是基于数值天气预报的,而数值天气预报对于突然变化的风是不能够准确事先预知的,因此需要通过对以往的预测数据进行统计分析,对波动幅度大的地方进行再修正,才能使得预测结果能够尽量贴近实际值。

尽管本文方法在大部分阶段都取得了良好的预测结果,但同时也观察到在大风期的低出力和平稳阶段,功率修正之后的RMSE要高于没有修正的数据,造成这种现象的原因是使用某时间段的数据训练模型时,由于不同类型的样本数量不同,会发生过补偿,在一定程度上影响预测精度。但是,与此同时也观察到MAE优于未修正之前。这表明本文的方法在提高预测稳定性方面,还是起了效果,在实际工程中可以根据风电场更侧重精度还是稳定性而对修

正的比例系数进行调整。

将在时间上分类的功率预测值按原来的时间序列组合,得到最终组合预测结果,在大风期,RMSE与原始算法相比提高了1.55%,MAE提高了1.568%;在小风期,RMSE与原始算法相比提高了0.781%,MAE提高了0.77%。

因此,从总体误差指标统计来看,基于变尺度时间窗口和波动特征提取的短期风电功率组合预测算法对于精度的提高显著,尤其适合有大幅波动的天气且波动越剧烈功率预测。

6 结语

本文提出一种基于变尺度时间窗口和波动特征提取的短期风电功率组合预测方法。首先,考虑到风速的波动变化是一个十分复杂的分形过程,具有随机性和自相似性,利用多重分形谱能够更为全面地刻画风速波动的物理特征。其次,根据风速波动的多重分形特征值,利用变尺度时间窗口动态地对风速序列进行特征提取,并得到一个完整的波动过程。最后,利用BT(Blackman-Tukey)法和离散傅里叶变换分析风电功率在频域内的分布特性,对功率谱密度进行估计、拟合,并提出了一种基于频谱分析的风电场预测功率的修正方法。算例表明,本文提出的模型考虑了不同风速波动特征,具有一定的自适应性,预测效果较为理想,可以减少较大误差的出现,提高风电场风电功率的预测精度。

本文在完成过程中,受到新能源与储能运行控制国家重点实验室开放基金资助,谨此致谢。

附录见本刊网络版(<http://www.aeps-info.com/aeps/ch/index.aspx>)。

参考文献

- [1] 李俊峰,蔡丰波,乔黎明,等.2014中国风电发展报告2014[R].2014.
- [2] 薛禹胜,郁琛,赵俊华,等.关于短期及超短期风电功率预测的评述[J].电力系统自动化,2015,39(6):141-151.DOI:10.7500/AEPS20141218003.
XUE Yusheng, YU Chen, ZHAO Junhua, et al. A review on short-term and ultra-short-term wind power prediction[J]. Automation of Electric Power Systems, 2015, 39(6): 141-151. DOI: 10.7500/AEPS20141218003.
- [3] 余慎思,李征,蔡旭.基于风电场动态时空关系的风速分布模型研究[J].电网技术,2014,38(6):1432-1438.
SHE Shensi, LI Zheng, CAI Xu. Research on wind speed distribution model of wind farm based on its dynamic space-time

relation [J]. Power System Technology, 2014, 38(6): 1432-1438.

[4] ZHAO Yongning, YE Lin, LI Zhi, et al. A novel bidirectional mechanism based on time series model for wind power forecasting[J]. Applied Energy, 2016, 177(1): 793-803.

[5] MU Gang, YANG Mao, WANG Dong, et al. Spatial dispersion of wind speeds and its influence on the forecasting error of wind power in a wind farm[J]. Journal of Modern Power Systems and Clean Energy, 2016, 4(2): 265-274.

[6] 王铮, 王伟胜, 刘纯, 等. 基于风过程方法的风电功率预测结果不确定性估计[J]. 电网技术, 2013, 37(1): 242-247.

WANG Zheng, WANG Weisheng, LIU Chun, et al. Uncertainty estimation of wind power prediction result based on wind process method[J]. Power System Technology, 2013, 37(1): 242-247.

[7] 牛东晓, 魏亚楠. 基于 FHNN 相似日聚类自适应权重的短期电力负荷组合预测[J]. 电力系统自动化, 2013, 37(3): 54-57.

NIU Dongxiao, WEI Yanan. Short-term power load combinatorial forecast adaptively weighted by FHNN similar-day clustering [J]. Automation of Electric Power Systems, 2013, 37(3): 54-57.

[8] 戚永志, 刘玉田. 基于竞争博弈的风电爬坡协同控制策略[J]. 中国电机工程学报, 2014, 34(25): 4341-4349.

QI Yongzhi, LIU Yutian. Ramping coordination control of wind generation based on competitive game theory[J]. Proceedings of the CSEE, 2014, 34(25): 4341-4349.

[9] YANG Long, TIAN Fuqiang, HU Heping. Proper forecast window in ensemble streamflow prediction (ESP) approach[R]. 2011.

[10] 欧阳庭辉, 查晓明, 秦亮, 等. 风电功率爬坡事件预测时间窗选取建模[J]. 中国电机工程学报, 2015, 35(13): 3204-3210.

OUYANG Tinghui, ZHA Xiaoming, QIN Liang, et al. Modeling on selection of the time window for ramp events prediction [J]. Proceedings of the CSEE, 2015, 35(13): 3204-3210.

[11] CUI Mingjian, KE Depin, GAN Di, et al. Statistical scenarios forecasting method for wind power ramp events using modified neural networks[J]. Journal of Modern Power Systems and Clean Energy, 2015, 3(3): 371-380.

[12] 叶林, 刘鹏. 基于经验模态分解和支持向量机的短期风电功率组合预测模型[J]. 中国电机工程学报, 2011, 31(31): 102-108.

YE Lin, LIU Peng. Combined model based on EMD-SVM for short-term wind power prediction [J]. Proceedings of the CSEE, 2011, 31(31): 102-108.

[13] 叶林, 朱倩雯, 赵永宁. 超短期风电功率预测的自适应指数动态优选组合模型[J]. 电力系统自动化, 2015, 39(20): 12-18. DOI: 10.7500/AEPS20141128002.

YE Lin, ZHU Qianwen, ZHAO Yongning. Dynamic optimal combination model considering adaptive exponential for ultra-short term wind power prediction[J]. Automation of Electric Power Systems, 2015, 39(20): 12-18. DOI: 10.7500/AEPS20141128002.

[14] 赵永宁, 叶林. 区域风电场短期风电功率预测的最大相关-最小冗余数值天气预报特征选取策略[J]. 中国电机工程学报, 2015, 35(23): 5985-5994.

ZHAO Yongning, YE Lin. A numerical weather prediction feature selection approach based on minimal-redundancy-maximal-relevance strategy for short term regional wind power prediction [J]. Proceedings of the CSEE, 2015, 35(23): 5985-5994.

[15] SAKAMOTO T, TANIZUKA N, HIRATA Y, et al. A fractal dimension of wind speed time series[C]// International Conference on Noise and Fluctuations, September 9-14, 2012, Tokyo, Japan: 7p.

[16] 黄坡, 朱小帆, 查晓明, 等. 基于波动过程聚类的风电功率预测极大误差估计方法[J]. 电力系统保护与控制, 2016, 44(13): 130-136.

HUANG Po, ZHU Xiaofan, ZHA Xiaoming, et al. An estimation method for wind power prediction great error based on clustering fluctuation process[J]. Power System Protection and Control, 2016, 44(13): 130-136.

[17] MARQUIS M, WILCZAK J, AHLSTROM M S, et al. Forecasting the wind to reach significant penetration levels of wind energy [J]. Bulletin of the American Meteorological Society, 2011, 92(9): 1159-1171.

[18] POPE S B. Turbulent flows [M]. England: Cambridge University Press, 2000.

[19] PIACQUADIO M, BARRA A D L. Multifractal analysis of wind velocity data[J]. Energy for Sustainable Development, 2014, 22(1): 48-56.

[20] HALSEY T C, JENSEN M H, KADANOFF L P, et al. Fractal measures and their singularities: the characterization of strange sets[J]. Physical Review A, 1986, 33(2): 1141-1150.

[21] 叶林, 任成, 赵永宁, 等. 超短期风电功率预测误差数值特性分层分析方法[J]. 中国电机工程学报, 2016, 36(3): 692-700.

YE Lin, REN Cheng, ZHAO Yongning, et al. Stratification analysis approach of numerical characteristics for ultra-short-term wind power forecasting error [J]. Proceedings of the CSEE, 2016, 36(3): 692-700.

[22] 琛郁, 薛禹胜, 文福拴, 等. 按时序特征优化模型后在线选配的超短期风电预测[J]. 电力系统自动化, 2015, 39(8): 5-11. DOI: 10.7500/AEPS20141230007.

YU Chen, XUE Yusheng, WEN Fushuan, et al. An ultra-term wind power prediction method using “offline classification and optimization, online model matching” based on time series features[J]. Automation of Electric Power Systems, 2015, 39(8): 5-11. DOI: 10.7500/AEPS20141230007.

[23] 李滨, 陈姝, 韦化. 风电场储能容量优化的频谱分析方法[J]. 中国电机工程学报, 2015, 35(9): 2128-2134.

LI Bin, CHEN Shu, WEI Hua. Optimization of energy storage capacity based on spectral analysis for wind farm [J]. Proceedings of the CSEE, 2015, 35(9): 2128-2134.

[24] MIAO Fufeng, TANG Xisheng, QI Zhiping. Fluctuation feature extraction of wind power[C]// IEEE Innovative Smart Grid Technologies-Asia, May 21-24, 2012, Tianjin, China: 5p.

叶 林(1968—),男,通信作者,教授,博士生导师,德国洪堡学者,主要研究方向:电力系统自动化、新能源发电技术。E-mail: yelin@cau.edu.cn

滕景竹(1991—),女,硕士研究生,主要研究方向:电力系统运行与控制、新能源发电技术。E-mail: tengjingzhu@

cau.edu.cn

蓝海波(1974—),硕士,高级工程师,国网冀北电力有限公司省公司级专家人才,主要研究方向:电网调度。E-mail: lan.haibo@nc.sgcc.com.cn

(编辑 万志超)

Combined Prediction for Short-term Wind Power Based on Variable Time Window and Feature Extraction

YE Lin¹, TENG Jingzhu¹, LAN Haibo², ZHONG Wuzhi³, WU Linlin⁴, LIU Hui⁴, WANG Zheng³

(1. College of Information and Electrical Engineering, China Agricultural University, Beijing 100083, China;

2. State Grid Jibei Electric Company Limited, Beijing 100053, China;

3. China Electric Power Research Institute, Beijing 100192, China;

4. Electric Power Research Institute of State Grid Jibei Electric Company Limited, Beijing 100045, China)

Abstract: Short-term wind power prediction is a crucial technology to ensure security and stable operation of power grid connected with large-scale wind farms. The fluctuation and predication accuracy of wind power are definitely affected by the intermittence and variability of wind speed. This paper proposes a combined prediction method for short-term wind power based on the variable time window and feature extraction in wind speed. At first, a multifractal spectrum is used to investigate wind speed characterizations. Then, on the basis of the wind fluctuation definition, an abstracting feature extraction approach is proposed by use of a sliding variable time window algorithm capable of self-adaptively adjusting the size of time window width. The historical data is classified according to the fluctuation events abstracting results. Different prediction models are developed by selecting specific parameters after analyzing the fluctuation events characteristics. The presented method employs spectrum analysis to correct errors in power prediction full aware of the complexity and multiformity of output wind power in different time periods. Finally, case studies are carried out to verify and evaluate the availability of the proposed model. Results show that the short-term forecasting accuracy of wind power has been improved in various wind situations.

This work is supported by National Natural Science Foundation of China (No. 51477174, No. 51711530227) and State Grid Corporation of China (No. 5201011600TS).

Key words: wind power prediction; feature extraction; variable time window; combined prediction