

基于时间连续性及季节周期性的风速短期组合预测方法

蒋小亮¹, 蒋传文¹, 彭明鸿¹, 林海涛¹, 李子林²

(1. 上海交通大学电子信息与电气工程学院, 上海市 200240; 2. 上海市风力发电有限公司, 上海市 200090)

摘要: 根据风电机组功率曲线, 可由风速计算出风电机组出力, 因此, 风电功率预测问题可转化为风速预测问题。基于风电场气象及风速数据的时间连续性及季节周期性, 提出了一种风速短期组合预测模型。该模型采用模式识别技术分别提取时间连续性的样本及季节周期性的样本, 以反向传播(BP)神经网络作为预测模型, 得到风速横向预测值和纵向预测值, 最后再通过BP神经网络进行组合预测。对国内某风电场的风速预测结果表明, 所提出的风速预测模型可行、有效, 具有较好的预测精度。

关键词: 风速预测; 时间连续性; 季节周期性; 模式识别; 反向传播(BP)神经网络

0 引言

随着风电场穿透功率的增加, 风能的随机性、间歇性等特点给电力系统安全稳定和经济运行带来一系列的影响, 例如增加制定调度计划的难度、影响电能质量、改变潮流分布、增加线路阻塞、不利于可靠性分析、提高备用成本等^[1-3]。因此, 风电功率预测显得十分必要, 其不但有利于电网调度人员制定计划、评估系统可靠性, 而且有利于合理安排备用及阻塞管理等。根据风电机组的功率曲线, 可以由风速计算出风电机组的出力, 由此, 风电功率预测问题可转化为风速预测问题。

风速预测方法主要有持续法、卡尔曼滤波法、时间序列法、神经网络法和空间相关法等^[4]。其中, 持续法最简单, 直接将上一时刻的风速值作为当前时刻的风速预测值; 时间序列法根据风速的时间相关性进行预测, 是应用较多的方法; 神经网络法虽然在很多领域都有很好的预测效果, 但要求其样本具有较高的相似度, 预测效果受风电场的风速特性影响较大; 空间相关法需要考虑预测点及相邻点的风速, 所需数据量较大。目前, 风电场风速预测误差约为25%~40%^[5]。

为了达到更高的预测精度, 近年来的一般做法是对上述算法的某些步骤加以改进, 或将若干算法加以结合产生混合算法进行预测。文献[6]将人工神经网络与马尔可夫链相结合, 由人工神经网络预测得到的风速结果将通过马尔可夫链进行校正, 使

之与风速长期模式相吻合; 文献[7]利用风速呈季节性周期变化的特点, 将时间序列分析与灰色预测方法相结合形成组合预测方法进行风电场风速预测; 文献[8]充分考虑气象因素以及各个风电场的相关性, 采用自适应动态预测方法进行风速和风电场功率预测; 此外还有将小波理论应用于风速预测中以及组合预测的方法等^[9-11]。这些方法都不同程度地提高了预测精度, 然而其对于风速内在的规律和性质考虑不够。首先, 这些预测方法都直接采用了预测日之前的样本信息, 并没有对这些样本作出识别选择, 忽略了样本信息与预测日信息之间相似度差的问题; 另外, 这些方法仅仅考虑了风速的随机性, 而没有利用风速在随机性的表面特征之下的内在规律性。

与以上预测方法相比, 本文更关注于风速本身所具有的性质, 提出了基于季节周期性及时间连续性的风速短期组合预测模型。一方面, 随着季节的周期性变化, 不同年份的同一季节、同一月份的风速具有一定的周期性, 根据风速在横向历史上的周期性可以得到一个未来的风速预测值, 本文称为横向风速预测值; 另一方面, 相邻日的气候变化一般不大, 相邻日风速具有连续变化的特征, 根据风速在纵向上的时间连续变化特征得到一个未来风速预测值, 本文称为纵向风速预测值。横向预测和纵向预测均采用反向传播(BP)神经网络作为预测模型, 并在预测之前采用模式识别技术对样本集进行识别选择。最后将横向风速预测值及纵向风速预测值作为输入, 仍采用BP神经网络模型进行组合预测, 得到最终的风速预测值。预测结果表明, 本文所提出的预测方法预测误差较小, 具有良好的应用前景。

收稿日期: 2009-11-07; 修回日期: 2010-06-02。

国家高技术研究发展计划(863计划)资助项目(2007AA05Z458)。

1 模式识别技术

模式识别技术是一种通过反映事物的特征量对样本集进行分类的技术,主要分 2 步:首先是模式构造,即提取那些反映事物特性的向量,构成模式向量;其次是模式识别,即将待识别的模式向量与描述模式的特征集进行匹配。采用模式识别技术进行样本选择,可以有效提高预测精度^[12-13]。

1.1 模式构造

模式构造过程应遵循 2 个原则:一是在保证正确反映样本特性的前提下尽量减少特征向量的维数;二是保证在进行模式识别时特征向量间的相互干扰要小。风电场的风速主要受地理位置、地形等地貌信息以及温度、风力等级(气象预报中的风速等级)、风向等气象信息的影响,模式向量应该从这些量中提取。风电场的地貌信息一般不会有变化,可以不予考虑,模式向量主要从气象因素中提取。本文选取日最高温度 T_h 、日最低温度 T_l 、日最大风力等级 W_b 、日最小风力等级 W_s 和日风向 D (天气预报中给出的预报风向)等 5 个影响风速的主要因素构造模式向量 \mathbf{X} ,即 $\mathbf{X}=(T_h, T_l, W_b, W_s, D)$ 。模式构造过程完成后,可根据风电场历史气象信息按模式结构形成样本集。

1.2 样本归一化

各个模式向量元素的单位不同,数值差异较大,将会影响模式识别的结果,对模式向量元素进行归一化,可有效降低这种影响。

1.2.1 温度归一化

文献[13]给出一种 S 型函数,可以完成对温度的归一化,其表达式为:

$$T' = \left(1 + e^{\frac{5-T}{10}}\right)^{-1} \tag{1}$$

式中: T 为归一化前的原始温度; T' 为归一化后的温度。

1.2.2 风力等级归一化

风力等级反映的是气象预报中日最大、最小风速,数值范围不大,可以采用极大极小差值法对其归一化,其公式表示为:

$$W_i' = \frac{W_i - W_{\min}}{W_{\max} - W_{\min}} \tag{2}$$

式中: W_i' 为样本 i 的风力等级经归一化后的数值; W_i 为样本 i 归一化前最大、最小风力等级的平均值; W_{\max} 和 W_{\min} 分别为所有样本中最大、最小风力等级的数值。

1.2.3 风向归一化

气象预报给出的风向不是数值,因此首先要对其编码,编码表见表 1。

表 1 风向编码表
Table 1 Code table of the wind direction

风向	无	东北	东	东南	南	西南	西	西北	北
编码	0	1	2	3	4	5	6	7	8

对风向编码后,模式向量中的日风向就变成了数值。在所有样本中,找到日风向分量的最大值及最小值,采用式(2)对样本中的日风向分量进行归一化。

1.3 模式识别

根据天气预报信息及模式向量结构形成预测日的模式向量,通过欧式距离判断历史样本模式向量与预测日模式向量的相似度,相似度高的历史样本模式向量被认为与预测日模式向量属于同一个模式,可以作为预测样本。设样本集为 Θ ,样本总数为 N ,样本 i 的模式向量为 $\mathbf{X}_i=(x_{i1}, x_{i2}, \dots, x_{im})$,预测日 t 的模式向量为 $\mathbf{X}_t=(x_{t1}, x_{t2}, \dots, x_{tm})$, m 为模式向量元素个数。相似度判别公式如下:

$$r_{it} = \left|1 - \sqrt{\sum_{j=1}^m (x_{ij} - x_{tj})^2}\right| \tag{3}$$

利用模式识别技术选取风速预测样本的步骤如下:

- 1)根据式(3)逐一计算各个样本模式向量与预测日模式向量的相似度。
- 2)选定相似度最高的前 n 个样本作为预采用样本。

模式识别的作用在于根据气象信息选出风速规律相近的历史日期,其模式结构未必符合预测时的模型输入模式。因此,这里将选出的样本定义为预采用样本,再根据预测模型输入的需要,重新形成训练样本的模式向量。

2 风速短期组合预测

以往的组合预测方法大多是将各种预测模型加以纵向或横向组合。纵向组合预测一般是用前一个预测方法对样本进行预处理,再传递给下一个预测模型来预测^[10]。横向组合预测就是将各个预测模型的预测值通过加权的方式得到最终的预测值^[11]。本文则根据风速和气象信息的横向季节周期性和纵向时间连续性,采用 BP 神经网络模型预测得到横向风速预测值及纵向风速预测值,最后通过神经网络进行权重组合预测。BP 神经网络模型是一个比较成熟的模型,本文均采用 3 层网络、单极性 S 型转移函数。

2.1 基于 BP 神经网络的横向风速预测

BP 神经网络的结构如图 1 所示。图中: v_i 为输入样本第 i 个时间点的风速值; v_i' 为预测日第 i 个

时间点的预测值; ΔT_h 为输入样本日与预测日最高温度的差值; ΔT_l 为输入样本日与预测日最低温度的差值; ΔW_b 为输入样本日与预测日最大风力等级的差值; ΔW_s 为输入样本日与预测日最小风力等级的差值。本文 BP 神经网络的中间层采用 Kolmogrov 提出的结构,当输入层的神经元数为 k 时,隐层节点数为 $2k+1$ 。本文输入层神经元数为 5,因此中间层神经元数为 11。




图 1 BP 神经网络结构
Fig. 1 Structure of the BP neural network

设有 Z 年(不计预测日所在年份)的历史数据,预测日为 t ,则其模式向量为 $\mathbf{X}_t = (T_{hr}, T_{lr}, W_{br}, W_{sr}, D_t)$ 。设横向训练样本数为 M_1 ,则基于 BP 神经网络的横向风速预测步骤如下:

1)从历史数据中(去除预测日所在年份)选择与预测日 t 同日的的数据及该日前 $0.5n_1$ 日的的数据,后 $0.5n_1-1$ 日的的数据,按模式结构形成模式向量,组成一个含有 Zn_1 个样本的集合,作为模式识别的对象样本集($n_1 \geq 2M_1$)。

2)对所有样本进行归一化处理。

3)根据式(3)逐一计算 Zn_1 个模式向量与预测日 t 的模式向量的相似度。

4)选出与预测日 t 的模式向量相似度最大的前 M_1 个样本组成预采用样本集 A_1 。

5)根据图 1 中神经网络输入向量的结构及集合 A_1 中样本对应的历史日期,构造训练样本集 B_1 。用集合 B_1 中的样本训练 BP 神经网络模型。

6)将与预测日 t 相似度最高的历史样本作为输入,求取预测日 t 各个时间点的风速预测值,得到预测日 t 的横向风速预测值。

2.2 基于 BP 神经网络的纵向风速预测

纵向风速预测与横向预测类似,只不过所采用的模式识别对象集合及形成的训练样本不同。设纵向训练样本数为 M_2 ,则基于 BP 神经网络的纵向风速预测步骤如下:

1)从同年历史数据中选择预测日 t 前的 n_2 个历史日的的数据,按模式结构形成模式向量,组成一个含有 n_2 个样本的集合,作为模式识别的对象样本集($n_2 \geq 3M_2$)。

2)对所有样本进行归一化处理。

3)根据式(3)逐一计算 n_2 个模式向量与预测日 t 的模式向量的相似度。

4)选出与预测日 t 的模式向量相似度最大的前 M_2 个样本组成预采用样本集 A_2 。

5)根据图 1 中神经网络输入向量的结构及集合 A_2 中样本对应的历史日期,构造训练样本集 B_2 。用集合 B_2 中的样本训练 BP 神经网络模型。

6)将与预测日 t 相似度最高的历史样本作为输入,求取预测日 t 各个时间点的风速预测值,得到预测日 t 的纵向风速预测值。

2.3 基于 BP 神经网络的组合预测

将横向风速预测值、纵向风速预测值作为 BP 神经网络的输入,得到最终的风速预测值。神经网络模型可以通过一系列由横向风速预测值、纵向风速预测值及历史真实值组成的样本集来训练。组合预测的 BP 神经网络结构如图 2 所示。




图 2 组合预测的 BP 神经网络结构
Fig. 2 Structure of the BP neural network for the combination forecasting

基于 BP 神经网络的权重组合预测步骤如下:

1)从预测日 t 的前 C_1 个历史日中选出与其模式相近的 C_2 个历史日。

2)分别将 C_2 个历史日作为预测日,根据 2.1 节及 2.2 节的预测步骤得到 C_2 个横向风速预测值和 C_2 个纵向风速预测值,将这些预测值及历史真实值作为一组训练样本,训练图 2 所示的 BP 神经网络模型。

3)针对预测日 t ,根据 2.1 节和 2.2 节的预测步骤得到预测日 t 的横向风速预测值及纵向风速预测值。

4)将预测日 t 的横向风速预测值及纵向风速预测值输入图 2 所示的 BP 神经网络模型,得到最终预测日 t 的风速预测值。

3 算例分析

为验证本文方法的有效性,以国内某风电场为例,根据 2004 年—2006 年的风速及气象信息作为历史数据,则 $Z=2$,取 $M=10$, $n_1=20$, $n_2=30$, $C_1=30$, $C_2=5$ 。从 2006 年 4 个季节中随机选出 4 个月

(2月、5月、8月和11月),对该风电场进行一共120日的风速预测。分别从4个月中各随机选取一日(分别为2月16日、5月24日、8月9日和11月20日),对这4个预测日的风速进行预测,结果如图3所示。从风速预测结果可以看出,本文预测方法具有良好的预测结果,预测风速曲线与实际风速曲线的形状大致相同,误差平稳。




图3 风速预测结果
Fig. 3 Forecasting results of the wind speed

分别统计4个月的横向、纵向和组合预测相对误差的平均值,并计算各个平均相对误差总的平均值和均方差,结果如表2所示。

表2 预测相对误差统计结果
Table 2 Statistical results of the relative prediction error

预测模型	平均相对误差				%	
	2月	5月	8月	11月	总平均值	均方差
横向预测	31.54	17.84	28.65	18.51	24.135 0	16.303
纵向预测	44.31	27.02	25.62	20.44	29.347 5	13.725
组合预测	32.22	16.15	22.46	16.03	21.715 0	12.765

比较表2中各个预测的平均相对误差可以看出,总体上横向风速预测的平均误差要比纵向风速预测的平均误差小,说明风速的季节周期特性强于时间连续特性。进一步,组合预测的平均相对误差要比横向风速预测的平均相对误差小,充分说明基于风速的横向季节周期性及纵向时间连续性的组合

预测方法是最有效的。此外,组合预测平均相对误差的均方差是12.765%,也说明预测误差的整体波动范围较小。

将4个月一共120个预测日、每日144个时间点的风速预测相对误差按区间统计,其误差概率分布如附录A图A1所示。误差概率分布图表明,本文组合预测方法的风速预测误差大部分在35%以下,其中,误差绝对值在25%以下的占60%以上,充分说明了基于风速的横向季节周期性及纵向时间连续性的组合预测方法的可行性和有效性,具有一定的实用价值。

4 结语

尽管风能具有较强的随机性,给风电功率及风速预测带来难度,但是只要合理地利用风能的季节周期性、时间连续性等特点,仍能使风电功率及风速预测达到较高的精度。本文提出了一种基于风速的季节周期性及时间连续性特点的风速短期组合预测模型,预测结果表明这种预测方法是可行和有效的。未来风电功率及风速预测的研究,主要可从利用新的预测模型、分析风速与气象因素的统计关系、风能的特性等方面考虑。

附录见本刊网络版(<http://aeprs.sgepri.sgcc.com.cn/aeprs/ch/index.aspx>)。

参考文献

[1] 雷亚洲. 与风电并网相关的研究课题. 电力系统自动化, 2003, 27(8): 84-89.
LEI Yazhou. Studies on wind farm integration into power system. Automation of Electric Power Systems, 2003, 27(8): 84-89.

[2] 雷亚洲, 王伟胜, 印永华, 等. 风电对电力系统的价值分析. 电网技术, 2002, 26(5): 10-14.
LEI Yazhou, WANG Weisheng, YIN Yonghua, et al. Analysis of wind power value to power system operation. Power System Technology, 2002, 26(5): 10-14.

[3] MANGUEIRA H H D, SAAVEDRA O R, PESSANHA J E O. Impact of wind generation on the dispatch of the system: a fuzzy approach. Electrical Power and Energy Systems, 2008, 30(1): 67-72.

[4] MA Lei, LUAN Shiyan, JIANG Chuanwen. A review on the forecasting of wind speed and generated power. Renewable and Sustainable Energy Reviews, 2009, 13(4): 915-920.

[5] 杨秀媛, 肖洋, 陈树勇. 风电场风速和发电功率预测研究. 中国电机工程学报, 2005, 25(11): 1-5.
YANG Xiuyuan, XIAO Yang, CHEN Shuyong. Wind speed and generated power forecasting in wind farm. Proceedings of the CSEE, 2005, 25(11): 1-5.

[6] KANIS A P, RIAHY G H. A new ANN-based methodology for very short-term wind speed prediction using Markov chain

- approach// Proceedings of IEEE Electrical Power & Energy Conference, October 6-7, 2008, Vancouver, Canada: 1-6.
- [7] 张国强,张伯明. 基于组合预测的风电场风速及风电机功率预测. 电力系统自动化, 2009, 33(18): 92-95.
ZHANG Guoqiang, ZHANG Boming. Wind speed and wind turbine output forecast based on combination method. Automation of Electric Power Systems, 2009, 33(18): 92-95.
- [8] 李智,韩学山,韩力,等. 地区电网风电场功率超短期预测方法. 电力系统自动化, 2010, 34(7): 90-94.
LI Zhi, HAN Xueshan, HAN Li, et al. An ultra-short-term wind power forecasting method in regional grids. Automation of Electric Power Systems, 2010, 34(7): 90-94.
- [9] LI Ran, WANG Yue. Short-term wind speed forecasting for wind farm based on empirical mode decomposition// Proceedings of 2008 International Conference on Electrical Machines and Systems, October 17-20, 2008, Wuhan, China: 2521-2525.
- [10] PALIT A K, POPOVIC D. Nonlinear combination of forecasts using artificial neural network, fuzzy logic and neuro-fuzzy approaches// Proceedings of the 9th IEEE International Conference on Fuzzy Systems, May 7-10, 2000, San Antonio, TX, USA: 566-571.
- [11] 金义雄,段建民,徐进,等. 考虑气象因素的相似聚类短期负荷组合预测方法. 电网技术, 2007, 31(19): 60-64.
JIN Yixiong, DUAN Jianmin, XU Jin, et al. A combination short-term load forecasting method by use of similarity clustering and considering weather factors. Power System Technology, 2007, 31(19): 60-64.
- [12] 吴兴华,周晖,黄梅. 基于模式识别的风电场风速和发电功率预测. 继电器, 2008, 36(1): 27-32.
WU Xinghua, ZHOU Hui, HUANG Mei. Wind speed and generated power forecasting based on pattern recognition in wind farm. Relay, 2008, 36(1): 27-32.
- [13] 赵凯,彭建春,石峰. 基于模式识别技术的短期负荷预测. 湖南电力, 2000, 20(6): 1-3.
ZHAO Kai, PENG Jianchun, SHI Feng. Short-term load forecasting based on pattern recognition. Hunan Electric Power, 2000, 20(6): 1-3.

蒋小亮(1986—),男,通信作者,硕士研究生,主要研究方向:风力发电、电力系统可靠性。E-mail: xiaoliangjiang@sju.edu.cn

蒋传文(1966—),男,博士生导师,主要研究方向:电力市场、配电网自动化、电力系统优化运行、水调自动化、风力发电。E-mail: jiangcw@sju.edu.cn

彭明鸿(1971—),男,现在博士后流动站从事研究工作,主要研究方向:配电网自动化。E-mail: pmh888@sohu.com

A Short-term Combination Wind Speed Forecasting Method Considering Seasonal Periodicity and Time-continuity

JIANG Xiaoliang¹, JIANG Chuanwen¹, PENG Minghong¹, LIN Haitao¹, LI Zilin²

(1. Shanghai Jiaotong University, Shanghai 200240, China; 2. Shanghai Wind Power Co. Ltd., Shanghai 200090, China)

Abstract: As long as the wind speed can be forecasted, the output of a wind power unit can be calculated according to the unit's power curve. A short-term combination forecasting model of wind speed is developed based on the seasonal periodicity and time-continuity of wind energy. With the pattern recognition technique, two kinds of samples to seasonal periodicity and time-continuity are selected separately. The two kinds of samples are used respectively to train two back propagation (BP) neural network models to obtain the lateral and vertical wind speed forecasting values. By importing the two values to a BP neural network again, the wind speed value is finally predicted. Forecasting results of a domestic wind farm indicate that the proposed combination forecasting method is valid and effective in short-term wind speed forecasting.

This work is supported by the National High Technology Research and Development Program (863 Program) of China (No. 2007AA05Z458).

Key words: wind forecasting; time-continuity; seasonal periodicity; pattern recognition; back propagation (BP) neural network

附录 A 风速预测误差概率分布




图 A1 风速预测误差概率分布比较图
Fig.1 The probability distribution of wind speed forecasting error

图 A1 中:横坐标 0.05 表示误差在区间[0,0.1]之间出现的概率, 0.15 表示误差在区间 [0.1,0.2]之间出现的概率, 其他的依此类推。