

DOI: 10.7500/AEPS20130830010

# 基于 OS-ELM 和 Bootstrap 方法的超短期风电功率预测

王 焱<sup>1</sup>, 汪 震<sup>1</sup>, 黄民翔<sup>1</sup>, 蔡祯祺<sup>2</sup>, 杨濛濛<sup>1</sup>

(1. 浙江大学电气工程学院, 浙江省杭州市 310027; 2. 国网上海市电力公司, 上海市 200122)

**摘要:**提出了一种基于在线序贯极限学习机(OS-ELM)的超短期风电功率预测方法。利用 OS-ELM 学习速度快、泛化能力强的优点,将批处理和逐次迭代相结合,不断更新训练数据和网络结构,实现了对数值天气预报风速的快速实时修正和风电机组输出功率的快速预测。随后,采用计算机自助(Bootstrap)法构造伪样本,给出了预测功率的置信区间评估。实例和研究结果表明,该预测方法与反向传播(BP)网络、支持向量机(SVM)方法相比,在计算时间上更能满足在线应用需求,而且预测精度相当,有较好的应用前景。

**关键词:**风电预测; 风速修正; 误差区间估计; 极限学习机; Bootstrap 方法

## 0 引言

随着风电装机容量的迅猛增长,由于风电的高度波动性和随机性,大规模风电并网已成为制约中国风电发展的最大瓶颈。对风电场输出功率进行“小时”“分钟”级超短期预测可以为实时调整电网调度计划、安排备用容量提供依据,有利于提高系统的安全稳定和经济运行<sup>[1]</sup>。新出台的《风电功率预测系统功能规范》<sup>[2]</sup>对预测时间提出了明确要求:超短期预测应能预测未来 0~4 h 的风电输出功率,时间分辨率不小于 15 min,并且每 15 min 自动执行一次。因此,大规模风电的逐步接入必然对风电预测算法的鲁棒性和速度提出了更高要求。

目前,风电功率超短期/短期预测的方法大致分为物理分析法、统计分析法以及两者结合方法<sup>[3]</sup>。物理分析法是一种基于风变化物理过程、综合考虑风电场地理信息及风电机组特性等信息进行分析、建模和预测的方法,该方法无需历史数据,但对模型精度要求较高<sup>[4]</sup>。统计分析法是一种基于历史数据信息关联分析的趋势分析方法,该方法对历史数据要求较高。其中常用的历史数据包括数值天气预报(NWP)数据、实测风电输出等,常见的关联分析方法包括时间序列法、卡尔曼滤波法、神经网络法、小波分析法、支持向量机(SVM)以及结合几种方法的组合预测方法等<sup>[5-9]</sup>。

传统的人工神经网络(ANN)学习算法,如反向传播(BP)网络和 SVM 方法等,虽然具有较强的

非线性辨识能力,但也存在泛化能力不强、学习速度慢、易陷入局部最优等缺陷。文献[10]提出一种新型单隐层前馈神经网络算法,称为极限学习机(extreme learning machine, ELM),其具有学习速度快、泛化性能优良等特点,已被应用于研究许多工程问题求解中。在电力工程领域,ELM 及其扩展算法在实时电价预测<sup>[11]</sup>、电力系统暂态稳定在线评估<sup>[12]</sup>等方面都取得了不错的效果。在 ELM 基础上,文献[13]提出了一种在线序贯 ELM(online sequential-ELM, OS-ELM)算法,其特点是历史数据分批进行训练并且支持可变化的样本数,每一轮训练过程中训练算法仅输入当前批次数据并更新网络权值,无需重复扫描历史数据,泛化能力更强。考虑到实际风电预测系统中不可避免会出现数据错误或缺失的情况,因此 OS-ELM 算法鲁棒性能更能满足实际应用的需要。

另一方面,随着含有风电场的电力系统运行风险评估与风险决策问题的研究日益增多,对预测误差的评估和分析相比于单点预测能提供更为充分的决策信息<sup>[14-15]</sup>。对风电预测误差进行评估可以帮助调度部门更好地掌握风电的不确定性,从而在不同风险水平下制定灵活的调度策略<sup>[16-17]</sup>。

本文提出一种基于 OS-ELM 算法的双神经网络风电预测方法,第 1 个神经网络用于对 NWP 风速进行修正,第 2 个神经网络用于风电功率预测,在训练过程中将批处理和逐次迭代相结合。为了评估预测误差,本文结合 OS-ELM 和计算机自助(Bootstrap)法构造伪样本计算置信区间。通过对江苏启东某大型风电场的输出功率的超短期预测仿真验证了预测方法的有效性。

收稿日期: 2013-08-30; 修回日期: 2013-12-12。

国家高技术研究发展计划(863 计划)资助项目(2011AA050204); 国家自然科学基金资助项目(51277160)。

## 1 OS-ELM 算法

ELM 属于单隐层前馈神经网络(SLFN),对于  $N$  个不同的训练样本  $\{\mathbf{x}_j, y_j\}$ ,有矩阵形式:

$$\mathbf{H}\boldsymbol{\beta} = \mathbf{R} \quad (1)$$

式中: $\mathbf{H}$  为神经网络的隐含层输出矩阵; $\boldsymbol{\beta}$  为输出权值矩阵; $\mathbf{R}$  为网络的输出矩阵(详见附录 A)。

ELM 是针对 SLFN 的新算法,该算法随机产生输入层和隐含层的连接权值及隐含层神经元的阈值,且在训练过程中无须调整,只需要设置隐含层神经元的个数,便可以获得唯一的最优解。文献[10]已经证明全局最优输出权值可写为:

$$\hat{\boldsymbol{\beta}} = \mathbf{H}^* \mathbf{R} \quad (2)$$

式中: $\mathbf{H}^* = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T$  为隐含层输出矩阵  $\mathbf{H}$  的 Moore-Penrose 广义逆。

为了更好地适应在线应用需要,增加算法对数据的容错能力,进一步引入 OS-ELM。OS-ELM 主要包括如下 2 个步骤。

1)初始化阶段:输入训练样本,设定网络参数,求得初始隐含层输出矩阵  $\mathbf{H}_0$  和输出权值向量  $\boldsymbol{\beta}_0$ 。

2)在线序贯学习阶段:在初始网络基础上,根据最新批次的样本数据序贯更新参数  $\mathbf{H}$  和  $\boldsymbol{\beta}$ ,直到所有数据学习完毕。

OS-ELM 的详细模型、相关概念和算法步骤在附录 A 中详细介绍。

## 2 基于 OS-ELM 的预测模型

### 2.1 数据预处理

本文所针对的风电场可提供的历史数据分为 2 类:①由数据采集与监控(SCADA)系统获取的实测输出功率和测风塔风速;②由当地气象部门 NWP 系统提供的数据,包括风速、风向、温度、气压和湿度。所有数据的时间分辨率均为 10 min,即一天拥有 144 个数据样本,预测的时间分辨率与此一致。考虑式(3)向量作为 OS-ELM 网络输入:

$$\mathbf{x} = [v \quad v_{\sin} \quad v_{\cos} \quad \rho]^T \quad (3)$$

$$\rho = 1.276 \frac{P - 0.378 \frac{h}{100} P_b}{1 + 0.00366 T_c} \quad (4)$$

式中: $v, v_{\sin}/v_{\cos}$  分别表示风速和风向的正/余弦值; $\rho$  为空气密度; $T_c$  为摄氏温度; $P$  为大气压; $h$  为空气相对湿度; $P_b$  为该温度下的饱和水蒸气压。所有输入数据都需归一化到  $[0, 1]$  区间内。

### 2.2 NWP 风速修正

从风电场的历史数据来看, NWP 风速与 SCADA 系统实测风速整体趋势保持一致,但每一

个时刻点都存在不同程度的误差且有一定规律,类似正态分布(如图 1 所示)。




图 1 NWP 风速单点绝对误差

Fig.1 Single-point absolute error of NWP wind speed

根据常见风电机组功率输出特性曲线,在中风速段(切入风速至额定风速),较小的风速变化会引起明显的输出功率变化,因此本文尝试对 NWP 风速预报数据进行一定程度的修正。此处采取如图 2 网络 A 所示的 OS-ELM 结构来模拟修正风速和风速的非线性关系,以 NWP 风速  $v_{nwp}$  和前一时刻的实测 SCADA 风速  $v_{t-1}$  作为网络的输入,相应时间段 SCADA 实测风速数据为输出来训练网络。




图 2 考虑风速修正的双 OS-ELM 结构

Fig.2 Double OS-ELM structure considering wind-speed correction

### 2.3 风功率预测模型

预测模型网络结构如图 2 网络 B 所示,该时刻的修正风速、风向正弦、风向余弦、空气密度为网络输入,SCADA 实测输出功率为输出。NWP 风速修正和风电功率预测 2 个 OS-ELM 结构可以组成一个双 OS-ELM 网络结构,如图 2 所示。

针对本文的实际情况,OS-ELM 数据结构可由图 3 形象地表示。




图 3 OS-ELM 数据结构说明

Fig.3 Explanation of OS-ELM data structure

图 3 中,  $[X_1, X_2, \dots, X_t]$  表示 NWP 等网络输

入向量,  $[\tilde{Y}_1, \tilde{Y}_2, \dots, \tilde{Y}_T]$  表示输出功率预测向量,  $[Y_1, Y_2, \dots, Y_T]$  表示从 SCADA 系统获取的实测输出功率向量。每一批次样本数据的数量可以不同, 可以反映不同的时间尺度。

图 4 给出了风电输出功率预测时序图, 图中预测时间为第 2 日 00:00—03:50 共 24 个点, 预测启动时刻为前一日 23:50。在启动时刻从系统获取第  $T-1$  批次数据的实测 SCADA 风速、功率以及第  $T$  批次的 NWP 预测数据。第 1 个网络根据第  $T-1$  批次的实测 SCADA 风速和第  $T$  批次的 NWP 风速可以得到第  $T$  批次的修正风速, 并成为第 2 个网络的输入。第 2 个网络通过第  $T-1$  批次的输入和实测功率作为最新的训练样本以更新网络, 以第  $T$  批次的修正风速和 NWP 数据为输入计算第  $T$  批次的输出功率。




图 4 预测时序图

Fig.4 Sequence diagram of prediction

在实际的超短期风电功率预测应用中, 尽管双 OS-ELM 的结构相对复杂, 但考虑到 OS-ELM 快速学习的特性, 这种结构不会消耗大量计算资源, 能很好地适应大规模数据分析的需要。另外, 风速修正网络可独立于功率预测网络, 风速修正可通过离线修正和在线应用的方式实施。

风电功率点预测的效果通常采用均方根百分比误差来衡量:

$$e_{\text{RMSE}} = \frac{1}{P_{\text{rated}}} \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \tilde{y}_i)^2} \times 100\% \quad (5)$$

式中:  $P_{\text{rated}}$  为风电场的额定容量;  $y_i$  为第  $i$  个实测数据;  $\tilde{y}_i$  为第  $i$  个预测数据;  $n$  为预测数据个数。

## 2.4 基于 Bootstrap 法的多 ELM 误差评估网络

Bootstrap 法是由美国 Stanford 大学统计学家 Efron 提出的利用计算机产生自助样本进行样本分布特性统计推断的方法, 可应用于对未知分布(非参数)统计评估。Bootstrap 法对样本差异的良好适应性使其近年来应用于电价预测<sup>[11]</sup>、配电设备可靠性评估<sup>[18]</sup>等领域。以下从数据结构、误差评估和评估效果验证 3 个方面说明 Bootstrap 法。

### 2.4.1 数据结构

训练数据: 基于 Bootstrap 法的多 ELM 误差评估网络如图 5(a) 所示。在  $N_B$  个误差评估训练样本  $\{x_j, y_j\} (j=1, 2, \dots, N_B)$  基础上通过 Bootstrap 法产生  $M$  组 Bootstrap 伪训练样本, 并进一步形成

$M$  个多 ELM 误差评估网络(产生方法见下文), 其中每个 ELM 结构类似图 5(b), 每个网络训练输入输出为一组  $\{x_j, y_j^*\} (j=1, 2, \dots, N_B)$ , 最后生成的 ELM 网络隐函数记为  $r_k^*(x), k=1, 2, \dots, M$ 。




图 5 基于 Bootstrap 法的多 ELM 误差评估网络

Fig.5 Multiple Bootstrap-ELMs for error evaluation

预测数据: 应用上述网络进行预测的结构示意图如图 5 所示。给定任意测试样本输入  $x'$ , 对于每个网络分别计算得到  $M$  组预测输出  $r_k^*(x') (k=1, 2, \dots, M)$  用于 Bootstrap 置信区间计算。

### 2.4.2 误差评估

Bootstrap 法用于误差评估时有 3 个核心概念: ①残差样本; ②Bootstrap 训练样本; ③Bootstrap 置信区间。整个误差评估流程主要分为 3 步: ①生成残差样本; ②生成 Bootstrap 训练样本; ③计算 Bootstrap 置信区间  $[Z_{M_1}, Z_{M_2}]$ 。

百分位数 Bootstrap(percentile Bootstrap, PB)法是计算 Bootstrap 置信区间的常用方法, 它利用经验分位数估计 Bootstrap 置信区间, 但存在部分 Bootstrap 伪估计偏离真实值的情况。本文中, 引入修正偏差后的百分位数 Bootstrap(biased-corrected percentile Bootstrap, BCPB)法来克服上述问题<sup>[19]</sup>。相关的误差评估算法具体步骤和说明见附录 B。

为了评估 BCPB 方法的效果, 在附录 C 中分别给出 PB, BCPB 及常用的正态分布法 3 种方法的预测误差评估效果, 计算在不同置信水平下同一个批次(24 个预测点)的平均置信区间宽度并加以比较。从附录 D 表 D1 可以看到, BCPB 法能得到较小的置信区间宽度, 而正态分布法的效果略逊于 Bootstrap 方法。

### 2.4.3 评估效果验证

本文方法可以给出每个预测时刻的预测误差区间, 进一步为了总体检验预测误差区间的效果, 对于  $N_C$  个测试输入  $x_j' (j=1, 2, \dots, N_C)$ , 引入绝对覆盖误差(absolute coverage error, ACE)和预测覆盖



宽度 (prediction coverage width, PIW) 2 个指标<sup>[11,20]</sup>:

$$\hat{\alpha} = \frac{f(r(\mathbf{x}_j'))}{N_C} \quad r(\mathbf{x}_j') \in [Z_{M_1,j}, Z_{M_2,j}] \quad (6)$$

$$e_{ACE} = |\hat{\alpha} - \alpha| \quad (7)$$

$$l_{PIW} = \frac{1}{N_C} \sum_{j=1}^{N_C} |Z_{M_2,j} - Z_{M_1,j}| \quad (8)$$

式中:  $f(\cdot)$  表示事件发生的频率函数;  $\hat{\alpha}$  为在  $N_C$  次测试中预测值位于 Bootstrap 置信区间内统计概率;  $e_{ACE}$  用于评估 Bootstrap 置信区间理论值和计算值间偏差大小,越小说明结果估计越接近实际误差分布;  $l_{PIW}$  给出了一组测试样本的平均置信区间宽度,宽度越窄表示估计结果的可靠性越高。

3 算例测试和分析

算例风电场是位于江苏省启东市的某近海风电场,共有 67 台额定容量为 1 500 kW 的双馈变速风电机组。该风电场拥有一年以上的风电场输出功率及相关气象信息连续监测数据,以 2009—2010 年(10 min 分辨率)的历史数据为研究对象。经过多次模拟测试,研究中 OS-ELM 初始训练样本选取预测点前一周历史数据,OS-ELM 的数据更新周期为 4 h(数据滚动周期的讨论见附录 D),隐层神经元节点数设为 90(测试结果见附录 E);多 ELM 误差评估网络训练样本选取预测点前一周历史数据。

3.1 风速修正效果分析

为了验证风速修正的效果,同时考虑风特性的季节性特征,从 2010 年 4 个季节中随机挑选各两组数据,每组数据包含连续 7 d 共 1 008 个样本,采用未修正风速标准 ELM、修正 NWP 风速后的标准 ELM 和 OS-ELM(激活函数类型均为“sig”)进行对比,均方根误差(RMSE)对比结果如表 1 所示。

表 1 各方法预测功率数据均方根误差  
Table 1 Corrected NWP wind speed RMSE

季节	组号	RMSE/%		
		未修正 ELM 直接预测	修正 NWP ELM 预测	修正 NWP OS-ELM 预测
春	1	26.79	15.03	12.47
	2	23.83	16.48	15.38
夏	3	11.27	7.80	7.71
	4	7.61	5.35	5.08
秋	5	21.44	13.25	11.41
	6	12.75	11.68	11.69
冬	7	13.05	12.23	12.18
	8	6.01	6.15	6.08

从表 1 可见:未修正 NWP 风速直接采用 ELM 预测时,第 1,2,5 组预测误差超过 20%,分析发现

上述 3 组数据对应的风速预测误差较大;而修正后所有误差均控制在 20% 以下,可见从总体上来看,修正 NWP 风速对预测精度提高起了正面作用。

图 6 给出了第 1 组数据前 3 d 的风速和功率预测情况。可以清楚地看到,NWP 风速与实际风速偏差较大,通过修正过程偏差改善明显。对于第 4,6,8 组数据,风速预测值和实际值偏差不大,风速修正效果不明显。

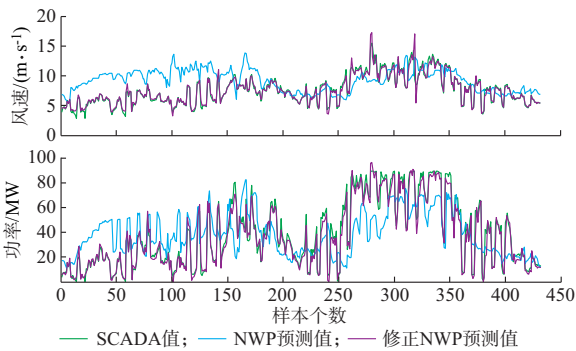


图 6 第 1 组风速和功率预测情况  
Fig.6 Wind speed and power output prediction of the first group

3.2 算法性能比较

进一步为测试算法性能,在配置 I5-3.4 GHz CPU 和 4 GB RAM 的 PC 平台上对比研究了 OS-ELM(3 种不同核函数)和常用的 BP 神经网络、SVM<sup>[21]</sup> 的预测效果,所有算法均经过风速修正。以下选取 2010 年 4 月(春)、7 月(夏)、10 月(秋)、1 月(冬)共 4 个月数据进行算法测试并比较 RMSE 和计算耗时两项指标,结果如表 2 所示。

表 2 算法性能对比  
Table 2 Computing comparison of algorithms

季节	算法	计算时间/s	RMSE/%
春	OS-ELM(sig)	1.318 1	16.58
	OS-ELM(rbf)	2.123 4	17.34
	OS-ELM(sin)	1.205 3	18.03
	BP	17.819 0	18.51
	SVM	53.692 0	18.18
夏	OS-ELM(sig)	1.426 5	10.47
	OS-ELM(rbf)	2.156 1	11.86
	OS-ELM(sin)	1.319 7	12.28
	BP	17.914 0	12.53
秋	SVM	55.713 0	10.76
	OS-ELM(sig)	1.317 9	14.57
	OS-ELM(rbf)	2.139 8	15.84
	OS-ELM(sin)	1.108 7	15.16
冬	BP	17.712 0	16.51
	SVM	56.261 0	16.18
	OS-ELM(sig)	1.321 8	13.17
	OS-ELM(rbf)	2.189 2	13.95
	OS-ELM(sin)	1.217 4	12.83
	BP	17.638 0	13.68
	SVM	54.375 0	14.03

对比各种算法,在精度相当的情况下 OS-ELM 类算法的耗时相比 BP 和 SVM 具有明显的优势,在 OS-ELM 三种核函数类型中,“sin”耗时最少,而精度则是“sig”相对较高。4 组数据中春季的误差较高,通过研究发现,对应的实际风速波动较大,相应的 NWP 误差较大。

3.3 算法鲁棒性研究

为了测试算法对数据缺失的容错能力,选取 2010 年 7 月最后 7 d 的数据作为初始训练集,8 月和 9 月共 61 d 数据作为预测测试集(每 4 h 一批,共计 366 批)。

为模拟 SCADA 实测数据的缺失,在每批滚动数据中随机选取某些点并假设这些点无法获取,具体方法如下:在每一批 24 个数据点中,随机选定  $z$  个点,其中  $15 \leq z \leq 24$ 。

图 7 给出了 2 个月 61 d 的预测结果,可以看到预测功率曲线与实际功率曲线具有基本一致的变化趋势。图 8 给出了每一批次数据的预测误差和训练样本数据量。从图 8 可以看到,当某一批次数据误差较大时(如第 27 批次 RMSE 达到 28.50%),经过随后几次网络更新 RMSE 逐步下降。这说明本文方法对数据缺失有一定的适应能力,但数据缺失对风电预测功率的具体影响仍有待进一步验证。

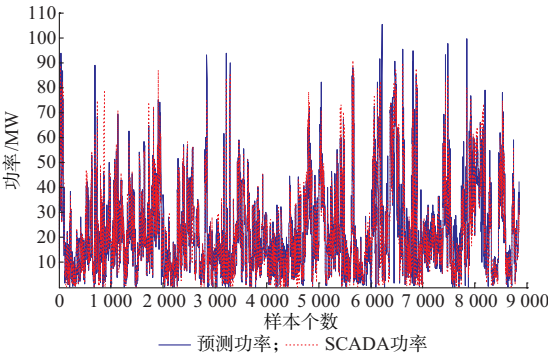


图 7 2 个月预测结果  
Fig.7 Prediction results of two months




图 8 每批次数据误差和数量  
Fig.8 Chunk error and number of each batch

3.4 误差评估结果

选取 2010 年 5 月(春)、8 月(夏)、11 月(秋)、2 月(冬)共 4 个月的数据进行测试。对应每一时刻预测值,有相应的预测误差带(区间),为显示方便,在图 9 中给出了 2 个批次(48 个预测时刻)在不同置信水平下的 BCPB 置信区间带。可以看到,实际风电输出功率可以较好地包络到置信区间带中。




图 9 BCPB 置信区间带  
Fig.9 BCPB confidence intervals under different levels

表 3 反映了在不同置信水平下 Bootstrap 误差评估的效果,可以看出,  $\alpha$  和  $\hat{\alpha}$  数值十分接近( $e_{ACE}$  趋近于 0),表明 Bootstrap 置信区间能模拟实际误差分布情况,能为含有风电场的电力系统风险决策提供数据支持。

表 3 误差区间评估  
Table 3 Error interval evaluation results

季节	$\alpha$ /%	$\hat{\alpha}$ /%	$e_{ACE}$ /%	季节	$\alpha$ /%	$\hat{\alpha}$ /%	$e_{ACE}$ /%
春	80.00	83.65	3.65	秋	80.00	82.47	2.47
	90.00	91.83	1.83		90.00	88.57	1.43
	95.00	92.89	2.11		95.00	93.29	1.71
夏	80.00	82.31	2.31	冬	80.00	81.03	1.03
	90.00	90.95	0.95		90.00	88.62	1.38
	95.00	93.34	1.66		95.00	94.03	0.97

4 结语

本文设计了一种基于 OS-ELM 算法的超短期风电功率预测方法。利用 OS-ELM 算法学习速度快、泛化能力强的优点,构建了一种双 OS-ELM 网络结构。算例验证了本文模型在不降低预测精度的前提下,相比其他 ANN 学习算法有明显的时间优势,且对数据缺失有较好的适应能力。

同时本文采用 Bootstrap 法对误差区间进行评估,经过实例验证,Bootstrap 置信区间可以有效模拟实际误差分布的情况,为考虑风电场出力不确定性的系统风险决策提供数据支持。

附录见本刊网络版 (<http://aeps.sgepri.sgcc.com.cn/aeps/ch/index.aspx>)。

## 参 考 文 献

- [1] 雷亚洲.与风电并网相关的研究课题[J].电力系统自动化,2003,27(8):84-89.  
LEI Yazhou. Studies on wind farm integration into power system[J]. Automation of Electric Power Systems, 2003, 27(8): 84-89.
- [2] 国家电网公司.Q/GDW 588—2011 风电功率预测功能规范[S].北京:中国电力出版社,2011.
- [3] MA Lei, LUAN Shiyun. A review on the forecasting of wind speed and generated power[J]. Renewable and Sustainable Energy Reviews, 2009, 13(4): 915-920.
- [4] 冯双磊,王伟胜,刘纯,等.风电场功率预测物理方法研究[J].中国电机工程学报,2010,30(2):1-6.  
FENG Shuanglei, WANG Weisheng, LIU Chun, et al. Study on the physical approach to wind power prediction [J]. Proceedings of the CSEE, 2010, 30(2): 1-6.
- [5] 茆美琴,周松林,苏建徽.基于脊波神经网络的短期风电功率预测[J].电力系统自动化,2011,35(7):30-33.  
MAO Meiqin, ZHOU Songlin, SU Jianhui. Short-term wind power forecast based on ridgelet neural network[J]. Automation of Electric Power Systems, 2011, 35(7): 30-33.
- [6] 丁志勇,杨苹,杨曦,等.基于连续时间段聚类的支持向量机风电功率预测方法[J].电力系统自动化,2012,36(14):131-135.  
DING Zhiyong, YANG Ping, YANG Xi, et al. Wind power prediction method based on sequential time clustering support vector machine [J]. Automation of Electric Power Systems, 2012, 36(14): 131-135.
- [7] 师洪涛,杨静玲,丁茂生,等.基于小波-BP 神经网络的短期风电功率预测方法[J].电力系统自动化,2011,35(16):44-48.  
SHI Hongtao, YANG Jingling, DING Maosheng, et al. A short-term wind power prediction method based on wavelet decomposition and BP neural network [J]. Automation of Electric Power Systems, 2011, 35(16): 44-48.
- [8] 张国强,张伯明.基于组合预测的风电场风速及风电机电功率预测[J].电力系统自动化,2009,33(18):92-95.  
ZHANG Guoqiang, ZHANG Boming. Wind speed and wind turbine output forecast based on combination method [J]. Automation of Electric Power Systems, 2009, 33(18): 92-95.
- [9] 严欢,卢继平,覃俏云,等.基于多属性决策和支持向量机的风电功率非线性组合预测[J].电力系统自动化,2013,37(10):29-34.  
YAN Huan, LU Jiping, QIN Qiaoyun, et al. A nonlinear combined model for wind power forecasting based on multi-attribute decision-making and support vector machine [J]. Automation of Electric Power Systems, 2013, 37(10): 29-34.
- [10] HUANG G B, ZHU Q Y, SIEW C K. Extreme learning machine: theory and applications[J]. Neurocomputing, 2006, 70(1/2/3): 489-501.
- [11] CHEN X, DONG Z Y, MENG K, et al. Electricity price forecasting with extreme learning machine and Bootstrapping [J]. IEEE Trans on Power Systems, 2012, 27(4): 2055-2062.
- [12] XU Y, DONG Z Y, MENG K. Real-time transient stability assessment model using extreme learning machine [J]. IET Generation, Transmission & Distribution, 2011, 5(3): 314-322.
- [13] LIANG N Y, HUANG G B, SARATCHANDRAN P, et al. A fast and accurate online sequential learning algorithm for feedforward networks[J]. IEEE Trans on Neural Networks, 2006, 17(6): 1411-1423.
- [14] 李智,韩学山,杨明,等.基于分位点回归的风电功率波动区间分析[J].电力系统自动化,2011,35(3):83-87.  
LI Zhi, HAN Xueshan, YANG Ming, et al. Wind power fluctuation interval analysis based on quantile regression[J]. Automation of Electric Power Systems, 2011, 35(3): 83-87.
- [15] 杨明,朱思萌,韩学山,等.风电场输出功率的多时段联合概率密度预测[J].电力系统自动化,2013,37(10):23-28.  
YANG Ming, ZHU Simeng, HAN Xueshan, et al. Joint probability density forecast for wind farm output in multi-time-interval[J]. Automation of Electric Power Systems, 2013, 37(10): 23-28.
- [16] 刘芳,潘毅,刘辉,等.风电功率预测误差分段指数分布模型[J].电力系统自动化,2013,37(18):14-19.  
LIU Fang, PAN Yi, LIU Hui, et al. Piecewise exponential distribution model of wind power forecasting error [J]. Automation of Electric Power Systems, 2013, 37(18): 14-19.
- [17] 吴雄,王秀丽.新能源组合出力的置信区间估计[J].电力系统自动化,2013,37(16):7-12.  
WU Xiong, WANG Xiuli. Estimation on confidence intervals of combined output of renewable energy [J]. Automation of Electric Power Systems, 2013, 37(16): 7-12.
- [18] ANSELMO B R, MARIA S. Confidence intervals estimation for reliability data of power distribution equipments using Bootstrap[J]. IEEE Trans on Power Systems, 2013, 28(3): 3283-3291.
- [19] EFRON B, TIBSHIRANI R J. An introduction to the Bootstrap[M]. London, UK: Chapman and Hall, 1993.
- [20] ABBAS K, SAEID N, DOUG C. Prediction intervals for short-term wind farm power generation forecasts[J]. IEEE Trans on Sustainable Energy, 2013, 4(3): 602-610.
- [21] CHUNG C C, LIN C J. LIBSVM: a library for support vector machines[EB/OL]. [2013-12-01]. <http://www.csie.ntu.edu.tw/~cjlin/libsvm>.

王 焱(1987—),男,硕士研究生,主要研究方向:电力系统规划、新能源发电。

汪 震(1976—),男,通信作者,副教授,主要研究方向:电力系统稳定和控制、新能源应用。E-mail: z.wang@zju.edu.cn

黄民翔(1955—),男,教授,主要研究方向:电力系统规划、电力市场。

(编辑 孔丽蓓)

(下转第 122 页 continued on page 122)

## Ultra-short-term Wind Power Prediction Based on OS-ELM and Bootstrap Method

WANG Yan<sup>1</sup>, WANG Zhen<sup>1</sup>, HUANG Minxiang<sup>1</sup>, CAI Zhenqi<sup>2</sup>, YANG Mengmeng<sup>1</sup>

(1. College of Electrical Engineering, Zhejiang University, Hangzhou 310027, China;

2. State Grid Shanghai Municipal Electric Power Company, Shanghai 200122, China)

**Abstract:** An ultra-short-term wind power prediction method based on an online sequential extreme learning machine (OS-ELM) is proposed. Firstly, the OS-ELM is utilized to correct the predicted wind speed sequence so as to amend and improve the accuracy of predicted wind speed. Then, by combining batch processing with successive iteration, real-time prediction of wind turbine power output is accomplished with the help of the advantages of OS-ELM's fast learning speed and strong generalization ability. Finally, a Bootstrap method is adopted to estimate the predicted intervals by resampling data. Analysis results show that, compared with the back propagation (BP) network and support vector machine (SVM) method, this prediction method can better meet the demand of online application and has good application prospects, while its forecasting accuracy is comparable to BP network and SVM method.

This work is supported by National High Technology Research and Development Program of China (863 Program) (No. 2011AA050204) and National Natural Science Foundation of China (No. 51277160).

**Key words:** wind power prediction; wind speed correction; error interval estimation; extreme learning machine (ELM); Bootstrap method