

# 基于主成分—遗传神经网络的短期风电功率预测

罗毅, 刘峰, 刘向杰

(华北电力大学控制与计算机工程学院, 北京 102206)

**摘要:** 短期风电功率预测对接入大量风电的电力系统运行具有重要的意义, 建立了基于主成分分析与遗传神经网络相结合的短期风电功率预测模型。该模型先对原始输入数据进行主成分分析, 分析结果作为神经网络预测模型的输入; 为克服 BP 神经网络训练时间长、易陷入局部极小值的缺陷, 采用遗传算法优化神经网络的初始权值和阈值, 并使用 Levenberg-Marquardt 算法对网络权值和阈值进行细化训练。经某风电场实际数据验证, 与 GA 神经网络模型、PCA-LM 神经网络模型相比, 预测精度明显提高, 为短期风电功率预测提供了一种有效的方法。

**关键词:** 风电功率; 神经网络; 遗传算法; 主成分分析; 短期预测

## Short-term wind power prediction based on principal component analysis and genetic neural network

LUO Yi, LIU Feng, LIU Xiang-jie

(School of Control and Computer Engineering, North China Electric Power University, Beijing 102206, China)

**Abstract:** Short-term wind power prediction is important to the operation of power system with comparatively large amount of wind power, a short-circuit wind power predicting model based on principal component analysis (PCA) method and genetic neural network is proposed. PCA is applied to process original input data, the principal components are used as input data for neural network. In order to solve the problems of slow convergence speed and being easy to fall into local minimum of BP neural network, genetic algorithm (GA) is used to make a thorough searching for the initial weights and thresholds, and the Levenberg-Marquardt (L-M) method is used to finely train the network. Based on the actual data of a wind farm, the forecasting results by the proposed method is more precise than those by GA neural network model and PCA-LM neural network model, providing an effective way to forecast short-term wind power.

This work is supported by National Natural Science Foundation of China (No. 60974051) and Beijing Natural Science Foundation (No. 4122071).

**Key words:** wind power; neural network; genetic algorithm; principal component analysis; short-term prediction

中图分类号: TM614 文献标识码: A 文章编号: 1674-3415(2012)23-0047-07

## 0 引言

随着全球石化资源储量的日渐匮乏以及低碳、环保概念的逐步深化, 风能等可再生能源的开发与利用日益受到国际社会的重视<sup>[1]</sup>。风力发电是风能的主要利用方式之一, 也是可再生能源发电技术中发展最快和最为成熟的一种。但风电是一种间歇性、波动性电源, 大规模风电的接入给电力系统的安全稳定运行带来了新挑战。对风电场输出功率进行短期预测成为解决这一问题的有效途径之一。

目前, 短期风电功率预测方法从预测模型的对象角度, 可分为两类: 第一类为间接法, 即先预测风速, 然后根据风电场的布局与发电特性等信息计算风电场的输出功率; 第二类为直接法, 即直接预测风电场的输出功率<sup>[2]</sup>。从时间角度可分为三类: 第一类为超短期预测(几分钟); 第二类为短期预测(几小时到几天); 第三类为中长期预测(数周或数月)<sup>[3]</sup>。从采用的数学模型角度可分为四类: 物理预测方法、统计预测方法、智能预测方法、组合预测方法<sup>[4]</sup>。基于数值天气预报的物理预测方法模型复杂、计算量很大; 以时间序列法为代表的统计预测方法模型简单, 但预测误差较大且预测结果不稳定<sup>[5]</sup>; 以神经网络为代表的智能预测方法一般不需

**基金项目:** 国家自然科学基金项目(60974051); 北京市自然科学基金项目(4122071)

要研究对象的准确解析模型, 具有较大优势。

在实际工况条件下, 短期风电功率不仅与风速有关, 而且与风向、气温、气压、湿度、粗糙度、尾流等因素有关, 以上原因导致短期风电功率的变化具有高度非线性和不确定性。而且在很多情况下, 各影响因素之间有一定的相关性, 从而使得这些变量提供的信息在一定程度上有所重叠, 这会增加计算的复杂性, 给预测带来较大的误差。

主成分分析法是一种多元统计分析方法, 它通过线性变换从被考察的可能有一定相关关系的多个变量中综合出较少几个互不相关的新变量, 可以有效解决上述问题。

BP 网络由于其良好的非线性逼近能力、结构比较简单、操作性强, 在风电功率预测中引起了广泛关注<sup>[6-10]</sup>。但它存在训练时间长、易陷入局部极小值的问题。Levenberg-Marquardt 法结合了梯度下降法和牛顿法的优点, 采用 Levenberg-Marquardt 法训练神经网络可有效解决 BP 神经网络训练时间长的问題; 遗传算法是一种全局并行的随机搜索方法, 具有良好的全局寻优能力, 采用遗传算法优化神经网络的初始权值和阈值可有效解决 BP 网络易陷入局部极小值的问题。

针对原始输入数据间的相关性及 BP 神经网络训练时间长、易陷入局部极小值的不足, 本文建立了基于主成分分析与遗传神经网络相结合的短期风电功率预测模型。首先采用主成分分析法对原始输入样本进行预处理, 预处理后的数据用于神经网络建模。结合神经网络对非线性问题良好的逼近能力和遗传算法优良的全局寻优能力, 分两步优化神经网络: 首先利用遗传算法优化网络的初始权值和阈值; 然后再用 Levenberg-Marquardt 法对网络权值和阈值进行细化训练以进一步减小误差。经风电场实际数据验证表明, 与 GA 神经网络模型、PCA-LM 神经网络模型相比, 预测精度明显提高, 为风电场输出功率短期预测提供了一种有效的方法。

## 1 短期风电功率影响因素的主成分模型

风速是影响风电场输出功率的重要参量之一, 除此之外, 风向、温度、气压等都对风电场输出功率有一定影响, 因此本文选取从数据采集与监视控制系统 (Supervisory Control And Data Acquisition, SCADA) 采集到的风速、风向、温度、气压实时数据作为网络模型的输入。为消除神经网络输入变量间的相关性, 建立了短期风电功率影响因素的主成分模型, 用较少的互不相关的综合变量来反映原变量所提供的绝大部分信息, 通过对新变量的分析达

到解决问题的目的<sup>[11]</sup>。

设有  $n$  组数据, 每组数据包含有  $p$  个变量, 得到原始数据矩阵  $X_{n \times p}$ , 主成分分析法简化输入的过程如下<sup>[12-13]</sup>。

### (1) 原始数据标准化

为消除原变量的量纲不同、数值差异太大带来的影响, 对原始数据进行标准化处理, 即

$$y_{ij} = \frac{x_{ij} - \bar{x}_j}{\sigma_j} \quad (1)$$

式中,  $i=1, 2, \dots, n; j=1, 2, \dots, p$ 。

$$\bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{ij}, \sigma_j = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2}$$

(2) 建立相关矩阵  $R$ , 并计算其特征值和特征向量。

$$R = \frac{1}{n-1} Y^T Y \quad (2)$$

式中,  $Y$  为标准化后的数据矩阵。

求得  $R$  的特征值为  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$  及相应的特征向量为

$$\alpha_i = (\alpha_{i1}, \alpha_{i2}, \dots, \alpha_{ip})^T, i=1, 2, \dots, p$$

(3) 计算方差贡献率  $\beta_k$  和累积方差贡献率  $\beta(k)$ 。

$$\beta_k = \lambda_k / \sum_{k=1}^p \lambda_k \quad (3)$$

$$\beta(k) = \sum_{i=1}^k \lambda_i / \sum_{i=1}^p \lambda_i \quad (4)$$

### (4) 求出主成分 $Z = Ya$

若  $\forall \alpha \in (0, 1)$ , 且当  $\beta(s) \geq \alpha$ , 则  $Z_1, Z_2, \dots, Z_s$  称为样本  $X_1, X_2, \dots, X_p$  的显著性水平为  $\alpha$  的主成分。其中  $\beta(s)$  为第  $s$  个主成分累计贡献率。以  $Z_1, Z_2, \dots, Z_s$  来代替  $X_1, X_2, \dots, X_p$ , 既降低了输入维数又消除了原样本空间的自相关性。

## 2 遗传神经网络预测模型

### 2.1 Levenberg-Marquardt 算法

L-M (Levenberg-Marquardt) 算法是高斯-牛顿法和梯度下降法的结合。由于 L-M 算法利用了近似二阶导数信息, 比梯度下降法快得多; 同时, L-M 算法不需要过多的调整参数, 在许多参数优化的场合得到了广泛的应用<sup>[14]</sup>。采用 L-M 算法训练神经网络时, 权值调整式为

$$\Delta W = (J^T J + \mu I)^{-1} J^T E \quad (5)$$

式中:  $\Delta W$  为权值修正量;  $E$  为误差;  $J$  为误差对权值微分的雅克比矩阵;  $\mu$  为标量, 它确定了学习是根据牛顿法还是梯度法来完成。实践表明, L-M 算法可有效解决传统 BP 算法的缺陷, 缩短学习时间<sup>[15]</sup>。

## 2.2 遗传神经网络算法

遗传算法作为一种现代优化方法, 借鉴了达尔文的进化论和孟德尔的遗传学说, 其本质是一种高效、并行、全局搜索的方法<sup>[16]</sup>。遗传算法与神经网络结合主要有三种方式<sup>[17]</sup>: (1) 用于网络训练, 即学习网络各层之间的连接权重; (2) 学习网络的拓扑结构; (3) 优化神经网络的学习规则, 本文采用遗传算法优化神经网络的初始权值和阈值。

当种群趋向于收敛后, 遗传算法不适合精确确定最优解的位置, 而当局部区域确定以后, L-M 算法可以快速收敛到训练精度要求<sup>[18]</sup>。因此本文将遗传算法用于神经网络权值和阈值的优化中, 分两步进行: 首先利用遗传算法群体寻优策略, 采用遗传算法对网络权值和阈值进行全局搜索, 保证其落入全局最优点的领域; 然后再用 L-M 法对网络权值和阈值进行细化训练以进一步减小误差, 使其收敛于全局最优解或性能更好的近似最优解。该网络能够充分发挥遗传算法的全局收敛和 L-M 算法的指导性搜索思想, 能有效地解决传统 BP 网络的收敛速度慢、易陷入局部极小值的缺陷, 并提高网络的学习精度<sup>[19-20]</sup>, 其算法流程图如图 1 所示。

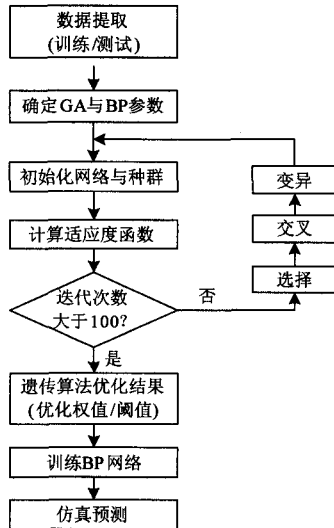


图 1 遗传算法优化 BP 网络权值/阈值流程图

Fig. 1 Flow chart of optimizing weights and thresholds with Genetic Algorithm

## 3 实例分析

### 3.1 样本选取及主成分分析

本次所采用的样本数据取自内蒙古某风电场 28 天现场实际数据, 采样间隔为 10 min, 总共 4 032 组数据。前 25 天的 3 600 组数据作为训练样本, 后 3 天的 432 组数据作为测试样本, 建立风电功率短期预测模型, 仿真试验是在 Matlab 7.1 环境下编程实现。

为消除输入数据矩阵  $X_{4032 \times 4}$  各变量单位和数量级不同的影响, 先对输入数据矩阵进行标准化处理, 得到新的数据矩阵  $Y_{4032 \times 4}$ , 然后调用 princomp 函数对矩阵  $Y_{4032 \times 4}$  进行主成分分析, 获得分析后的 4 个综合指标变量。所得 4 个新变量协方差矩阵特征值以及协方差矩阵的各特征值对应的特征向量分别如表 1、表 2 所示。

表 1 4 个变量的协方差矩阵特征值

Table 1 The eigenvalue of four variables covariance matrix

主成分 变量名	协方差矩阵 特征值	相邻两特征 值之差	主成分 贡献率	累计 贡献率
$Z_1$	1.629 1	0.610 8	40.727 2	40.727 2
$Z_2$	1.018 3	0.154 0	25.457 8	66.185 0
$Z_3$	0.864 4	0.376 1	21.609 0	87.794 0
$Z_4$	0.488 2		12.206 0	100.000 0

表 2 协方差矩阵各特征值对应的特征向量

Table 2 The characteristic vector of eigenvalue of covariance matrix

	matrix			
	$Z_1$	$Z_2$	$Z_3$	$Z_4$
$Y_1$	-0.426 4	-0.299 8	0.826 2	-0.213 9
$Y_2$	0.061 7	0.928 8	0.365 2	-0.013 9
$Y_3$	0.662 9	-0.100 6	0.115 9	-0.732 8
$Y_4$	0.612 3	-0.193 4	0.413 0	0.645 8

取  $\alpha = 90\%$ , 由表 1 可知四个特征值的累积方差贡献率才大于 90%, 所以选取四个主成分。

通过特征向量矩阵写出主成分表达式。

第一主成分为

$$Z_1 = -0.4264Y_1 + 0.0617Y_2 + 0.6629Y_3 + 0.6123Y_4$$

第二主成分为

$$Z_2 = -0.2998Y_1 + 0.9288Y_2 - 0.1006Y_3 - 0.1934Y_4$$

第三主成分为

$$Z_3 = 0.8262Y_1 + 0.3652Y_2 + 0.1159Y_3 + 0.4130Y_4$$

第四主成分为

$$Z_4 = -0.2139Y_1 - 0.0139Y_2 - 0.7328Y_3 + 0.6458Y_4$$

式中,  $Y_1$ 、 $Y_2$ 、 $Y_3$ 、 $Y_4$  分别代表标准化处理后的风速、风向、温度、气压数据。

从主成分表达式的系数可以看出: 第一主成分主要与温度和气压有关; 第二主成分主要与风向有关; 第三主成分主要与风速有关; 第四主成分主要与温度和气压有关。根据上述表达式对样本数据进行主成分计算, 计算所得数据再用于神经网络建模。

### 3.2 遗传神经网络参数选取

#### 3.2.1 神经网络结构

根据 Kolmogorov 定理, 三层的前向神经网络可以以任意精度逼近任何连续的非线性函数, 因此预测模型中的神经网络采用三层神经元结构, 即 1 个输入层、1 个隐含层和 1 个输出层。选取风电场输出功率的 4 个主要影响因素: 风速、风向、温度、气压作为神经网络的输入, 即输入层神经元个数为 4; 输出为风电功率值, 即输出层神经元个数为 1; 将隐含层神经元个数设为输入层神经元个数的 2 倍再加 1<sup>[21]</sup>, 即隐含层神经元个数设为 9。隐含层和输出层的激活函数分别为  $\text{tansig}$  函数和  $\text{purelin}$  函数, 网络训练函数为  $\text{trainlm}$  函数, 学习速率为 0.01, 训练目标为 0.01。

#### 3.2.2 遗传算法参数选取

遗传算法在进化搜索过程中是以适应度函数为依据的, 本文选取误差平方和的倒数作为适应度函数; 权重个体的基因位数为  $P = 4 \times 9 + 9 \times 1 + 9 + 1 = 55$ , 基因位数较长, 所以采用浮点数编码; 初始种群大小为 100; 选择轮盘赌抽样; 算术交叉概率为 0.9; 非统一变异概率为 0.09; 最大进化代数 of 100 代。

### 3.3 功率预测仿真与结果分析

主成分分析后所得数据作为神经网络的输入, 利用遗传算法优化神经网络的初始权值和阈值, 经过 100 代繁殖后, 退出遗传算法, 得到神经网络权值和阈值的初始值, 优化过程如图 2 所示。

从图 2 可以看出, 遗传繁殖到 72 代时, 最佳适应度函数已不再发生变化, 即说明遗传算法已对神经网络的权值和阈值进行了全局搜索, 找到粗略的最优值区域。

找到粗略的最优值区域之后, 为进一步减小误差, 对神经网络进行细化训练, 图 3、图 4 分别为采用 L-M 算法、BP 算法训练神经网络的收敛曲线。

从图3、图4 可以比较得出, 采用L-M算法训练神经网络只需7次的迭代就可以把误差数量级数降

低到0.01, 而采用BP算法进行了1 000次训练才把网络的训练误差降到0.055, 可见采用L-M算法训练神经网络可有效解决BP算法训练速度慢的问题, 仿真验证表明GA与L-M的混合算法工作状态较理想, 算法收敛速度快。




图2 适应度函数进化曲线

Fig. 2 Evolution curve of fitness function

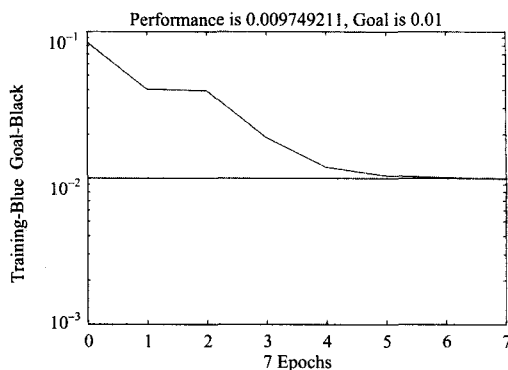


图3 采用 L-M 算法训练神经网络的收敛曲线

Fig. 3 Convergence curve of neural network training with L-M algorithm




图4 采用 BP 算法训练神经网络的收敛曲线

Fig. 4 Convergence curve of neural network training with BP algorithm

为验证本文提出的主成分-遗传神经模型的有效性, 对内蒙古某风电场现场数据进行了短期风电功率预测仿真, 并将仿真结果与实际风电功率值、PCA-LM 神经网络预测值、GA 神经网络预测值进行对比。

图 5 为 PCA-GA 神经网络模型预测效果图, 其中实线为实际风电功率值, 虚线为 PCA-GA 神经网络预测值。预测的误差如表 3 所示。




图 5 PCA-GA 神经网络预测效果

Fig. 5 The prediction result of PCA-GANN

表 3 PCA-GA 神经网络预测误差

Table 3 Prediction error of PCA-GANN

$e_{MAE}/\%$	$e_{RMSE}/\%$
2.52	3.27

表 3 中  $e_{MAE}$ 、 $e_{RMSE}$  分别为国际上通用的两种误差评价指标: 平均绝对误差、均方根误差, 分别按如下公式计算<sup>[22]</sup>: 其中平均绝对误差 (Mean Absolute Error, MAE) 定义为

$$e_{MAE} = \frac{\sum |y_i' - y_i|}{nP} \quad (6)$$

均方根误差 (Root Mean Square Error, RMSE) 定义为

$$e_{RMSE} = \frac{1}{P} \sqrt{\frac{\sum (y_i' - y_i)^2}{n}} \quad (7)$$

其中:  $y_i$ 、 $y_i'$ 、 $P$  分别表示风电场实际功率值、风电场预测功率值和风电场额定容量;  $n$  为样本数量。

图 6 为 PCA-GA 神经网络与 PCA-LM 神经网络预测结果对比图, 其中实线为风电功率实际值, 虚线为 PCA-GA 神经网络预测值, 点划线为 PCA-LM 神经网络预测值。预测误差比较如表 4 所示。




图 6 PCA-GA 神经网络与 PCA-LM 神经网络预测结果对比

Fig. 6 Comparison of prediction results of PCA-GANN and PCA-LMNN

表 4 PCA-GA 神经网络与 PCA-LM 神经网络

预测误差比较

Table 4 Comparison of prediction error of PCA-GANN and PCA-LMNN

指标	PCA-GA 神经网络	PCA-LM 神经网络
$e_{MAE}/\%$	2.52	4.79
$e_{RMSE}/\%$	3.27	6.03

从图 6 和表 4 可以比较得出, 采用 PCA-GA 神经网络建模得到的平均绝对误差比 PCA-LM 神经网络建模的降低了 2.27%, 均方根误差降低了 2.76%, 因为遗传算法具有良好的全局搜索能力, 采用遗传算法优化神经网络的初始权值和阈值可有效解决 BP 神经网络全局搜索能力差、易陷入局部极小值的不足, 提高模型预测的精度。

图 7 为 PCA-GA 神经网络与 GA 神经网络预测结果对比图, 其中实线为风电功率实际值, 虚线为 PCA-GA 神经网络预测值, 点划线为 GA 神经网络预测值。预测误差比较如表 5 所示。

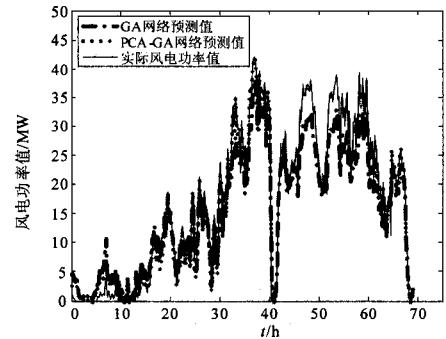


图 7 PCA-GA 神经网络与 GA 神经网络预测结果对比

Fig. 7 Comparison of prediction results of PCA-GANN and GANN

表 5 PCA-GA 神经网络与 GA 神经网络预测误差比较  
Table 5 Comparison of prediction error of PCA-GANN and

指标	GANN	
	PCA-GA 神经网络	GA 神经网络
$e_{MAE}/\%$	2.52	5.35
$e_{RMSE}/\%$	3.27	6.77

从图 7 和表 5 可以比较得出 PCA-GA 神经网络预测模型的各项评价指标值均优于 GA 神经网络预测模型, 平均绝对误差比采用 GA 神经网络建模的降低了 2.83%, 均方根误差降低了 3.5%。因为 PCA 消除了变量之间的相关性, 减少了计算的复杂性, 提高了预测精度和泛化能力。

#### 4 结论

本文建立了基于主成分分析与遗传神经网络相结合的短期风电功率预测模型, 现场实际数据仿真结果表明该模型可有效克服 BP 神经网络训练时间长、易陷入局部极小值的不足, 为风电功率短期预测问题的解决提供了有效的方法。

#### 参考文献

- [1] 李晶, 宋家骅, 王伟胜. 大型变速恒频风力发电机组建模与仿真[J]. 中国电机工程学报, 2004, 24(6): 104-109.  
LI Jing, SONG Jia-hua, WANG Wei-sheng. Modeling and dynamic simulation of variable speed wind turbine with large capacity[J]. Proceedings of the CSEE, 2004, 24(6): 104-109.
- [2] 王丽婕, 廖晓钟, 高阳, 等. 风电场发电功率的建模和预测研究综述[J]. 电力系统保护与控制, 2009, 37(13): 118-121.  
WANG Li-jie, LIAO Xiao-zhong, GAO Yang, et al. Summarization of modeling and prediction of wind power generation[J]. Power System Protection and Control, 2009, 37(13): 118-121.
- [3] 谷兴凯, 范高峰, 王晓蓉, 等. 风电功率预测技术综述[J]. 电网技术, 2007, 31(S2): 335-338.  
GU Xing-kai, FAN Gao-feng, WANG Xiao-rong, et al. Summarization of wind power prediction technology[J]. Power System Technology, 2007, 31(S2): 335-338.
- [4] 洪翠, 林维明, 温步瀛. 风电场风速及风电功率预测方法研究综述[J]. 电网与清洁能源, 2011, 27(1): 60-66.  
HONG Cui, LIN Wei-ming, WEN Bu-ying. Overview on prediction methods of wind speed and wind power[J]. Power System and Clean Energy, 2011, 27(1): 60-66.
- [5] 方江晓, 周晖, 黄梅. 基于统计聚类分析的短期风电功率预测[J]. 电力系统保护与控制, 2011, 39(11): 67-73.  
FANG Jiang-xiao, ZHOU Hui, HUANG Mei. Short-term wind power prediction based on statistical clustering analysis[J]. Power System Protection and Control, 2011, 39(11): 67-73.
- [6] 张珣, 颜文俊, 王超. 基于 AMPSO 算法与神经网络的风电场发电量预测[J]. 华东电力, 2011, 39(5): 797-802.  
ZHANG Xu, YAN Wen-jun, WANG Chao. Prediction study of wind energy based on AMPSO algorithm and neural network[J]. East China Electric Power, 2011, 39(5): 797-802.
- [7] 武小梅, 白银明, 文福拴. 基于 RBF 神经网络的风电功率短期预测[J]. 电力系统保护与控制, 2011, 39(15): 80-83.  
WU Xiao-mei, BAI Yin-ming, WEN Fu-shuan. Short-term wind power forecast based on the radial basis function neural network[J]. Power System Protection and Control, 2011, 39(15): 80-83.
- [8] 师洪涛, 杨静玲, 丁茂生, 等. 基于小波-BP 神经网络的短期风电功率预测方法[J]. 电力系统自动化, 2011, 35(16): 44-48.  
SHI Hong-tao, YANG Jing-ling, DING Mao-sheng, et al. A short-term wind power prediction method based on wavelet decomposition and BP neural network[J]. Automation of Electric Power Systems, 2011, 35(16): 44-48.
- [9] 袁铁江, 晁勤, 李义岩, 等. 大规模风电并网电力系统经济调度中风电场出力的短期预测模型[J]. 中国电机工程学报, 2010, 30(13): 23-27.  
YUAN Tie-jiang, CHAO Qin, LI Yi-yan, et al. Short-term wind power output forecasting model for economic dispatch of power system incorporating large-scale wind farm[J]. Proceedings of the CSEE, 2010, 30(13): 23-27.
- [10] 孟洋洋, 卢继平, 孙华利, 等. 基于相似日和人工神经网络的风电功率短期预测[J]. 电网技术, 2010, 34(12): 163-167.  
MENG Yang-yang, LU Ji-ping, SUN Hua-li, et al. Short-term wind power forecasting based on similar days and artificial neural network[J]. Power System Technology, 2010, 34(12): 163-167.
- [11] 张明理, 杨晓亮, 滕云, 等. 基于主成分分析与前向反馈传播神经网络的风电场输出功率预测[J]. 电网技术, 2011, 35(3): 183-187.  
ZHANG Ming-li, YANG Xiao-liang, TENG Yun, et al. Forecasting of wind farm generation output based on principal component analysis and back propagation neural network[J]. Power System Technology, 2011, 35(3): 183-187.
- [12] 赵杰辉, 葛少云, 刘自发, 等. 基于主成分分析的径向基函数神经网络在电力系统负荷预测中的应用[J]. 电网技术, 2004, 28(5): 35-37.  
ZHAO Jie-hui, GE Shao-yu, LIU Zi-fa, et al. Application of radial basic function network based on principal component analysis in load forecasting[J]. Power System

- Technology, 2004, 28(5): 35-37.
- [13] 王华, 王连华, 葛岭梅. 主成分分析与 BP 神经网络在煤耗氧速度预测中的应用[J]. 煤炭学报, 2008, 33(8): 920-925.  
WANG Hua, WANG Lian-hua, GE Ling-mei, et al. Application of principal component analysis and BP neural network in the rate of coal oxygen consumption prediction[J]. Journal of China Coal Society, 2008, 33(8): 920-925.
- [14] 韩敏, 穆大芸. 回声状态网络 LM 算法及混沌时间序列预测[J]. 控制与决策, 2011, 26(10): 8-12.  
HAN Min, MU Da-yun. L-M algorithm in echo state network for chaotic time series prediction[J]. Control and Decision, 2011, 26(10): 8-12.
- [15] 杨秀媛, 肖洋, 陈树勇. 风电场风速和发电功率预测研究[J]. 中国电机工程学报, 2005, 25(11): 1-5.  
YANG Xiu-yuan, XIAO Yang, CHEN Shu-yong. Wind speed and generated power forecasting in wind farm[J]. Proceedings of the CSEE, 2005, 25(11): 1-5.
- [16] 据亚平, 张楚华. 基于人工神经网络与遗传算法的风力机翼型优化设计方法[J]. 中国电机工程学报, 2009, 29(20): 106-111.  
JU Ya-ping, ZHANG Chu-hua. Optimal design method for wind turbine airfoil based on artificial neural network model and genetic algorithm[J]. Proceedings of the CSEE, 2009, 29(20): 106-111.
- [17] 王小平, 曹立明. 遗传算法——理论、应用与软件实现[M]. 西安: 西安交通大学出版社, 2002: 189-190.
- [18] 田旭光, 宋彤, 刘宇新. 结合遗传算法优化 BP 神经网络的结构和参数[J]. 计算机应用与软件, 2004, 21(6): 69-71.  
TIAN Xu-guang, SONG Tong, LIU Yu-xin. Optimizing the structure and parameters of BP neural network based on genetic algorithm[J]. Computer Applications and Software, 2004, 21(6): 69-71.
- [19] 孙光民, 张灿辉, 王湛, 等. 基于遗传神经网络的微滤膜通量的预测[J]. 化工学报, 2009, 60(9): 2237-2242.  
SUN Guang-min, ZHANG Can-hui, WANG Zhan, et al. Flux prediction of micro-filtration devices based on genetic neural network[J]. Journal of the Chemical Industry and Engineering Society of China, 2009, 60(9): 2237-2242.
- [20] 韩飞, 莫健华, 龚攀. 基于遗传神经网络的数字化渐进成形回弹预测[J]. 华中科技大学学报: 自然科学版, 2008, 36(1): 121-124.  
HAN Fei, MO Jian-hua, GONG Pan. Incremental sheet NC forming springback prediction using genetic neural network[J]. Journal of Huazhong University of Science and Technology: Natural Science, 2008, 36(1): 121-124.
- [21] 范佳妮, 王振雷, 钱锋. BP 人工神经网络隐层结构设计的研究进展[J]. 控制工程, 2005, 12(S2): 109-113.  
FAN Jia-ni, WANG Zhen-lei, QIAN Feng. Research progress structural design of hidden layer in BP artificial neural networks[J]. Control Engineering of China, 2005, 12(S2): 109-113.
- [22] 徐曼, 乔颖, 鲁宗相. 短期风电功率预测误差综合评价方法[J]. 电力系统自动化, 2011, 35(12): 20-26.  
XU Man, QIAO Yin, LU Zong-xiang. A comprehensive error evaluation method for short-term wind power prediction[J]. Automation of Electric Power Systems, 2011, 35(12): 20-26.

收稿日期: 2012-02-28

作者简介:

罗毅(1969-), 男, 教授, 主要研究方向为复杂系统建模与仿真、优化控制与决策; E-mail: lyphzh@163.com

刘峰(1987-), 男, 硕士研究生, 研究方向为风电场输出功率预测; E-mail: ncepuliufeng@163.com

刘向杰(1966-), 男, 教授, 博士生导师, 主要研究方向为先进控制策略在电力过程控制中的应用、非线性系统建模与控制、预测与自适应控制。

(上接第 46 页 continued from page 46)

- [9] 朱声石. 差动保护的暂态可靠性[J]. 继电器, 2002, 30(8): 1-6.  
ZHU Sheng-shi. The transient reliability of differential protection[J]. Relay, 2002, 30(8): 1-6.
- [10] 徐振宇. 1000 kV 特高压输电线路保护的现状及发展[J]. 电力设备, 2008, 9(4): 17-20.  
XU Zhen-yu. The development and application of 1000 kV UHV transmission line protection[J]. Electrical Equipment, 2008, 9(4): 17-20.
- [11] 尹项根, 邵能灵, 杨书富. 标积制动量的应用与分析[J]. 中国电机工程学报, 2000, 20(1): 85-88.  
YIN Xiang-gen, TAI Neng-ling, YANG Shu-fu. The application and analysis of the differential protection with the product-restraint quantity[J]. Proceedings of the CSEE, 2000, 20(1): 85-88.
- [12] 吴大立, 尹项根, 张哲, 等. 输电线路复合差动保护方案[J]. 电网技术, 2008, 32(7): 87-91.  
WU Da-li, YIN Xiang-gen, ZHANG Zhe, et al. Research on multi-differential protection scheme for transmission line[J]. Power System Technology, 2008, 32(7): 87-91.

收稿日期: 2012-02-27; 修回日期: 2012-04-13

张艳霞(1962-), 女, 博士, 教授, 研究方向为电力系统继电保护;

张家杭(1987-), 男, 硕士研究生, 研究方向为电力系统继电保护. E-mail: waynezoe@126.com