

# 基于自适应扰动量子粒子群算法参数优化的 支持向量回归机短期风电功率预测

陈道君<sup>1</sup>, 龚庆武<sup>1</sup>, 金朝意<sup>2</sup>, 张静<sup>1</sup>, 王定美<sup>3</sup>

(1. 武汉大学 电气工程学院, 湖北省 武汉市 430072;

2. 南京南瑞继保电气有限公司, 江苏省 南京市 211100;

3. 甘肃省电力公司风电技术中心, 甘肃省 兰州市 730050)

## Short-Term Wind Power Prediction Based on Support Vector Regression Machine Optimized by Adaptive Disturbance Quantum-Behaved Particle Swarm Optimization

CHEN Daojun<sup>1</sup>, GONG Qingwu<sup>1</sup>, JIN Zhaoyi<sup>2</sup>, ZHANG Jing<sup>1</sup>, WANG Dingmei<sup>3</sup>

(1. School of Electrical Engineering, Wuhan University, Wuhan 430072, Hubei Province, China;

2. Nari-relays Electric Co. Ltd., Nanjing 211100, Jiangsu Province, China;

3. Wind Power Center of Gansu Electric Power Corporation, Lanzhou 730050, Gansu Province, China)

**ABSTRACT:** A higher accuracy of short-term wind farm output prediction is required due to the construction of smart grid and grid-connection of large-scale wind farms. To remedy the defect of support vector regression machine (SVR) that the learning parameter selection of SVR depends on factitious experiences, adaptive disturbance quantum-behaved particle swarm optimization (ADQPSO) algorithm is proposed by adding adaptive premature criterion, mixed disturbance operator and dynamic expansion-contraction coefficient in quantum-behaved particle swarm optimization (QPSO) algorithm, and ADQPSO algorithm is used in optimized selection of learning parameters for SVR. Case study shows that the proposed ADQPSO algorithm possesses such advantages as good global search ability, strong robustness and high computation efficiency, and applying the ADQPSO algorithm to the optimization of the obtained learning parameters of SVR the accuracy of short-term wind power prediction is higher than those by back propagation neural network (BPNN) and radial basis function neural network (RBFNN).

**KEY WORDS:** short-term wind power prediction; selection of learning parameters; adaptive disturbance quantum-behaved particle swarm optimization (ADQPSO) algorithm; support vector regression machine (SVR)

**摘要:** 智能电网的建设和大规模风电接入电网对短期风电功率预测精度提出了更高的要求。为了克服支持向量回归机(support vector regression machine, SVR)依赖人为经验选择学习参数的弊端,在量子粒子群优化(quantum-behaved particle swarm optimization, QPSO)算法中加入自适应早熟判定准则、混合扰动算子和动态扩张-收缩系数,提出了自适应扰动量子粒子群优化算法(adaptive disturbance quantum-behaved particle swarm optimization, ADQPSO),并使用ADQPSO优化选择SVR的学习参数。实例研究表明,ADQPSO算法全局寻优能力强、鲁棒性好、计算耗时短,利用ADQPSO优化得到的SVR参数,可有效提高模型的预测精度;与反向传播神经网络(back propagation neural network, BPNN)和径向基神经网络(radial basis function neural network, RBFNN)相比,提出的ADQPSO-SVR能够提高短期风电功率预测的准确性和稳定性。

**关键词:** 短期风电功率预测; 学习参数选择; 自适应扰动量子粒子群优化算法; 支持向量回归机

## 0 引言

风电场的输出功率具有高度随机性和间歇性,大规模风电接入电网会给电力系统的安全稳定运行带来严峻挑战,其中很重要的一方面是对电力系统调度运行的影响<sup>[1]</sup>。提高短期风电功率预测精度,有利于电力系统调度部门及时调整发电计划,从而有效减轻风电波动对电网造成的不利影响,减少电力系统的旋转备用和运行成本<sup>[2]</sup>。

目前常用的风电功率预测方法包括持续时间法、卡尔曼滤波法<sup>[3]</sup>、人工神经网络法<sup>[4]</sup>、自回归

基金项目: 中央高校基本科研业务费专项资金资助(201120702020009); 教育部博士研究生学术新人奖(5052011207016)。

Fundamental Research Funds for the Central Universities (201120702020009); The Scholarship Award for Excellent Doctoral Student Granted by Ministry of Education (5052011207016)。

滑动平均模型(auto-regressive and moving average model, ARMA)法<sup>[5]</sup>、小波分析法<sup>[6]</sup>和支持向量机(support vector machine, SVM)回归法等。SVM中的支持向量回归机(support vector regression, SVR)作为一种具有较好非线性拟合能力的机器学习方法,近年来被广泛应用于风电功率预测的研究中。文献[7]分别使用SVR和ARMA预测风电场输出功率,利用交叉熵理论建立了风电功率组合预测模型;文献[8]使用SVR模型预测短期风电功率,重点研究建模数据量多少对于预测结果的影响;文献[9]用经验模态分解将风速序列分解为一系列相对平稳的分量,利用SVR对各分量建立预测模型,最后通过功率转化曲线得到风电功率预测结果。选取适当的学习参数对于SVR模型的学习性能和泛化能力非常重要<sup>[10]</sup>,直接影响着预测精度的高低。传统预测方法往往根据经验,通过反复试验来选择参数,但这并不能确保SVR模型训练误差达到全局最小,预测结果也无法保证最优。

量子粒子群优化(quantum-behaved particle swarm optimization, QPSO)算法具有全局寻优能力强、鲁棒性好和计算耗时短等特点,已被成功应用于解决电力系统多目标发电调度<sup>[11]</sup>和数字滤波器参数优化<sup>[12]</sup>等问题。本文针对QPSO算法在迭代过程中可能出现的早熟收敛问题,在算法中加入自适应早熟判定准则、混合扰动算子(blended disturbance operator, BDO)和动态扩张-收缩系数(dynamic expansion compression coefficient, DECC),提出自适应扰动量子粒子群优化(adaptive disturbance quantum-behaved particle swarm optimization, ADQPSO)算法,并将其用于SVR学习参数的优化选择,实现参数的自动调整。实例分析验证ADQPSO算法在优化选择SVR学习参数时的有效性。与反向传播神经网络(back propagation neural network, BPNN)和径向基神经网络(radial basis function neural network, RBFNN)相比,ADQPSO-SVR模型在短期风电功率预测中具有更好的预测准确性和稳定性。

## 1 支持向量回归机模型

SVM方法最早用于解决线性可分情况下2类样本的分类问题,将分类问题推广到解决回归拟合问题就形成了SVR<sup>[13]</sup>。SVR使用非线性核函数,将低维空间的非线性数据集映射到高维Hilbert空

间,转化为线性问题进行回归估计。

SVR依据结构风险最小化的思想构建损失函数,并通过极小化以下目标函数来确定回归函数:

$$\begin{cases} \min & [\frac{1}{2} \mathbf{w}^T \mathbf{w} + \frac{C}{n} \sum_{i=1}^n (\xi_i + \xi_i^*)] \\ \text{s.t.} & f(\mathbf{x}_i) - y_i \leq \varepsilon + \xi_i \\ & y_i - f(\mathbf{x}_i) \leq \varepsilon + \xi_i^* \\ & \xi_i, \xi_i^* \geq 0, i=1, 2, \dots, n \end{cases} \quad (1)$$

式中:  $C$  是惩罚系数;  $\xi_i$ 、 $\xi_i^*$  为松弛因子;  $\varepsilon$  为不敏感损失系数。

引入拉格朗日乘子,式(1)可转化为求解如下对偶问题:

$$\begin{cases} \min & [\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n (a_i^* - \alpha_i)(a_j^* - \alpha_j) K(\mathbf{x}_i, \mathbf{x}_j)] + \\ & \varepsilon \sum_{i=1}^n (a_i^* + \alpha_i) - \sum_{i=1}^n y_i (a_i^* - \alpha_i) \\ \text{s.t.} & \sum_{i=1}^n (a_i - a_i^*) = 0 \text{ 且 } 0 \leq a_i, a_i^* \leq \frac{C}{n} \end{cases} \quad (2)$$

式中:  $K(\mathbf{x}_i, \mathbf{x}_j)$  为核函数,满足 Mercer 条件;  $a_i$  和  $a_i^*$  为拉格朗日乘子。

求解式(2)可得到最优回归函数为

$$f(\mathbf{x}) = \sum_{i=1}^n (a_i - a_i^*) K(\mathbf{x}_i, \mathbf{x}) + b \quad (3)$$

常用核函数有如下形式: 1) 多项式核函数,  $K(\mathbf{x}, \mathbf{x}_i) = \mathbf{x}_i^T \mathbf{x}$ ; 2) 径向基(radial basis function, RBF)核函数,  $K(\mathbf{x}, \mathbf{x}_i) = \exp(-\|\mathbf{x} - \mathbf{x}_i\|^2 / 2\sigma^2)$ ; 3) 多层感知器(multi-layer perception, MLP)核函数,  $K(\mathbf{x}, \mathbf{x}_i) = \tanh(\mathbf{v} \mathbf{x}_i^T \mathbf{x} + \gamma)$ 。RBF核函数的局部性较优,它对于一定范围内的数据具有较好的插值能力<sup>[14]</sup>。短期风电功率预测以局部历史数据为基础,这些数据在一定范围内波动,同时,短期预测需要较好跟踪数据的变化,得出局部几h内较准确的预测值。因此,RBF核函数更适用于短期风电功率预测研究。

由上述分析可知,使用SVR进行预测时需要选择的学习参数包括式(1)中的  $C$ 、 $\varepsilon$  和 RBF 核函数的核参数  $\sigma$ , 本文使用 ADQPSO 算法在模型训练阶段实现这3个参数的自动选择。

## 2 自适应扰动量子粒子群优化算法

### 2.1 量子粒子群优化算法

粒子群优化算法(particle swarm optimization, PSO)不能保证以概率1搜索到全局最优解,PSO的全局收敛性存在一定缺陷<sup>[15]</sup>。针对上述问题, Sun 从量子力学的角度考察粒子个体与群体的进化模

式, 提出了 QPSO 算法<sup>[16]</sup>。QPSO 算法中的粒子只带有位置信息, 而没有速度信息, 算法的控制参数相对更少, 同 PSO 相比, 其具有全局寻优能力强、鲁棒性好和计算耗时短的优点。

假设粒子  $m$  在  $D$  维空间运动, 在第  $k$  次迭代时, 粒子  $m$  在第  $d$  维的势阱为  $p_{md}(k)$ 。

$$p_{md}(k) = \varphi_{md}(k)P_{md}(k) + [1 - \varphi_{md}(k)]P_{gd}(k) \quad (4)$$

式中:  $P_m$  为粒子  $m$  的个体最优位置;  $P_g$  为群体的全局最优位置;  $\varphi_{md}$  是均匀分布在  $(0, 1)$  上的随机数。

应用 Monte Carlo 方法可以得到在第  $k+1$  次迭代时粒子  $m$  在第  $d$  维的位置表达式<sup>[17]</sup>为

$$x_{md}(k+1) = p_{md}(k) \pm 0.5L_{md}(k)\ln[1/u_{md}(k)] \quad (5)$$

式中:  $u_{md}$  是均匀分布在  $(0, 1)$  上的随机数;  $L_{md}(k)$  可以通过式(6)确定。

$$L_{md}(k) = 2\alpha|S_d(k) - x_{md}(k)| \quad (6)$$

式中:  $\alpha$  称为扩张-收缩系数;  $S$  为平均最优位置, 它是所有粒子个体最优位置的中心点, 可以由式(7)计算得到:

$$S(k) = (S_1(k), S_2(k), \dots, S_D(k)) = \frac{1}{M} \sum_{m=1}^M P_m(k) = \left( \frac{1}{M} \sum_{m=1}^M P_{m1}(k), \frac{1}{M} \sum_{m=1}^M P_{m2}(k), \dots, \frac{1}{M} \sum_{m=1}^M P_{mD}(k) \right) \quad (7)$$

式中:  $M$  为群体规模。

综合式(5)(6)得到粒子的位置更新方程为

$$x_{md}(k+1) = p_{md}(k) \pm \alpha|S_d(k) - x_{md}(k)| \cdot \ln(1/u_{md}(k)) \quad (8)$$

QPSO 算法中  $P_m$  和  $P_g$  的更新方程与 PSO 算法的更新方程完全相同, 即

$$\begin{cases} P_m(k+1) = \begin{cases} x_m(k+1), & f(x_m(k+1)) < f(P_m(k)) \\ P_m(k), & f(x_m(k+1)) \geq f(P_m(k)) \end{cases} \\ P_g(k+1) = \arg\{\min_{1 \leq m \leq M} [f(P_m(k))]\} \end{cases} \quad (9)$$

式中:  $f()$  为目标函数。

## 2.2 自适应扰动量子粒子群优化算法

### 2.2.1 自适应早熟判定准则

作为进化算法, QPSO 也会遇到早熟收敛问题, 迭代后期粒子的多样性减少, 导致后续搜索中的局部寻优能力变差<sup>[18]</sup>。为了提高算法的局部搜索性能, 本文对 QPSO 算法做出了适当改进, 在算法中加入自适应早熟判定准则、混合扰动算子(blended disturbance operator, BDO)和动态扩张-收缩系数(dynamic expansion compression coefficient, DECC), 提出了 ADQPSO 算法。

在 QPSO 算法中, 粒子位置决定着粒子的适应

度大小, 粒子位置的一致等价于各粒子的适应度相同。因此, 根据群体中所有粒子适应度的整体变化可以判定群体的状态。

设群体规模大小为  $M$ ,  $f_m$  为粒子  $m$  的适应度,  $f_{avg}$  为当前群体的平均适应度,  $s^2$  为群体的适应度方差,  $s^2$  可以定义<sup>[19]</sup>为

$$s^2 = \sum_{m=1}^M \left( \frac{f_m - f_{avg}}{f} \right)^2 \quad (10)$$

式中:  $f$  为归一化定标因子, 通过式(11)计算得到。

$$f = \begin{cases} \max_{1 \leq m \leq M} |f_m - f_{avg}|, & \max_{1 \leq m \leq M} |f_m - f_{avg}| > 1 \\ 1, & \text{其他} \end{cases} \quad (11)$$

随着算法迭代次数的增加, 不同粒子的适应度会越来越接近, 因此  $s^2$  会越来越小。 $s^2$  越小, 则群体中粒子的聚集程度越大, 群体趋近于收敛。当  $s^2$  小于某一个给定的阈值  $\lambda$  时, 认为算法进入后期搜索阶段, 容易出现早熟收敛情况。当  $s^2 < \lambda$  时, 本文通过增加扰动操作的方法避免早熟现象出现。

### 2.2.2 平均最优位置增加混合扰动操作

扰动操作可以促使算法跳出局部最优, 进入解空间的其他区域继续进行搜索, 以达到提高计算精度的目的。本文在 QPSO 算法迭代后期使用 BDO 在平均最优位置增加扰动操作, BDO 表达式如下:

$$\beta_k = c_1[C_k(0,1) + c_2N_k(0,1)] \quad (12)$$

式中:  $C_k(0,1)$  为服从标准柯西分布(Cauchy disturbance, CD)的随机数;  $N_k(0,1)$  为服从标准高斯分布(Gaussian disturbance, GD)的随机数;  $c_1$  和  $c_2$  为扰动系数, 表达式如下:

$$\begin{cases} c_1 = c_{1min} + (c_{1max} - c_{1min}) \frac{k}{k_{max}} \\ c_2 = c_{2max} - (c_{2max} - c_{2min}) \frac{k}{k_{max}} \end{cases} \quad (13)$$

式中:  $c_{1max}$  为  $c_1$  的最大值, 取 2.0,  $c_{1min}$  为  $c_1$  的最小值, 取 0.05;  $c_{2max}$  为  $c_2$  的最大值, 取 5.0,  $c_{2min}$  为  $c_2$  的最小值, 取 0.1;  $k$  为当前迭代次数;  $k_{max}$  为最大迭代次数。

使用 BDO 操作后的平均最优位置  $\hat{S}_d(k)$  为

$$\hat{S}_d(k) = S_d(k)(1 + \beta_k) \quad (14)$$

BDO 具有如下优点: 1) 在迭代过程中, 随着  $c_2$  取值的变化, BDO 可以产生大量的介于 GD 和 CD 之间的概率密度函数, 从而得到范围更广的随机数; 2)  $c_1$  的取值随着迭代过程线性递增, 在扰动操作初期, 较小的  $c_1$  有利于对当前的搜索区域进行局部搜索, 利于算法收敛; 随着迭代过程的进行,

较大的  $c_1$  有利于跳出局部极小点, 便于全局搜索。

### 2.2.3 动态扩张-收缩系数

扩张-收缩系数  $\alpha$  能够调节 QPSO 算法的收敛过程,  $\alpha$  的控制方法对于算法的计算性能具有重要影响。借鉴 PSO 中关于动态惯性权重的思想<sup>[20]</sup>, 给出 DECC 的表达式:

$$\alpha = \alpha_{\min} + (\alpha_{\max} - \alpha_{\min}) \frac{k_{\max} - k}{k_{\max}} \quad (15)$$

式中:  $\alpha_{\max}$  和  $\alpha_{\min}$  分别为  $\alpha$  的最大值和最小值, 一般取  $\alpha_{\max}=1.0$ ,  $\alpha_{\min}=0.5$ 。

DECC 可以随着迭代的进行线性减小, 迭代初期较大的  $\alpha$  有利于全局寻优, 而较小的  $\alpha$  则在迭代后期, 避免算法陷入早熟收敛。

### 2.2.4 ADQPSO 算法描述

综上, ADQPSO 算法具体步骤如下:

- 1) 设置算法参数, 如群体规模、粒子维数, 初始化粒子群。
- 2) 在初始条件下, 根据目标函数计算每个粒子的适应度, 确定并记录粒子的个体最优位置  $P_m$ 、群体的全局最优位置  $P_g$  和平均最优位置  $S$ 。
- 3) 根据式(8)更新群体中粒子位置, 重新计算每个粒子的适应度, 按式(9)更新  $P_m$  和  $P_g$ , 按式(7)更新  $S$ 。
- 4) 判断算法是否满足终止条件, 如果满足, 转向步骤 6); 否则执行步骤 5)。
- 5) 根据式(10)计算群体的适应度方差, 判断  $s^2$  是否小于阈值  $\lambda$ , 如果是, 根据式(14)对群体执行扰动操作; 而后转向步骤 3)。
- 6) 输出  $P_g$  及其适应度值, 算法运行结束。

## 3 采用 ADQPSO 算法和 SVR 的短期风电功率预测方法

### 3.1 数据的归一化

风电功率数据值存在很大波动, 在训练和预测前, 需要对数据进行归一化处理, 归一化公式为

$$\hat{x}_i = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}}, \quad i=1, 2, \dots, n \quad (16)$$

式中:  $x_i$  为原始数据值;  $x_{\max}=\max(x_i)$ ;  $x_{\min}=\min(x_i)$ ;  $\hat{x}_i$  为归一化后的数据值。

### 3.2 适应度函数的选取

针对 SVR 学习参数选择, 选用均方误差(mean squared error, MSE)作为适应度函数, 表达式如下:

$$G = \frac{1}{n} \sum_{j=1}^n (y_j - \hat{y}_j)^2 \quad (17)$$

式中:  $y_j$  和  $\hat{y}_j$  分别为实际值和训练输出值;  $G$  为适应度函数,  $G$  越小, 说明选择的一组学习参数效果相对较好。

### 3.3 预测误差评价函数

预测误差评价函数采用平均绝对百分比误差(mean absolute percentage error, MAPE)、相对百分比误差(relative percentage error, RPE)和均方根误差(root of the mean squared error, RMSE)。

### 3.4 ADQPSO-SVR 预测流程图

采用 ADQPSO 算法和 SVR 的短期风电功率预测流程图如图 1 所示。

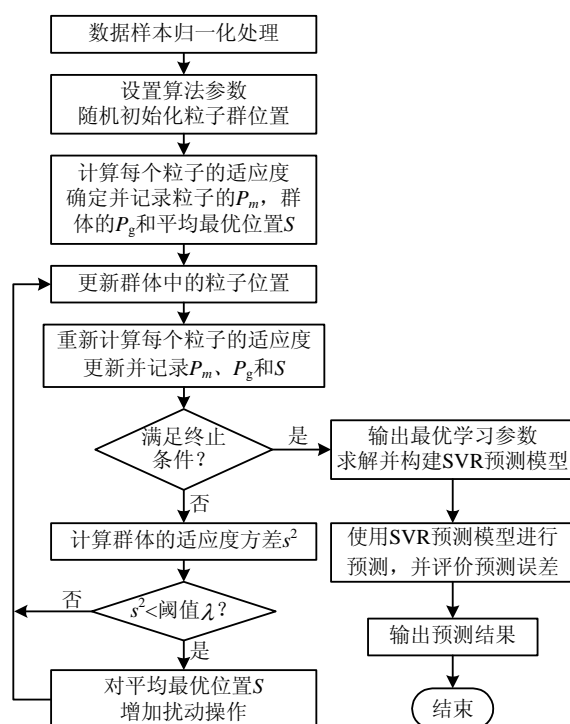


图 1 ADQPSO-SVR 预测流程图

Fig. 1 Flow chart of ADQPSO-SVR prediction

## 4 实例分析

### 4.1 研究对象与参数

以中国某风电场 2011 年 11 月的实测风电功率数据为实验样本, 该风电场含有单机容量为 750 kW 的风电机组 41 台, 总容量为 30 750 kW。样本数据每 10 min 采样一次。为满足预测的需要, 将每 h 内的 6 个数据作平均值处理, 转化为每小时 1 个点的数据。取其中的 7 d 数据用于建模预测, 前 6 d 的数据作为训练样本, 后 1 d 的数据作为测试样本。

采用提前 6 步的预测方法, 对未来 24 h 的风电功率进行直接多步预测。分别采用 PSO、遗传算法(genetic algorithm, GA)、QPSO 算法和 ADQPSO

算法优化选择 SVR 的学习参数, 并比较所构建 SVR 模型的预测效果。学习参数的搜索范围如下:  $C \in (0, 1000]$ ,  $\varepsilon \in [0.001, 1]$ ,  $\sigma \in [0.01, 10]$ 。使用 Matlab 编写程序代码, 计算环境为: Intel(R) Core(TM) i3-2100 3.10 GHz, 2 GB RAM。

#### 4.2 ADQPSO 算法性能分析

4 种算法的群体规模都取 20, 最大迭代次数取 200。PSO 的学习因子取 2, 惯性权重  $\omega=1$ ; GA 采用轮盘选择算子, 均匀交叉和基本位变异; QPSO 算法的  $\alpha=0.8$ ; ADQPSO 算法的阈值  $\lambda$  取  $5 \times 10^{-6}$ 。

考虑到算法的随机性, 对每种算法分别独立运行 20 次, 表 1 是 4 种算法的训练结果, 表 2 是 20 次运算中得到的最优学习参数。分析表 1 可知, GA 的寻优能力最差, 求得的最好适应度值仅为  $2.175 \times 10^{-2}$ , 20 次运算中适应度值的偏差为 4.920%。另外, GA 的计算耗时最长, 且每次计算耗时波动剧烈, 这表明 GA 在优化选择学习参数时的鲁棒性较差, 算法不够稳定。PSO 得到的最好适应度值比 GA 降低了 0.276%, 平均计算耗时减少了 74.115 s。QPSO 算法的训练结果较 GA 和 PSO 有了较大提升, 适应度偏差分别下降了 2.363% 和 1.777%; 最小计算耗时仅为 12.483 s, 是 4 种算法中最短的, 这验证了 QPSO 全局寻优能力强、鲁棒性好和计算耗时短的优点。ADQPSO 算法的训练效果最好, 20 次运算中得到的最好适应度值和平均适应度值都明显优于其他 3 种算法, 且偏差最小; 由于需要计算适应度方差和增加扰动操作, ADQPSO 的平均计算耗时比 QPSO 增加了 4.237 s, 但是比 GA 和 PSO 分别减少了 104.911 s 和 30.796 s。

惩罚系数  $C$  控制的是训练错误率与模型复杂度间的折衷。当  $C$  较小时, 训练错误率较高, 模型复杂度低;  $C$  增加时, 训练错误率迅速降低; 当  $C$  增加到一定值后, 训练错误率不再随  $C$  的变化而改变, 即在较大范围内, 模型的泛化能力对  $C$  的变化不敏感。因此, 虽然表 2 中不同算法得到的参数  $C$

表 1 4 种算法的训练结果

Tab. 1 The train results of four algorithms

评价指标	算法	最好值	最差值	平均值	偏差/%
适应度函数 $G/10^{-2}$	PSO	2.169	2.263	2.214	4.334
	GA	2.175	2.282	2.231	4.920
	QPSO	2.151	2.206	2.182	2.557
	ADQPSO	2.078	2.125	2.091	2.262
计算耗时/s	PSO	36.531	69.432	48.821	90.063
	GA	59.382	160.052	122.936	169.529
	QPSO	12.483	16.905	13.788	35.424
	ADQPSO	15.141	21.313	18.025	40.763

表 2 4 种算法得到的最优学习参数

Tab. 2 Optimal learning parameters obtained by four algorithms

参数	PSO	GA	QPSO	ADQPSO
$C$	8.5724	17.5243	7.5847	3.0116
$\varepsilon$	0.2291	0.1984	0.1875	0.0696
$\sigma$	0.2114	0.1579	0.2151	1.9577

的取值相差较大, 但依然在训练允许的误差范围内。

上述分析表明, ADQPSO 算法继承了 QPSO 算法鲁棒性好和计算耗时短的优点, 且进一步提升了算法的寻优能力, 计算精度、计算速度和算法的稳定性都远远优于 GA 和 PSO 算法。因此, ADQPSO 可以为 SVR 学习参数的选择提供更精确的解。

#### 4.3 ADQPSO-SVR 模型预测效果分析

使用表 2 的最优学习参数构建 SVR 预测模型, 预测结果如图 2 所示。表 3 是 4 种模型预测的 MAPE 和 RMSE 指标。从图 2 可看出, ADQPSO-SVR 模型相对于其他 3 种模型, 预测曲线更接近于真实曲线, 特别是在功率变化幅度大的位置, 其准确性更加明显。这主要是因为 ADQPSO 算法优化选择得到的学习参数更优良, 使得预测模型的精度和泛化能力更好。由表 3 的数据可知, ADQPSO-SVR 的 MAPE 为 10.344%, 同 PSO-SVR、GA-SVR 和 QPSO-SVR 相比, 分别降低了 3.671%、4.430% 和 1.965%; 预测的 RMSE 为  $1.248 \times 10^3$  kW, 在 4 种模型中也是最低的, ADQPSO-SVR 的预测效果最佳。




图 2 4 种模型的风电功率预测曲线

Fig. 2 Wind power prediction curves of four models

表 3 4 种模型预测的 MAPE 和 RMSE

Tab. 3 MAPE and RMSE of four models predictions

评价指标	PSO-SVR	GA-SVR	QPSO-SVR	ADQPSO-SVR
$e_{MAPE}/\%$	14.015	14.774	12.309	10.344
$e_{RMSE}/MW$	1.995	2.077	1.599	1.248

图 3 是 4 种模型预测结果的 24 个 RPE 指标, 表 4 是 RPE 指标的分布情况。由图 3 和表 4 可知, 在 24 个预测点中, ADQPSO-SVR 得到的 23 个点的 RPE 值小于 20%, 且 RPE 值大于 30% 的个数为 0, 这表明 ADQPSO-SVR 模型的预测稳定性最好。

综上可知, 使用 ADQPSO 算法优化选择 SVR






图 3 4 种模型预测的 RPE

Fig. 3 RPE of four models predictions

表 4 4 种模型预测的 RPE 分布情况

Tab. 4 The RPE distribution of four models predictions

模型	位于各误差区间的预测点个数			
	<5%	5%~20%	20%~30%	>30%
PSO-SVR	4	14	4	2
GA-SVR	4	14	5	1
QPSO-SVR	4	17	3	0
ADQPSO-SVR	4	19	1	0

的学习参数,使得 ADQPSO-SVR 模型具有更好的预测能力和泛化性能,可有效提高风电功率预测的准确性,降低预测误差,且模型的预测稳定性更好。

#### 4.4 模型预测效果对比分析

为进一步验证 ADQPSO-SVR 模型在短期风电功率预测中的有效性,使用较常用的 BPNN 和 RBFNN 方法建立预测模型,预测步长和预测点数同前文所述的 SVR 模型保持一致。

对 3 种模型分别独立运行 20 次,预测结果如表 5 所示。图 4 是 3 种模型预测的最好 MAPE 所对应的 24 个 RPE 指标,表 6 为相应 RPE 指标的分布情况。由表 5 可知,ADQPSO-SVR 预测得到的最好 MAPE 较 BPNN 和 RBFNN 分别降低了 4.828% 和 3.915%;预测的最好 RMSE 则分别减少了 853 kW 和 808 kW;20 次运行中的预测偏差较其他 2 种模型也明显偏小。因此,ADQPSO-SVR 的预测效果优于 BPNN 和 RBFNN。

对比分析图 4 和表 6 可知,BPNN 和 RBFNN 预测的最大 RPE 分别为 41.060% 和 38.208%,而 ADQPSO-SVR 的最大 RPE 仅为 22.327%。在 24 个

表 5 3 种模型的预测结果

Tab. 5 The prediction results of three models

评价指标	模型	最好值	最差值	平均值	偏差/%
$e_{MAPE}/\%$	1	15.242	17.209	16.459	12.905
	2	14.329	15.801	15.048	10.273
	3	10.414	11.046	10.786	6.069
$e_{RMSE}/MW$	1	2.111	2.398	2.245	13.595
	2	2.066	2.309	2.150	11.762
	3	1.258	1.373	1.314	9.141

注:模型 1 为 BPNN 模型;模型 2 为 RBFNN 模型;模型 3 为 ADQPSO-SVR 模型。




图 4 3 种模型预测的 RPE

Fig. 4 RPE of three models predictions

表 6 3 种模型预测的 RPE 分布情况

Tab. 6 The RPE distribution of three models predictions

模型	位于各误差区间的预测点个数			
	<5%	5%~20%	20%~30%	>30%
BPNN	5	11	6	2
RBFNN	5	13	4	2
ADQPSO-SVR	4	19	1	0

预测点中,ADQPSO-SVR 有近 80% 预测点的 RPE 值在 5%~20% 之间,比例明显高于其他 2 种模型;且 RPE 值大于 30% 的个数为 0,而 BPNN 和 RBFNN 各有 2 个点。

上述对比分析表明:SVR 模型基于结构风险最小化原则,较 BPNN 和 RBFNN 具有更好的泛化性能;同时,使用 ADQPSO 算法优化选择学习参数,又可以有效提高 SVR 模型的预测精度。因此,相对于 BPNN 和 RBFNN 模型,ADQPSO-SVR 模型具有更高的预测精度和更好的预测稳定性。

## 5 结论

1) 本文在 QPSO 算法中加入自适应早熟判定准则、BDO 和 DECC,提出了 ADQPSO 算法,并将其应用于 SVR 学习参数的优化选择。和其他 3 种算法的对比研究表明,ADQPSO 算法具有全局优化能力强、鲁棒性好和计算耗时短的优点;构建的 ADQPSO-SVR 模型具有更强的泛化能力,可有效提高短期风电功率预测的准确性。

2) 短期风电功率预测实例表明,与 BPNN 和 RBFNN 相比,本文提出的 ADQPSO-SVR 能够实现较高的预测精度和较好的预测稳定性,验证了 ADQPSO-SVR 模型的正确性和先进性。

3) 在使用 ADQPSO 算法优化选择 SVR 学习参数时,算法计算耗时能够满足短期风电功率预测的要求,ADQPSO-SVR 模型在工程上具有可行性。

## 参考文献

- [1] Chen Daojun, Gong Qingwu, Zou Bichang, et al. A low-carbon dispatch model in a wind power integrated system considering wind speed forecasting and energy-environmental efficiency[J]. Energies,

- 2012, 5(4): 1245-1270.
- [2] 石文辉, 陈静, 王伟胜. 含风电场的互联发电系统可靠性评估[J]. 电网技术, 2012, 36(2): 224-230.
- Shi Wenhui, Chen Jing, Wang Weisheng. Reliability assessment of interconnected generation systems with grid-connected wind farms [J]. Power System Technology, 2012, 36(2): 224-230(in Chinese).
- [3] 潘迪夫, 刘辉, 李燕飞. 基于时间序列分析和卡尔曼滤波算法的风电场风速预测优化模型[J]. 电网技术, 2008, 32(7): 82-86.
- Pan Difu, Liu Hui, Li Yanfei. A wind speed forecasting optimization model for wind farms based on time series analysis and Kalman filter algorithm[J]. Power System Technology, 2008, 32(7): 82-86(in Chinese).
- [4] 孟洋洋, 卢继平, 孙华利, 等. 基于相似日和人工神经网络的风电功率短期预测[J]. 电网技术, 2010, 34(12): 163-167.
- Meng Yangyang, Lu Jiping, Sun Huali, et al. Short-term wind power forecasting based on similar days and artificial neural network[J]. Power System Technology, 2010, 34(12): 163-167(in Chinese).
- [5] 丁明, 张立军, 吴义纯. 基于时间序列分析的风电场风速预测模型[J]. 电力自动化设备, 2005, 25(8): 32-34.
- Ding Ming, Zhang Lijun, Wu Yichun. Wind speed forecast model for wind farms based on time series analysis[J]. Electric Power Automation Equipment, 2005, 25(8): 32-34(in Chinese).
- [6] 杨琦, 张建华, 王向峰, 等. 基于小波-神经网络的风速及风力发电量预测[J]. 电网技术, 2009, 33(17): 44-48.
- Yang Qi, Zhang Jianhua, Wang Xiangfeng, et al. Wind speed and generated wind power forecast based on wavelet-neural network[J]. Power System Technology, 2009, 33(17): 44-48(in Chinese).
- [7] 陈宁, 沙倩, 汤奕, 等. 基于交叉熵理论的风电功率组合预测方法[J]. 中国电机工程学报, 2012, 32(4): 29-34.
- Chen Ning, Sha Qian, Tang Yi, et al. A combination method for wind power prediction based on cross entropy theory[J]. Proceedings of the CSEE, 2012, 32(4): 29-34(in Chinese).
- [8] Kramer O, Gieseke F. Short-term wind energy forecasting using support vector regression[C]//IEEE International Conference on Soft Computing Models in Industrial and Environmental Applications, Salamanca, Spain: IEEE, 2011: 271-280.
- [9] 叶林, 刘鹏. 基于经验模态分解和支持向量机的短期风电功率组合预测模型[J]. 中国电机工程学报, 2011, 31(31): 102-108.
- Ye Lin, Liu Peng. Combined model based on EMD-SVM for short-term wind power prediction[J]. Proceedings of the CSEE, 2011, 31(31): 102-108(in Chinese).
- [10] 高昆伦, 刘建明, 徐茹枝, 等. 基于支持向量机和粒子群算法的信息网络安全态势复合预测模型[J]. 电网技术, 2011, 35(4): 176-182.
- Gao Kunlun, Liu Jianming, Xu Ruzhi, et al. A hybrid security situation prediction model for information network based on support vector machine and particle swarm optimization[J]. Power System Technology, 2011, 35(4): 176-182(in Chinese).
- [11] Sun Chengfu, Lu Songfeng. Short-term combined economic emission hydrothermal scheduling using improved quantum-behaved particle swarm optimization[J]. Expert Systems with Applications, 2010, 37(6): 4232-4241.
- [12] Sun J, Fang W, Xu W B. A quantum-behaved particle swarm optimization with diversity-guided mutation for the design of two-dimensional IIR digital filters[J]. IEEE Transactions on Circuits and Systems II-Express Briefs, 2010, 57(2): 141-145.
- [13] Vapnik V. The nature of statistical learning theory[M]. New York: Springer-Verlag, 1995: 138-170.
- [14] Mohandes M A, Halawani T O, Rehman S, et al. Support vector machines for wind speed prediction[J]. Renewable Energy, 2004, 29(6): 939-947.
- [15] Bergh V D, Engelbrecht A P. A study of particle swarm optimization particle trajectories[J]. Information Sciences, 2006, 176(8): 937-971.
- [16] Sun J, Xu W B, Feng B. A global search strategy of quantum-behaved particle swarm optimization[C]//IEEE Conference on Cybernetics and Intelligent Systems. Singapore, Singapore: IEEE, 2004: 111-116.
- [17] 龙海侠, 须文波, 王小根, 等. 基于选择操作的量子粒子群算法[J]. 控制与决策, 2010, 25(10): 1499-1506.
- Long Haixia, Xu Wenbo, Wang Xiaogen, et al. Using selection to improve quantum-behaved particle swarm optimization[J]. Control and Decision, 2010, 25(10): 1499-1506(in Chinese).
- [18] Wu Q. Hybrid forecasting model based on support vector machine and particle swarm optimization with adaptive and Cauchy mutation[J]. Expert Systems with Applications, 2011, 38(8): 9070-9075.
- [19] 王小根, 龙海侠, 孙俊. 基于高斯扰动的量子粒子群优化算法[J]. 计算机应用研究, 2010, 27(6): 2093-2096.
- Wang Xiaogen, Long Haixia, Sun Jun. Quantum-behaved particle swarm optimization based on Gaussian disturbance[J]. Application Research of Computers, 2010, 27(6): 2093-2096(in Chinese).
- [20] 刘刚, 彭春华, 相龙阳. 采用改进型多目标粒子群算法的电力系统环境经济调度[J]. 电网技术, 2011, 35(7): 139-144.
- Liu Gang, Peng Chunhua, Xiang Longyang. Economic-environmental dispatch using improved multi-objective particle swarm optimization[J]. Power System Technology, 2011, 35(7): 139-144(in Chinese).



陈道君

收稿日期: 2012-07-15.

## 作者简介:

陈道君(1986), 男, 博士研究生, 研究方向为风电并网运行调度, E-mail: chendaojun@whu.edu.cn;

龚庆武(1967), 男, 教授, 博士生导师, 研究方向为电力系统运行与控制、电力系统仿真、风力发电并网运行与控制等;

金朝意(1987), 男, 硕士, 研究方向为风电并网运行调度;

张静(1990), 女, 硕士研究生, 研究方向为风电场风电功率预测;

王定美(1984), 男, 工程师, 研究方向为风电并网技术。

(责任编辑 杜宁)