

基于混沌时间序列 GA-VNN 模型的 超短期风功率多步预测

江岳春¹, 张丙江¹, 邢方方¹, 张雨¹, 王志刚²

(1. 湖南大学 电气与信息工程学院, 湖南省 长沙市 410082;

2. 国网河南省电力公司 驻马店供电公司, 河南省 驻马店市 463000)

Super-Short-Term Multi-Step Prediction of Wind Power Based on GA-VNN Model of Chaotic Time Series

JIANG Yuechun¹, ZHANG Bingjiang¹, XING Fangfang¹, ZHANG Yu¹, WANG Zhigang²

(1. School of Electrical and Information Engineering, Hunan University, Changsha 410082, Hunan Province, China;

2. Zhumadian Power Supply Company, State Grid Henan Electric Power Company, Zhumadian 463000, Henan Province, China)

ABSTRACT: As wind power penetration in power system increases continuously, a good prediction method is essential to providing accurate and reliable results. In order to improve the wind power prediction accuracy, a super-short-term wind power prediction model is proposed based on genetic algorithm-Volterra neural network (GA-VNN) model using the chaos characteristic of wind power time series, mathematically deducing and analyzing the consistency between Volterra functional model and back propagation(BP) neural network in structure. The practicable Volterra functional model and BP neural network are combined together, learning the advantages of both, overcoming the difficulty in obtaining the high order kernel function of Volterra functional model, and designing a learning algorithm of the GA-VNN model of chaotic time series, in which BP neural network is optimized by utilizing the global optimization of GA algorithm to obtain the best initial weights and thresholds. The GA-VNN model of chaotic time series is applied to the super-short-term multi-step prediction of wind power, and the experimental results show that its estimated performance is obviously superior to both Volterra filter model and BP neural network and satisfactory results are achieved.

KEY WORDS: chaotic time series; BP neural network; GA algorithm; Volterra functional model; super short-term wind power multi-step prediction

摘要: 随着风电在电力系统中的渗透水平不断提高,能准确、可靠地进行风功率预测至关重要。为提高风功率超短期预测

精度,利用风功率时间序列的混沌特性,推导分析了 Volterra 泛函模型和 3 层前馈(back propagation, BP)神经网络在结构上的一致性,提出混沌时间序列遗传算法-Volterra 神经网络(genetic algorithm-Volterra neural network, GA-VNN)模型,对超短期风功率进行多步预测。该模型将实用的 Volterra 泛函模型和 BP 神经网络结合起来,解决了求解 Volterra 泛函模型高阶核函数的问题。同时设计了一种混沌时间序列 GA-VNN 模型的学习算法,在算法中利用 GA 全局寻优能力来优化 BP 神经网络,获得最优的初始权值和阈值。将上述方法应用于某风电场风功率超短期多步预测中,结果验证了所提模型的多步预测性能明显优于 Volterra 预测滤波器和 BP 神经网络。

关键词: 混沌时间序列; BP 神经网络; GA 算法; Volterra 泛函模型; 风功率超短期多步预测

DOI: 10.13335/j.1000-3673.pst.2015.08.015

0 引言

风能具有间歇性、随机性和不确定性等特点,风电并网对电网安全稳定运行带来诸多挑战,严重影响了电力系统经济调度和功率平衡^[1-2]。同时,微网中风功率预测误差影响储能设备容量的配置^[1],进而影响储能设备的投资。因此,提高风功率预测精度对电力系统安全稳定以及提高发电的经济效益至关重要。

目前,预测技术分为有 2 种:统计建模技术和物理建模技术^[2],前者主要基于风电场输出功率的时间序列来进行短期预测(不超过 30 min);后者以数值天气预报(numerical weather prediction, NWP)为输入,通过根据功率曲线预测功率输出来预测短期风功率(一般为 30 min~72 h),考虑因素复杂,受

基金项目: 国家自然科学基金项目(51277057); 科技部技术创新项目(12C26214305038)。

Project Supported by National Natural Science Foundation of China(51277057).

主观因素影响,准确预测较困难。预测的方法有自回归滑动平均模型法(auto regressive moving average, ARMA)^[3]、卡尔曼滤波法^[4]和人工神经网络方法^[5-6]、小波分析法^[7]和支持向量机法(support vector machine, SVM)^[8]等智能方法。由于方法单一且受主观因素影响较多而影响预测效果。此外还有改进的组合预测方法^[7-8],由于结合了几种方法的优点,有较好的预测效果。实践证明,组合式的预测方法效果好于单一预测方法,预测精度较高。

已有文献证明风功率具有混沌属性^[9-12],但针对基于混沌时间序列建模进行风电功率预测的研究却较少。由混沌理论可知,混沌信号经相空间重构会得到一个嵌入空间的低维流形,利用其可对重构的轨迹进行预测^[10]。另外,理论研究和实践证明,Volterra 泛函模型可表征大部分非线性系统,对混沌时间序列可进行精确预测,目前成为国内外研究人员进行风功率泛函系统辨识研究的重要方法^[11]。很多学者提出了预测风功率的 Volterra 泛函模型^[10-13],取得了较高的预测精度。然而,高阶 Volterra 核函数的求解是其应用的瓶颈。BP 神经网络可以进行非线性统计性数据建模来逼近任意非线性函数,具有自适应性、并行性和容错性等特点^[2,5],因此被广泛应用于非线性系统^[14-17]。但是,BP 神经网络预测结果往往陷入局部极小点,使训练获得的网络非最优。为克服这一缺陷,采用经遗传算法优化的神经网络,可大大提高其自适应性和鲁棒性^[18-19]。基于以上分析,本文首先证明 BP 神经网络模型和 Volterra 泛函模型在结构上的数学等价关系;然后结合风功率混沌时间序列特性,建立混沌时间序列 GA-VNN 模型进行风功率超短期多步预测,并提出一种针对该模型的 GA 优化算法;最后通过实例验证该模型在风功率超短期多步预测方面的优越性能。

1 风功率混沌时间序列 Volterra 预测模型

1.1 风功率混沌时间序列的相空间重构

对风功率时间序列进行相空间重构是建立风功率混沌时间序列 GA-VNN 模型不可缺少的重要步骤。Takes 等人提出的采用延时坐标的方法进行相空间重构,要求选取合适的嵌入空间维数 m 和延迟时间 τ 。由 Takes 定理可知,当嵌入维数 $m > 2d + 1$ (d 为系统动力学维数)时,重构的动力系统和原动力系统在拓扑意义上等价。本文采用 C-C 方法^[13]求解嵌入维数 m 和时延。

1.2 非线性系统的 Volterra 泛函实用模型

对于非线性系统,离散化 Volterra 泛函模型为

$$y(k) = \sum_{i=1}^k \sum_{l_1, l_2, \dots, l_i}^{\infty} h_i(l_1, l_2, \dots, l_i) x(k-l_1) \cdot x(k-l_2) \cdots x(k-l_i) \quad (1)$$

式中: $i, l_i, k \in \mathbf{R}$; $x(k-l_i)$ 表示系统输入; $y(k)$ 表示系统输出; $h_i(l_1, l_2, \dots, l_i)$ 为 i 阶 Volterra 核函数。理论上,式(1)可实现对风功率的精确预测。实际应用中,求解高阶核函数十分困难,通常对 Volterra 泛函模型进行二阶或三阶截断,但这会大大降低预测精度和性能^[5,10,16]。另外,Volterra 泛函系统具有有限的记忆性能,在离 k 很远的时间点 $k-k_0$ 处,当 k_0 很大时,输入 $x(k-k_0)$ 对输出不产生影响,故本文采用的实用 Volterra 泛函模型为

$$y(k) = h_0 + \sum_{l_1=0}^{m-1} h_1(l_1) x(k-l_1\tau) + \sum_{l_1=0}^{m-1} \sum_{l_2=0}^{m-1} h_2(l_1, l_2) x(k-l_1\tau) x(k-l_2\tau) + \cdots + \sum_{l_1=0}^{m-1} \sum_{l_2=0}^{m-1} \cdots \sum_{l_m=0}^{m-1} h_m(l_1, l_2, \dots, l_m) x(k-l_1\tau) x(k-l_2\tau) \cdots x(k-l_m\tau) \quad (2)$$

式中: m 表示系统的记忆长度,即风功率混沌时间序列重构相空间的最小嵌入维数(通常取值不大); τ 表示延迟时间。此时,Volterra 泛函模型完全可以实现对风功率的精确预测。对于不同的风功率,时间序列 m 是不同的,这也体现了所建模型的动态性和适应性,保证了预测精度。

2 风功率混沌时间序列 GA-VNN 模型的建模

2.1 BP 神经网络与 Volterra 泛函模型的等价性

首先,建立 m 维输入、单隐层和单输出的 BP 神经网络,如图 1 所示。输入向量为 $\mathbf{X}^T(k) = [x_{k,0}, x_{k,1}, \dots, x_{k,n}, \dots, x_{k,m-1}]$,由 $x(k)$ 延时得到,其中 $x_{k,n} = x(k-n)$, ($k=1, 2, \dots, m$)。隐含层第 l 个单元输出为

$$Z_{l,k} = S_l(U_{l,k}), \quad l=1, 2, \dots, L \quad (3)$$

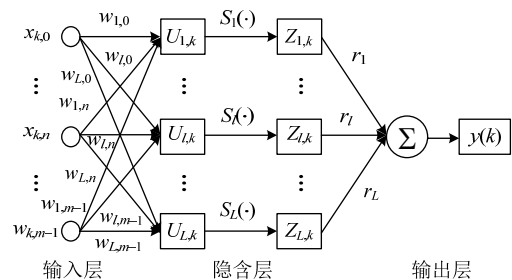


图1 对应 m 维输入、单输出的三层神经网络模型
Fig. 1 Three layer neural networks in response to m input and single output system

$U_{l,k}$ 表示系统输入序列的离散卷积, 表达式为

$$U_{l,k} = \sum_{n=0}^{m-1} w_{l,n} x_{k,n} \quad (4)$$

$S_l(\cdot)$ 为激励函数, 取 Sigmoid 函数, 即有

$$S_l(U_{l,k}) = \frac{1}{1 + \exp(-\lambda(U_{l,k} - \theta_l))} \quad (5)$$

式中: $w_{l,n}$ 和 r_l 分别表示隐含层和输出层的网络权值; θ_l 表示第 l 个单元的偏移量; λ 是固定值, 表示从输入层到隐含层的传递斜率。将隐含层的各个输出在阈值 θ_l 处展开成 Taylor 级数, 表达式为

$$Z_{l,k} = S_l(U_{l,k}) = \sum_{i=0}^{\infty} d_i(\theta_l)(U_{l,k})^i \quad (6)$$

式中 $d_i(\theta_l)$ 为展开后的各项系数, 它随着偏移阈值 θ_l 的变化而变化, 与激励函数有关。输出层用线性求和的形式表示, 则 BP 神经网络的输出表示式为

$$y(k) = \sum_{l=1}^L r_l Z_{l,k} = \sum_{l=1}^L r_l \left[\sum_{i=0}^{\infty} d_i(\theta_l) U_{l,k}^i \right] = \sum_{l=1}^L r_l \sum_{i=0}^{\infty} d_i(\theta_l) \cdot \sum_{n_1=0}^{m-1} \dots \sum_{n_i=0}^{m-1} [w_{l,n_1} \dots w_{l,n_i} x_{k,n_1} \dots x_{k,n_i}] \quad (7)$$

另一方面, 如果将 Volterra 核函数以基函数 $\{b_n(z)\}$ 的形式展开, 由实用 Volterra 泛函模型式(2)可得到变形后 Volterra 泛函模型, 如图 2 所示。

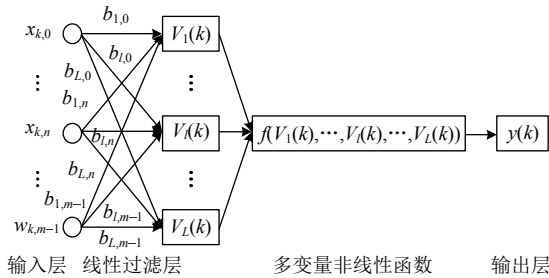


图 2 经过变形后 Volterra 级数模型

Fig. 2 Series Volterra model after deformation

图 2 中的 $V_l(k)$ 为输入序列的加权和, 即离散卷积:

$$V_l(k) = \sum_{z=0}^{m-1} b_{l,z} x_{k,z} \quad (8)$$

再将系统输出表示成一个多项式展开序列:

$$y(k) = f(V_1(k), \dots, V_L(k)) = c_0 + \sum_{l_0=0}^{m-1} c_1(l_0) V_1(k) + \sum_{l_1=0}^{m-1} \sum_{l_2=0}^{m-1} c_2(l_1, l_2) \cdot V_1(k) V_2(k) + \dots + \sum_{l_1=0}^{m-1} \sum_{l_2=0}^{m-1} \dots \sum_{l_m=0}^{m-1} c_m(l_1, l_2, \dots, l_m) \cdot V_1(k) V_2(k) \dots V_m(k) \quad (9)$$

式中 $c_m(l_1, l_2, \dots, l_m)$ 表示多项式系数, 若选择适当的 $b_{l,z}$, 使 $f(V_1(k), \dots, V_L(k))$ 的各项系数和核函数足够相逼近, 那么 Volterra 级数中的核函数可近似表达为

$$\begin{cases} h_1(z) = \sum_{l=0}^{m-1} c_1(l) b_{l,z} \\ h_2(z_1, z_2) = \sum_{l_1=0}^{m-1} \sum_{l_2=0}^{m-1} c_2(l_1, l_2) b_{l_1,z_1} b_{l_2,z_2} \\ \vdots \end{cases} \quad (10)$$

由式(4)(8)可看出, 它们都存在隐含变量 ($U_{l,k}, V_l(k)$) 且都是输入序列的离散卷积。若找到实用 Volterra 泛函模型中的基函数 $\{b_n(z)\}$, 式(9)就可利用 Sigmoid 函数线性叠加表示, 即有

$$f(V_1(k), \dots, V_L(k)) = \sum_{l=1}^L r_l S_l(V_l(k)) \quad (11)$$

比较式(7)(11)可以看出, Volterra 泛函模型和 BP 神经网络存在等量关系, 两者模型完全吻合。当多变量函数由单变量函数 $\{g_l(V_l(k))\}$ 线性叠加时, 表达式为

$$f(V_1(k), \dots, V_L(k)) = r_1 g_1(V_1(k)) + \dots + r_l g_l(V_l(k)) + \dots + r_L g_L(V_L(k)) \quad (12)$$

式中单变量函数 $\{g_l(V_l(k))\}$ 可用任意形式表示。

2.2 风功率混沌时间序列 GA-VNN 模型

在 2.1 节中推导分析了 3 层 BP 神经网络和实用 Volterra 泛函模型数学模型的等价性。基于此, 提出风功率混沌时间序列 GA-VNN 模型, 如图 3 所示。模型中, 输入向量取风功率混沌时间序列重构相空间向量 $\mathbf{X}^T = [x(k), x(k+\tau), \dots, x(k+(m-1)\tau)]$ 。 $V_l(k)$ 为风功率输入信号的卷积, 表达式为

$$V_l(k) = \sum_{j=0}^{m-1} w_{l,j} x(k+j\tau) \quad (13)$$

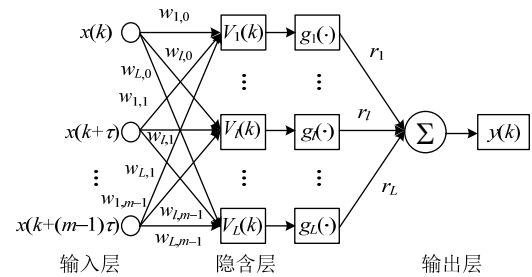


图 3 风功率混沌时间序列的 Volterra 神经网络模型

Fig. 3 Volterra neural network model of wind power chaotic time series

模型中激励函数 $g_l(\cdot)$ ($l=1, 2, \dots, L$) 选用多项式函数, 表达式为

$$g_l(\cdot) = a_{0,l} + a_{1,l}x + a_{2,l}x^2 + \dots + a_{i,l}x^i + \dots \quad (14)$$

式中 $a_{i,l} \in \mathbf{R}$ 为多项式系数。进一步可以得出混沌时间序列 GA-VNN 模型的输出为

$$y(k) = \sum_{l=1}^L r_l g_l(V_l(k)) = \sum_{l=1}^L \sum_{i=0}^{\infty} r_l a_{i,l} (V_l(k))^i = \sum_{l=1}^L \sum_{i=0}^{\infty} r_l a_{i,l} \left(\sum_{j=0}^{m-1} w_{l,j} x(k+j\tau) \right)^i \quad (15)$$

则第 i 阶的 Volterra 级数核表示为

$$h_i(z_1, z_2, \dots, z_i) = \sum_{l=1}^L r_l a_{i,l} w_{l,z_1} w_{l,z_2} \dots w_{l,z_i} \quad (16)$$

训练图 3 的网络结构, 在求得网络权值 $w_{l,n}$ 、 r_l 和阈值 θ_l 后, 对 $\{g_l(V_l(k))\}$ 在阈值处进行 Taylor 级数分解, 根据式(16)求得模型各阶核函数。

3 风功率混沌时间序列 GA-VNN 模型学习算法

该首先利用 C-C 算法求取相空间重构时的最优时延 t 和嵌入窗 τ_w , 根据嵌入窗时间公式 $\tau_w = (m-1)\tau$ 求出嵌入维数 m 。再根据 Wolf 法或小数据量法计算风电功率序列的最大 Lyaunov 指数, 根据其值的正负判断该风电功率时间序列是否具有混沌属性。若具有混沌属性, 则对其进行相空间重构。其次, 确定输入层、单隐层和输出层的 3 层风功率 Volterra 神经网络结构。输入层神经元的个数取混沌时间序列的嵌入维数 m ; 用灰色关联分析法确定隐含层神经元个数 L ; 输出层为单输出层, 即输出层神经元个数为 1, 建立一个结构为 $m-L-1$ 的混沌时间序列 GA-VNN 模型。最后, 利用混沌时间序列 GA-VNN 模型学习算法对未来风功率预测, 流程图如图 4 所示。具体步骤为:

1) 根据求得的延迟时间 τ 和嵌入维数 m , 通过相空间重构可以得到 $N = n - 1 - (m-1)\tau$ 个相空间向量, 取前 N' 相空间向量为输入向量, 即 $\mathbf{X}^T = [x(k), x(k+\tau), \dots, x(k+(m-1)\tau)], (k=1, 2, \dots, N')$ 。对

输入向量采用归一化处理, 将数据映射到 $[0,1]$ 之间。

2) 由图 3 可知, 该 $m-L-1$ 结构的 GA-VNN 模型得输入向量为 \mathbf{X}^T , 输出层为 $y(k)$, 其隐含层的权值系数矩阵和输出层的权值系数分别为 $\mathbf{W} = (w_{l,j})_{L \times m} (j=1, 2, \dots, m)$ 、 r_l 。

3) 利用 GA 优化风功率混沌时间序列 GA-VNN 模型中的网络参数, 其具体步骤为: 首先, 对网络参数包括输入层与隐含层的连接权值、隐含层的阈值、隐含层和输出层的连接权值以及输出层的阈值进行实数编码构成染色体, 确定种群规模。其次, 选定适应度函数 $F = k(e(k+1) - \tilde{x}(k+1))$ 。其中, $e(k+1)$ 表示期望输出, $\tilde{x}(k+1)$ 表示预测输出。然后, 进行选择、交叉、变异操作产生新一代种群。最后, 计算新一代种群的适应度值, 直至满足条件 $|F_{l+1} - F_l| < \varepsilon$ (l 为第 l 次迭代, ε 取 0.1), 则获得最优的初始权值和阈值; 否则, 返回上步直至满足结束条件。

4) 利用步骤 1)、2)、3) 中获得的数据, 利用式(15)对风功率混沌时间序列 GA-VNN 模型进行第 1 次网络计算。

5) 计算目标误差函数 E , 表达式为

$$E = \frac{1}{2} \sum_{k=1}^{N'} (y(k) - \tilde{y}(k))^2 \quad (17)$$

式中: $y(k)$ 为真实值; $\tilde{y}(k)$ 为估计值。最大目标误差 E_{\max} 设为 0.025, 若 $E < E_{\max}$, 则停止计算, 并存储网络训练权值系数矩阵 $\mathbf{W} = (w_{l,j})_{L \times m}$ 和权值系数 r_l 。结合多项式系数 $a_{i,l} (i=1, 2, \dots, m)$ 计算并存储各阶核函数 $h_i(l_1, l_2, \dots, l_i)$; 否则, 进入下一步。

6) 分别计算混沌时间序列 GA-VNN 模型的局部梯度 $\delta_l(k)$ 和网络权值参数的修正量 $\Delta w_{l,j}(k)$, 计算公式为

$$\delta_l(k) = -\frac{\partial E}{\partial y(k)} g'_l(V_l(k)) \quad (18)$$

$$\Delta w_{l,j}(k) = \alpha \Delta w_{l,j}(k-1) + \eta \delta_l(k) y(k) \quad (19)$$

式中: $\alpha \Delta w_{l,j}(k-1)$ 表示引入的动向量, $0 < \alpha < 1$; η 表示学习步长。

7) 修正网络权值并再次训练网络, 计算出网络输出 $\tilde{y}(k)$ 和目标误差 E , 反复训练, 直至满足 $E < E_{\max}$, 训练完毕, 存储权值系数矩阵 $\mathbf{W} = (w_{l,j})_{L \times m}$, 并将 $\{g_l(V_l(k))\}$ 在阈值 θ_l 处进行 Taylor 级数分解, 就可以得到 Taylor 展开式的系数 $d_i(\theta_l)$, 因为 $\{g_l(V_l(k))\}$ 取多项式形式, 所以 $d_i(\theta_l) = a_{i,l}$, 将系数代入式(16)就可以得到系统的各阶核函数。

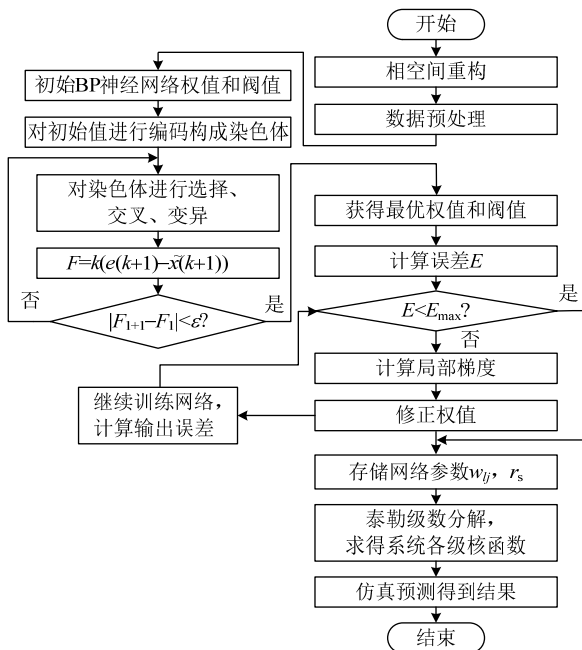


图 4 混沌时间序列 GA-VNN 学习算法流程图

Fig. 4 Learning algorithm flow chart of GA-VNN model of chaotic time series

8) 利用 Volterra 级数的各级核函数, 对风功率混沌时间序列进行预测。

4 算例结果与分析

某风电场包含 58 台 G58-850 kW 机组, 总装机容量为 49.3 MW。图 5 为 2014 年 2 月 1 日—2014 年 2 月 26 日发电功率时间序列, 每 15 min 采样一次, 共 2 496 个数据。由 C-C 法对风电功率时间序列进行相空间重构, 计算得出最优延迟时间 $\tau=12$; 延迟时间窗口 $\tau_w=62$ 。根据嵌入窗时间公式 $\tau_w=(m-1)\tau$ 求出嵌入维数 $m=6$ 。采用小数据量法计算风功率时间序列的最大 Lyapunov 指数, 计算得 0.018 4。由混沌理论可知, 风电功率序列的最大 Lyapunov 指数为正值, 也验证了风电功率时间序列具有混沌属性的结论。对其重构得相空间向量共 $N=n-1-(m-1)\tau=2\,435$ 个。




图 5 风力发电功率时间序列
Fig. 5 Time series of wind power

为了衡量风功率预测模型性能, 首先引入一个重要概念即多步预测, 多步预测在提前预警、宏观决策和电能调度计划等方面具有较高的利用价值。风功率时间预测序列的多步预测是指, 只利用现有的 N 个风功率数据样本, 除了单步预测第 $N+1$ 个值外, 也可以预测第 $N+2, N+3, \dots, N+T$, $T>0$ 为预测步数。

本实验利用 3 种预测模型对风功率分别进行 2 步、4 步和 6 步预测。具体过程是: 首先, 从重构得到的 2 435 个相空间向量中选取前 2 350 个向量作为训练样本, 训练风功率目标值取第 k 个风功率数据到第 $k+2\,349$ 个风功率数据, 其中 k 取 63、65、67, 训练完毕分别存储网络参数; 然后, 用混沌时间序列 GA-VNN 模型、2 阶 Volterra 滤波器模型和 BP 神经网络对风功率分别进行 $T=2, 4, 6$ 步预测, T 步预测的风功率取值为第 $T+2\,411$ 到样本结束的第 2 496 个数据, 其预测结果以及与真实值的误差结果分别如图 6—8 所示; 最后, 为了量化分析比较多步预测时的预测精度, 本文采用归一化绝对平均误差 e_{NMAE} 和归一化均方根误差 e_{NRMAE} , 它们的表达式为

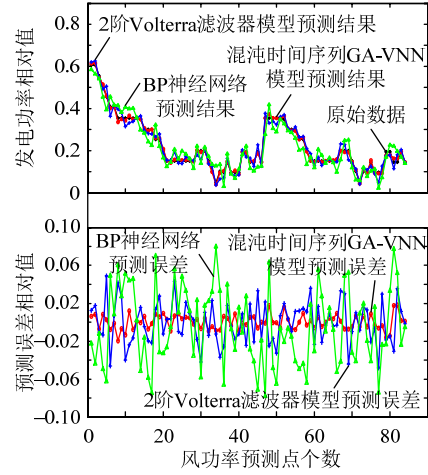


图 6 风电场风功率 2 步预测及误差
Fig. 6 Curves of 2-step wind power prediction results and error




图 7 风电场风功率 4 步预测及误差
Fig. 7 Curves of 4-step wind power prediction results and error




图 8 风电场风功率 6 步预测及误差
Fig. 8 Curves of 6-step wind power prediction results and error

$$e_{\text{NMAE}} = \frac{1}{P_{\text{cap}}} \frac{1}{N} \sum_{i=1}^N |\tilde{y}(k) - y(k)| \quad (18)$$

$$e_{\text{NRMAE}} = \frac{1}{P_{\text{cap}}} \sqrt{\frac{1}{N} \sum_{i=1}^N (\tilde{y}(k) - y(k))^2} \quad (19)$$

式中： N 为预测点个数； P_{cap} 为风机的额定容量。

分别计算图 6—8 中 3 种预测模型的归一化绝对平均误差和归一化均方根误差，结果见表 1。由表 1 可知，风功率混沌时间序列多步预测时，对于同一预测步数，混沌时间序列 GA-VNN 模型的归一化绝对平均误差、归一化均方根误差和最大相对误差最小，而 BP 神经网络 3 个指标最大；同时，随着预测步数的增加，由图 6—8 的预测误差图以及表 1 中对于同一预测模型、同一性能指标不同步数的大小比较可知，风功率混沌时间序列同一预测模型的 2 步预测结果要好于 4 步预测结果；4 步预测结果要好于 6 步预测结果。因此可以看出，对于同一预测模型，随着预测步数的增加，其预测性能也会不断下降。

表 1 3 种风功率模型多步预测归一化后误差性能比较
Tab. 1 Wind power multi-step prediction error comparison of three different prediction methods

预测步数	预测方法	e_{NMAE}	e_{NRMAE}	最大相对误差
2	混沌时间序列 GA-VNN 模型预测	0.523 6	0.007 627	0.019 520
	2 阶 Volterra 滤波器预测	1.567 0	0.022 180	0.048 800
	BP 神经网络预测	2.961 0	0.041 230	0.079 740
4	混沌时间序列 GA-VNN 模型预测	1.123 0	0.015 610	0.037 680
	2 阶 Volterra 滤波器预测	3.068 0	0.039 970	0.067 520
	BP 神经网络预测	4.717 0	0.060 570	0.095 050
6	混沌时间序列 GA-VNN 模型预测	1.877 0	0.025 340	0.049 070
	2 阶 Volterra 滤波器预测	3.714 0	0.049 670	0.084 490
	BP 神经网络预测	6.722 0	0.091 420	0.193 700

通过比较 3 种模型在风功率多步预测原理方面的差异，可以进一步探究产生这种差异的因素。BP 神经网络是通过训练初始样本进行未来预测，影响其预测精度和准确度的重要原因是其变量选择的主观性和盲目性，从而导致加入多余不相关变量或忽略重要变量。另外，BP 神经网络的静态性很容易使其陷入局部极小点，所以其预测效果最差，训练时间也最长。Volterra 滤波器本质上是利用风功率时间序列的混沌特性，通过拟合训练混沌吸引子轨道来预测非线性系统，通过线性二阶 Volterra 滤波器的乘积耦合方式来实现，故同时避免了因滤波器阶数较大而导致核函数求解困难和大量存在非线性耦合对滤波器系数不收敛或不稳定的影响，提高了预测精度。另外，Volterra 滤波器利用线性自适应算法调整滤波器参数，这种动态性可以提高其利用新数据预测的适应性和准确性，训练时间较短。

混沌时间序列 GA-VNN 模型将离散型的

Volterra 泛函模型和风功率时间序列的混沌属性相结合，利用风功率混沌时间序列的有限记忆性和因果性来确定 Volterra 级数的截断阶数和项数，从而实现 Volterra 级数的精确建模；并利用 BP 神经网络和 Volterra 泛函系统的等价性，解决了高阶核函数的求解问题；利用 GA 全局寻优能力优化算法以避免训练时陷入局部极小值点。总之，混沌时间序列 GA-VNN 模型综合了 Volterra 泛函模型和 BP 神经网络的优点，克服了 BP 神经网络建模时的盲目性和主观性，同时解决了求解高阶核函数的困难，从而在多步预测方面的性能优于其他 2 种模型。

但是，混沌时间序列 GA-VNN 模型也有如下不足：1) 与 2 阶 Volterra 滤波器相比，预测精度虽然高得多，但计算量要大得多，导致运行时间长，影响了预测的实用性。2) 虽然 BP 神经网络与 Volterra 泛函模型的结合解决了高阶核函数的求解问题，在实际应用中，其硬件实现却存在一定难度，且会增加预测的经济成本。

5 结论

1) 本文建立的混沌时间序列 GA-VNN 模型解决了求解 Volterra 高阶核函数的难题，实现了对超短期风功率的精确预测。在风功率多步预测方面，该模型的性能指标(归一化绝对平均误差、归一化均方根误差和最大相对误差)要好于单一的 BP 神经网络和 2 阶 Volterra 滤波器预测模型。

2) 针对混沌时间序列 GA-VNN 模型，结合风功率时间序列的混沌属性，确定了风功率输入信号的数量，使 Volterra 级数的截断项数和截断阶数都有明确的物理含义，避免了主观因素的影响以及单纯追求预测精度而造成的计算量呈指数增长现象，提高了模型的实用性。另外，混沌时间序列 GA-VNN 学习算法具有全局收敛性，大大缩减了预测时间，有较好的适应性和鲁棒性。

3) 本文基于风功率时间序列的混沌属性对其进行相空间重构，得到了模型的参数，对于负荷预测也有一定的借鉴意义。另外，为实现混沌时间序列 GA-VNN 模型的应用价值，其硬件的实现也是未来研究的重点。

参考文献

- [1] 林少伯, 韩民晓, 赵国鹏, 等. 基于随机误差的分布式光伏配网储能系统容量配置方法[J]. 中国电机工程学报, 2013, 33(4): 25-33. Lin Shaobo, Han Minxiao, Zhao Guopeng, et al. Capacity allocation of energy storage in distributed photovoltaic power system based on stochastic prediction error[J]. Proceedings of the CSEE, 2013, 33(4): 25-33(in Chinese).

- [2] 范高峰, 王伟胜, 刘纯, 等. 基于神经网络的风电功率预测[J]. 中国电机工程学报, 2008, 28(34): 118-123.
Fan Gaofeng, Wang Weisheng, Liu Chun, et al. Wind power prediction based on artificial neural network[J]. Proceedings of the CSEE, 2008, 28(34): 118-123(in Chinese).
- [3] 冬雷, 王丽婕, 郝颖, 等. 基于自回归滑动平均模型的风力发电容量预测[J]. 太阳能学报, 2011, 32(5): 617-622.
Dong lei, Wang Lijie, Hao Ying, et al. Prediction of wind power generation based on autoregressive moving average model[J]. Acta Energaie Solaris Sinica, 2011, 32(5): 617-622(in Chinese).
- [4] Bossanyi E A. Short-term wind prediction using Kalman filter[J]. Wind Engineering, 1985, 9(1): 1-8.
- [5] 刘瑞叶, 黄磊. 基于动态神经网络的风电场输出功率预测[J]. 电力系统自动化, 2012, 36(11): 19-37.
Liu Ruiye, Huang Lei. Wind power forecasting based on dynamic neural networks[J]. Automation of Electric Power Systems, 2012, 36(11): 19-37(in Chinese).
- [6] Barbounis T G, Theoharis J B. Locally recurrent neural networks for wind speed prediction using spatial correlation[J]. Information Sciences, 2007, 177(24): 5775-5797.
- [7] 王贺, 胡志坚, 陈珍, 等. 基于集合经验模态分解和小波神经网络的短期风功率组合预测[J]. 电工技术学报, 2013, 29(9): 137-144.
Wang He, Hu Zhijian, Chen Zhen, et al. A hybrid model for wind power forecasting based on ensemble empirical mode decomposition and wavelet neural networks[J]. Transactions of China Electrotechnical Society, 2013, 28(9): 137-144(in Chinese).
- [8] 叶林, 刘鹏. 基于经验模态分解和支持向量机的短期风电功率组合预测模型[J]. 中国电机工程学报, 2011, 31(31): 102-108.
Ye Lin, Liu Peng. Combined model based on EMD-SVM for short-term wind power prediction[J]. Proceedings of the CESS, 2011, 31(31): 102-108(in Chinese).
- [9] 王丽婕, 廖晓钟, 高爽, 等. 并网型大型风电场风力发电功率-时间序列的混沌属性分析[J]. 北京理工大学学报, 2007, 27(12): 1077-1080.
Wang Lijie, Liao Xiaozhong, Gao Shuang, et al. Chaos characteristics analysis of wind power generation time series for a grid connecting wind farm[J]. Transactions of Beijing Institute of Technology, 2007, 27(12): 1077-1080(in Chinese).
- [10] 张家树, 肖先赐. 混沌时间序列的 Volterra 自适应预测[J]. 物理学报, 2000, 49(3): 404-408.
Zhang Jiashu, Xiao Xianci. Prediction low-dimensional chaotic time series using Volterra adaptive filers[J]. Acta Physica Sinica, 2000, 49(3): 404-408(in Chinese).
- [11] Chatterjee A. Parameter estimation of Duffing oscillator using Volterra series and multi-tone excitation[J]. Neural Networks, 2009, 22(1): 343-347.
- [12] 张雪清, 梁军. 风电功率时间序列混沌特性分析及预测模型研究[J]. 物理学报, 2012, 61(19): 70-81.
Zhang Xueqing, Liang Jun. Chaotic characteristics analysis and prediction model study on wind power time series[J]. Acta Physica Sinica, 2012, 61(19): 70-81(in Chinese).
- [13] 王松岩, 李碧君, 于继来, 等. 风速与风电功率预测误差概率分布的时变特性分析[J]. 电网技术, 2013, 37(4): 967-973.
Wang Songyan, Li Bijun, Yu Jilai, et al. Analysis on time-varying characteristics of probability error in forecast of wind speed and wind power[J]. Power System Technology, 2013, 37(4): 967-973(in Chinese).
- [14] 殷礼胜, 何怡刚, 董学平, 等. 交通流量 VNNTF 神经网络模型多步预测研究[J]. 自动化学报, 2014, 40(9): 2066-2072.
Yin Lisheng, He Yigang, Dong Xueping, et al. Research on the multi-step prediction of Volterra neural network for traffic flow[J]. Acta Automatica Sinica, 2014, 40(9): 2066-2072(in Chinese).
- [15] Li Shuhui, Wunsch Donald C, O' Hair Edgar A, et al. Using neural network to estimate wind turbine power generation[J]. IEEE Transactions on Energy Conversion, 2004, 16(3): 523-536.
- [16] Yu Jiali, Zhang Yi, Zhou Jiliu. Continuous attractors of Lotka-Volterra recurrent neural networks with infinite neurons[J]. IEEE Transactions on Neural Networks, 2010, 21(10): 1690-1695.
- [17] 孟洋洋, 卢继平, 孙华利, 等. 基于相似日和人工神经网络的风电功率短期预测[J]. 电网技术, 2010, 34(12): 163-167.
Meng Yangyang, Lu Jiping, Sun Huali, et al. Short-term wind power forecasting based on similar days and artificial neural network[J]. Power System Technology, 2010, 34(12): 163-167(in Chinese).
- [18] 门志国, 彭秀艳, 王兴梅, 等. 基于 GA 优化 BP 神经网络辨识的 Volterra 级数核估计算法[J]. 南京理工大学学报, 2012, 36(6): 962-967.
Meng Zhiguo, Peng Xiuyan, Wang Xingmei, et al. Volterra series kernels estimation algorithm based on GA optimized BP neural network identification[J]. Journal of Nanjing University of Science and Technology, 2012, 36(6): 962-967(in Chinese).
- [19] 程洪亮, 张国贤, 包海昆. 基于 GA 神经网络的自适应预测控制的设计与仿真[J]. 系统仿真学报, 2003, 15(5): 718-721.
Cheng Hongliang, Zhang Guoxian, Bao Haikun. The design and simulation of a self-tuning predictive control based on neural network optimized by genetic algorithm[J]. Journal of System Simulation, 2003, 15(5): 718-721(in Chinese).



江岳春

收稿日期: 2015-01-18。

作者简介:

江岳春(1965), 男, 副教授, 主要研究方向为电力市场及技术支持系统、智能电网环境下的负荷预测理论与方法;

张丙江(1988), 男, 硕士研究生, 主要研究方向为人工智能在微网中的应用, E-mail: zhbjiang@163.com。

(责任编辑 王金芝)