

地区电网风电场功率超短期预测方法

李 智¹, 韩学山¹, 韩 力², 康 凯³

(1. 山东大学电气工程学院, 山东省济南市 250061; 2. 中国国际工程咨询公司, 北京市 100044;
3. 烟台供电公司, 山东省烟台市 264001)

摘要: 针对某地区电网并入多个风电场的情况, 论证分析了所有风电场总输出功率变化较单一风电场输出功率变化具有更好的规律性, 引入风电总量与风电分配因子这 2 个概念, 提出超短期风电场功率预测模型和求解方法。主要内容包括: 风电总量、风电分配因子以及它们之间的随机关联规律; 最小二乘支持向量机和卡尔曼滤波技术对风电总量和风电分配因子的自适应动态预测算法; 基于关联规律间接实现风电场输出功率的超短期预测。通过实例验证, 表明所提出的预测方法无论是在风电场功率预测精度、还是在预测误差分布范围方面都有明显改进。

关键词: 风电功率; 地区电网; 超短期预测; 风电总量; 分配因子; 最小二乘支持向量机; 卡尔曼滤波

0 引言

目前, 风电在部分省市地区电网中已占有一定比例, 对地区电网运行已造成明显的影响。把握风电运行的规律, 提高风电场输出功率预测的准确性^[1-3], 无论对于地区电网的安全经济运行, 还是对于风电资源的充分利用, 都显得非常重要。

对风电场而言, 气象条件是影响其输出功率变化的本质因素。文献[4-5]针对风速, 分别利用时间序列法和神经网络法进行了预测研究, 但由于没有考虑其他气象条件对风电功率的影响, 预测精度尚有提高的空间。文献[6]将天气预报的整体信息引入到预测过程中, 间接对风电场功率进行预测, 在一定程度上改善了预测精度。然而, 上述研究都从单一风电场功率预测的角度出发, 覆盖范围小, 在受到气象条件影响的同时, 局部随机扰动因素的影响使风电场功率变化的规律性受到干扰或破坏(如地表条件引起的随机紊流等), 预测精度很难提高。对此, 文献[7]通过在风电场周围地区建立测风站, 利用不同地点风速在空间上的相关性对风电场功率进行预测, 取得良好效果。不过, 为所有风电场都建立测风站又是不现实的。

一般来说, 地区电网中气象条件具有较好的相似性^[8], 各个风电场受到气象条件影响的规律基本一致。在给定地区内, 多个风电场的输出功率总和(本文称之为风电总量)至少能反映该地区风电场随

气象条件变化的总体规律, 而各单一风电场输出功率占风电总量的比例(本文称之为风电分配因子)之间又具有较强的相关性。因此, 把握好风电分配因子之间的相关性, 通过风电总量间接实现并网风电场的功率预测, 或许是提高风电场功率预测精度的一种途径, 更重要的是, 这种研究思路需要的信息量少, 更适合于电网层面上关于节点的风电预测, 这就是提出本文预测方法的初衷。

综上所述, 在充分利用电网数据采集功能的基础上, 本文提出一种风电场输出功率超短期预测的新思路和解决方法。

1 风电总量及风电分配因子关联规律分析

就电网而言, 目前获取风电接入节点的功率数据已不成问题, 进而可统计风电总量。以下对风电总量及风电分配因子的关联规律进行分析。

1.1 风电总量规律性分析

超短期风电功率预测通常以 5 min 为预测间隔, 本文按这一常规进行分析。以山东烟台地区电网为例, 主要有 7 座风电场并网运行, 其输出功率以及风电总量的 5 min 平均值曲线如图 1 所示。由于各风电场的装机容量不同, 去除风电功率曲线的基荷部分, 并进行归一化处理, 以强调风电的变化趋势规律。

由图 1 可见, 对于该地区电网, 由于气象条件的相似性, 使得各风电场功率的整体变化趋势基本一致。从概率理论角度讲, 风电总量的趋势变化规律显然要强于单一风电场的趋势变化规律。

收稿日期: 2009-09-14; 修回日期: 2009-12-02。
国家自然科学基金资助项目(50377021, 50677036)。




图 1 风电功率曲线
Fig. 1 Curves of wind power

上述现象可以通过量化予以分析。对于某一时段 D 内的预测对象而言,其用于建模的数据 $f(t)$ 可以分解为反映规律性变化的周期分量 $u(t)$ 和反映无法预知的、无规律性波动的非周期分量 $\epsilon(t)$,即建模误差。相对建模误差^[9] (RME)可以定义为:

$$S_{\text{RME}} = \frac{\epsilon(t)}{f(t)} \quad t \in D \quad (1)$$

RME 能够反映预测对象内在的规律性,对风电场输出功率和风电总量进行 RME 指标的定量分析

表 1 烟台地区电网风电场的风电分配因子间相关系数
Table 1 Correlation coefficients of distribution factors of wind farms in Yantai Power Grid

风电场	相关系数						
	风电场 1	风电场 2	风电场 3	风电场 4	风电场 5	风电场 6	风电场 7
1	1.000 0	0.827 9	0.958 9	0.832 9	0.828 3	0.644 7	0.745 6
2	0.827 9	1.000 0	0.791 0	0.915 8	0.901 4	0.799 5	0.840 1
3	0.958 9	0.791 0	1.000 0	0.733 7	0.796 2	0.600 1	0.642 6
4	0.832 9	0.915 8	0.733 7	1.000 0	0.915 9	0.781 2	0.726 5
5	0.828 3	0.901 4	0.796 2	0.915 9	1.000 0	0.799 5	0.874 7
6	0.644 7	0.799 5	0.600 1	0.781 2	0.799 5	1.000 0	0.837 7
7	0.745 6	0.840 1	0.642 6	0.726 5	0.874 7	0.837 7	1.000 0

2 风电场功率预测

2.1 基于最小二乘支持向量机 (LS-SVM) 的风电总量预测

风电的随机性和波动性使其呈现出明显的非线性变化特性,传统的时间序列法、回归分析法等由于模型过于简单,无法准确模拟复杂多变的风电功率。人工神经网络虽然能够处理非线性建模问题,但是结构和类型的选择过分依赖于经验,并且采用的经验风险最小化准则会导致泛化能力下降。LS-SVM 采用结构风险最小化准则,通过同时控制经验风险和学习机容量,能够在较好地建立非线性模型的同时获得良好的泛化能力^[11],通过实践表明其更适合于风电功率超短期预测。

给定风电总量的 n 组输入输出样本数据

能够更准确地描述其规律性变化的强弱。对图 1 所示烟台地区电网经过计算,风电场 1~风电场 7 的 RME 分别为 0.335 3,0.109 0,0.159 0,0.141 7,0.108 5,0.090 7,0.074 2,风电总量的 RME 为 0.068 6,可知风电总量的 RME 明显低于单一风电场的 RME,说明对风电总量总体规律的把握很重要。

1.2 风电分配因子相关性分析

第 k 座风电场在 t 时刻的风电分配因子 $\theta_k(t)$ 可定义如下:

$$\theta_k(t) = \frac{p_k(t)}{p(t)} \quad (2)$$

式中: $p_k(t)$ 为第 k 座风电场在 t 时刻的输出功率; $k=1,2,\dots,L$; L 为风电场数量; $p(t)$ 为 t 时刻的风电总量。

将风电场输出功率随时间的变化过程看做随机过程,通过相关系数反映各个随机过程间的线性相关程度^[10]。表 1 是烟台地区电网风电场的风电分配因子间的相关系数分析结果,可见风电分配因子间的相关系数均在 0.60~0.99 之间,具有强相关性。

$(\mathbf{V}_i(t), p_i(t))$ 。其中: $i=1,2,\dots,n$; $\mathbf{V}_i(t) \in \mathbf{R}^{d \times 1}$ 为由 $t-d \sim t-1$ 时刻风电总量组成的输入向量; $p_i(t) \in \mathbf{R}$ 为 t 时刻风电总量。下文叙述中将 $\mathbf{V}_i(t)$ 和 $p_i(t)$ 分别简写为 \mathbf{V}_i 和 p_i 。

由支持向量机 (SVM) 理论,风电总量不同时段间的非线性关系总可以描述为:

$$p_i = \omega^T \boldsymbol{\varphi}(\mathbf{V}_i) + b \quad (3)$$

式中: $\boldsymbol{\varphi}(\cdot)$ 为输入向量的非线性映射函数; $\omega \in \mathbf{R}^{d \times 1}$ 为权重向量; b 为偏移量。

由 Vapnik 的结构风险最小化准则,式 (3) 所示估计问题可表示成如下最优化问题:

$$\min_{\omega, b, e, \lambda_i} J = \frac{1}{2} \omega^T \omega + \gamma \sum_{i=1}^n e_i^2 - \sum_{i=1}^n \lambda_i (\omega^T \boldsymbol{\varphi}(\mathbf{V}_i) + b + e_i - p_i) \quad (4)$$

式中: λ_i 为拉格朗日乘子; $\mathbf{e} = [e_1, e_2, \dots, e_n]^T$ 为误差向量; γ 为正规化参数, 控制对超出误差运行范围样本的惩罚程度, 数值越大则训练误差越大, 泛化性能越好, 反之则训练误差越小, 泛化性能越差。

根据优化的 KKT 条件并消去 ω 和 \mathbf{e} , 式(4)的最优求解可变成如下线性方程组求解:

$$\begin{bmatrix} 0 & \mathbf{1}^T \\ \mathbf{1} & \mathbf{Z}^T \mathbf{Z} + \frac{\mathbf{I}}{\gamma} \end{bmatrix} \begin{bmatrix} b \\ \lambda \end{bmatrix} = \begin{bmatrix} 0 \\ \mathbf{P} \end{bmatrix} \quad (5)$$

式中: $\mathbf{Z} = [\varphi(\mathbf{V}_1), \varphi(\mathbf{V}_2), \dots, \varphi(\mathbf{V}_n)]^T$; $\lambda = [\lambda_1, \lambda_2, \dots, \lambda_n]^T$; $\mathbf{1} = [1, 1, \dots, 1]^T$; $\mathbf{P} = [p_1, p_2, \dots, p_n]^T$; \mathbf{I} 为单位矩阵。

输入空间经过 $\varphi(\cdot)$ 映射后会导致映射空间维数增加, 计算量急剧增大。根据泛函理论, 映射空间的内积 $\varphi(\mathbf{V}_i) \varphi(\mathbf{V}_j)$ 可用输入空间的核函数等效, 从而达到降低计算规模的目的。此处采用高斯核函数:

$$K(\mathbf{V}_i, \mathbf{V}_j) = \varphi(\mathbf{V}_i) \varphi(\mathbf{V}_j) = \exp\left(-\frac{\|\mathbf{V}_i - \mathbf{V}_j\|^2}{2\sigma^2}\right) \quad (6)$$

式中: σ 为高斯核函数的覆盖宽度。

用核函数替代后, 通过求解式(5)所示方程组求得 λ 和 b 。对于一组新的输入量 \mathbf{V}_{n+1} , 风电总量的非线性回归分析结果为:

$$p_{n+1} = \sum_{i=1}^n \lambda_i K(\mathbf{V}_{n+1}, \mathbf{V}_i) + b \quad (7)$$

尽管 LS-SVM 在计算速度方面有较大提高, 但在超短期预测在线运行过程中, 需要不断吸收新样本中的信息、放弃旧样本, 以准确反映系统最新的行为特征^[12]。如果对于所有新样本都要对式(5)的系数矩阵重新求逆, 计算效率依然无法达到在线运行的要求, 因此, 还需要对系数矩阵中的 $\mathbf{Z}^T \mathbf{Z} + \mathbf{I}/\gamma$ 建立系数矩阵的递推求逆公式^[13], 限于篇幅, 此处不详细介绍, 具体可见附录 A。

2.2 基于卡尔曼滤波的风电分配因子预测

如前所述, 多数地区电网中风电分配因子间具有较强的相关性。向量卡尔曼滤波与预测算法由于使用状态空间法在时域内设计滤波器, 能够充分利用这种相关性, 因而适用于风电分配因子的快速递推估计^[14]。在超短期预测周期内, 风电场输出功率波动的幅值和速率并不大, 因此可以在 t 时刻对风电分配因子的状态方程和观测方程进行线性化和离散化处理, 得到:

$$\begin{cases} \hat{\boldsymbol{\theta}}(t+1) = \mathbf{A}(t) \hat{\boldsymbol{\theta}}(t) + \boldsymbol{\delta}(t) \\ \mathbf{Y}(t) = \mathbf{B}(t) \hat{\boldsymbol{\theta}}(t) + \boldsymbol{\xi}(t) \end{cases} \quad (8)$$

式中: $\mathbf{A}(t), \mathbf{B}(t) \in \mathbf{R}^{L \times 1}$, 分别为系统矩阵和观测矩

阵; $\boldsymbol{\theta}(t) \in \mathbf{R}^{L \times 1}$ 为由风电分配因子 $\theta_k(t)$ 组成的向量; L 为风电场数量; $\mathbf{Y}(t) \in \mathbf{R}^{L \times 1}$ 为 t 时刻风电分配因子的观测向量; $\boldsymbol{\delta}(t)$ 为过程噪声向量, 代表状态转移过程中风电场功率的随机波动以及局部干扰因素; $\boldsymbol{\xi}(t)$ 为测量噪声向量, 代表状态观测时的不确定因素, 如测量和数据传输时产生的误差; $\boldsymbol{\delta}(t)$ 和 $\boldsymbol{\xi}(t)$ 的协方差矩阵分别为 $\mathbf{Q}(t)$ 和 $\mathbf{R}(t)$ 。

设 $\tilde{\boldsymbol{\theta}}(t)$ 为 t 时刻风电分配因子向量的预测估计, $\hat{\boldsymbol{\theta}}(t)$ 为根据 $\mathbf{Y}(t)$ 对 $\tilde{\boldsymbol{\theta}}(t)$ 进行校正得到的滤波估计, 则两者关系可表示为:

$$\hat{\boldsymbol{\theta}}(t) = \tilde{\boldsymbol{\theta}}(t) + \mathbf{K}(t)(\mathbf{Y}(t) - \mathbf{B}(t)\tilde{\boldsymbol{\theta}}(t)) \quad (9)$$

式中: $\mathbf{K}(t)$ 为增益矩阵。

预测误差和滤波误差的协方差矩阵分别为:

$$\mathbf{M}(t|t-1) = E(\mathbf{e}_t \mathbf{e}_t^T) \quad (10)$$

$$\mathbf{W}(t|t) = E(\mathbf{e}_e \mathbf{e}_e^T) \quad (11)$$

式中: $\mathbf{e}_t(t)$ 和 $\mathbf{e}_e(t)$ 分别为预测误差和估计误差, $\mathbf{e}_t(t) = \boldsymbol{\theta}(t) - \tilde{\boldsymbol{\theta}}(t)$, $\mathbf{e}_e(t) = \boldsymbol{\theta}(t) - \hat{\boldsymbol{\theta}}(t)$ 。

综合式(8)、式(9)和式(11)并计及 $\mathbf{e}_t(t)$ 与 $\boldsymbol{\xi}(t)$ 的不相关性, $\mathbf{W}(t|t)$ 可以表达为:

$$\mathbf{W}(t|t) = (\mathbf{K}(t)\mathbf{S}(t) - \mathbf{L}(t))(\mathbf{K}(t)\mathbf{S}(t) - \mathbf{L}(t))^T + \mathbf{M}(t|t-1) - \mathbf{L}(t)\mathbf{L}^T(t) \quad (12)$$

式中: $\mathbf{S}(t)\mathbf{S}^T(t) = \mathbf{B}(t)\mathbf{M}(t|t-1)\mathbf{B}^T(t) + \mathbf{R}(t)$; $\mathbf{L}(t) = \mathbf{M}(t|t-1)\mathbf{B}^T(t)(\mathbf{S}^T(t))^{-1}$ 。

式(12)中只有 $\mathbf{K}(t)$ 为待定量, 采用最小均方误差作为最优滤波准则, 选择 $\mathbf{K}(t)$ 使第 1 项为 0, 满足:

$$\mathbf{K}(t) = \mathbf{L}(t)\mathbf{S}^{-1}(t) = \mathbf{M}(t|t-1)\mathbf{B}^T(t)\mathbf{G}^{-1} \quad (13)$$

式中: $\mathbf{G} = \mathbf{B}(t)\mathbf{M}(t|t-1)\mathbf{B}^T(t) + \mathbf{R}(t)$ 。

此时 $\mathbf{K}(t)$ 称为最优滤波增益矩阵。最优增益对应的滤波误差的协方差矩阵为:

$$\mathbf{W}(t|t) = (\mathbf{I} - \mathbf{K}(t)\mathbf{B}(t))\mathbf{M}(t|t-1) \quad (14)$$

综合式(8)、式(10)和式(14), 经过变换得到 $t+1$ 时刻预测误差的协方差矩阵为:

$$\mathbf{M}(t+1|t) = \mathbf{A}(t)\mathbf{W}(t|t)\mathbf{A}^T(t) + \mathbf{Q}(t) \quad (15)$$

综合上述, 式(9)、式(13)、式(14)和式(15)构成卡尔曼滤波与预测算法的全部循环递推过程, 即

$$\tilde{\boldsymbol{\theta}}(t+1) = \mathbf{A}(t)\tilde{\boldsymbol{\theta}}(t) \quad (16)$$

$$\begin{cases} \mathbf{K}(t) = \mathbf{M}(t|t-1)\mathbf{B}^T(t)\mathbf{G}^{-1}(t) \\ \mathbf{G}(t) = \mathbf{B}(t)\mathbf{M}(t|t-1)\mathbf{B}^T(t) + \mathbf{R}(t) \\ \hat{\boldsymbol{\theta}}(t) = \tilde{\boldsymbol{\theta}}(t) + \mathbf{K}(t)(\mathbf{Y}(t) - \mathbf{B}(t)\tilde{\boldsymbol{\theta}}(t)) \\ \mathbf{W}(t|t) = (\mathbf{I} - \mathbf{K}(t)\mathbf{B}(t))\mathbf{M}(t|t-1) \\ \mathbf{M}(t+1|t) = \mathbf{A}(t)\mathbf{W}(t|t)\mathbf{A}^T(t) + \mathbf{Q}(t) \end{cases} \quad (17)$$

在得到风电总量预测值和风电分配因子预测值后, 经过简单计算即可得到风电场功率预测值。

2.3 风电场功率的递推超短期预测

综前所述,风电场功率的递推超短期预测的具体流程表述如下:

- 1)在 t 时刻,采用 LS-SVM 计算 $t+1$ 时刻的风电总量预测值 $p(t+1)$;
- 2)根据式(17)计算 $t+1$ 时刻风电分配因子的预测估计值 $\hat{\theta}(t+1)$,经过简单计算得到风电场输出功率的预测值 $p_k(t+1)$;
- 3)分别对 LS-SVM 的系数矩阵和卡尔曼滤波的误差协方差矩阵进行修正;
- 4)在 $t+1$ 时刻,返回步骤 1,进行下一时刻预测。

3 算例分析

为验证本文所提出的预测方法的有效性,仍以烟台地区电网为例,对烟台长岛地区风电场输出功率进行预测。烟台地区共有 7 座主要风电场,总装机容量为 158.85 MW,总装机台数为 178 台。烟台 220 kV 主网架及风电场分布情况参见附录 B。

取 2008 年 6 月 2 日风电总量以及各风电场功率的 5 min 平均值共 288 组数据进行分析。其中,前 7 组数据用于启动算法,其余数据用于测试本文所提出的预测方法的有效性。

图 2 为风电总量预测结果。可以看出,由于风电总量的规律性较强,整体预测效果较好,尤其是当风电功率发生几次较大幅度突变时,预测模型能够较好地跟踪风电功率快速变化,没有发生较大偏移,预测结果能够真实反映风电总量良好的规律性。




图 2 风电总量预测结果

Fig. 2 Forecasting result of total wind power

将预测值与实测值进行对比就可以得到逐点的相对预测误差序列,对该序列进行进一步分析即可得到误差序列的平均值及方差,即平均相对误差和相对误差方差。这 2 个指标能够表征预测模型的整体预测精度和误差的分布范围,进而反映模型的预测水平^[15]。表 2 对比了采用风电场单独预测方法和本文方法得到的风电功率预测结果的平均相对误差和相对误差方差。由表 2 可见,本文方法的平均相对误差和相对误差方差均好于风电场单独预测方

法,说明预测精度得到整体提高,同时也说明本文方法在提高预测精度的同时,由于强调风电总量的规律性在预测过程中的作用,有效降低了局部随机因素的干扰作用,因而能够减小预测误差的分布范围。这一点对于减少系统运行成本和备用容量、体现风电价值具有重要意义。

表 2 预测结果误差对比
Table 2 Comparison of forecasting errors

风电场	平均相对误差		相对误差方差	
	风电场 单独预测方法	本文方法	风电场 单独预测方法	本文方法
1	0.294 27	0.229 90	0.435 30	0.387 82
2	0.268 70	0.212 34	0.398 64	0.334 07
3	0.253 94	0.187 97	0.390 01	0.311 86
4	0.255 44	0.213 81	0.392 52	0.359 76
5	0.269 30	0.202 42	0.400 06	0.334 21
6	0.243 68	0.216 91	0.367 72	0.348 54
7	0.212 35	0.201 93	0.350 88	0.334 35

4 结语

要实现考虑电网安全的在线优化调度与控制,在已有研究成果基础上,有必要掌握并网风电场输出功率的变化规律。本文对此进行了深入分析和研究,提出了相应的模型和方法,并以实际系统为例进行验证,结论如下:

- 1)从电网层面上讲,风电接入节点的功率预测可以采用调度自动化数据,以风电功率反映风电随气象的变化规律,间接预测是可行的。
- 2)在地区电网气象条件差别不显著的前提下,风电总量具有强规律性,各风电场之间又有强相关性。
- 3)风电分配因子是关联风电总量和单一风电场功率的关键,具有相互牵制的作用,把握风电分配因子间的相关性对预测风电有益。
- 4)本文研究成果已在烟台实际电网风电预测中得到验证。对于其他地区电网,乃至气象条件差异悬殊的情形,有待深入研究与分析。

附录见本刊网络版 (<http://www.aeps-info.com/aeps/ch/index.aspx>)。

参考文献

[1] 雷亚洲. 与风电并网相关的研究课题. 电力系统自动化, 2003, 27(8): 84-89.
LEI Yazhou. Studies on wind farm integration into power system. Automation of Electric Power Systems, 2003, 27(8): 84-89.
[2] ALSAC O, STOTT B. Optimal load flow with steady-state security. IEEE Trans on Power Apparatus and Systems, 1974,

- 93(4): 745-751.
- [3] ALEXANDRE C, ANTONIO C, JORGE N. A review on the young history of the wind power short-term prediction. *Renewable and Sustainable Energy Reviews*, 2008, 12(6): 1725-1744.
- [4] KAMAL L, JAFRI Y Z. Time series models to simulate and forecast hourly averaged wind speed in Quetta, Pakistan. *Solar Energy*, 1997, 61(1): 23-32.
- [5] 杨秀媛, 肖洋, 陈树勇. 风电场风速和发电功率预测研究. *中国电机工程学报*, 2005, 25(11): 1-5.
YANG Xiuyuan, XIAO Yang, CHEN Shuyong. Wind speed and generated power forecasting in wind farm. *Proceedings of the CSEE*, 2005, 25(11): 1-5.
- [6] 范高峰, 王伟胜, 刘纯, 等. 基于人工神经网络的风电功率预测. *中国电机工程学报*, 2008, 28(34): 118-123.
FAN Gaofeng, WANG Weisheng, LIU Chun, et al. Wind power prediction based on artificial neural network. *Proceedings of the CSEE*, 2008, 28(34): 118-123.
- [7] DAMOUSIS I G, ALEXIADIS M C. A fuzzy model for wind speed prediction and power generation in wind parks using spatial correlation. *IEEE Trans on Energy Conversion*, 2004, 19(2): 352-361.
- [8] 黎静华, 栗然, 顾雪平, 等. 网格化的电力系统短期负荷预测的MDRBR模型. *电力系统自动化*, 2005, 29(24): 27-31.
LI Jinghua, LI Ran, GU Xueping, et al. Grid model for short-term load forecasting based on MDRBR algorithm. *Automation of Electric Power Systems*, 2005, 29(24): 27-31.
- [9] 穆钢, 侯凯元, 杨右虹, 等. 负荷预报中负荷规律性评价方法的研究. *中国电机工程学报*, 2001, 21(10): 96-101.
MU Gang, HOU Kaiyuan, YANG Youhong, et al. Studies on load regularity evaluating method for load forecasting. *Proceedings of the CSEE*, 2001, 21(10): 96-101.
- [10] 盛骤. 概率论与数理统计. 北京: 高等教育出版社, 2001.
- [11] SUYKENS J, VANDEWALE J. Least squares support vector machine classifiers. *Neural Processing Letters*, 1999, 9(3): 293-300.
- [12] 康重庆, 夏清, 张伯明. 电力系统负荷预测研究综述与发展方向的探讨. *电力系统自动化*, 2004, 28(17): 1-11.
KANG Chongqing, XIA Qing, ZHANG Boming. Review of power system load forecasting and its development. *Automation of Electric Power Systems*, 2004, 28(17): 1-11.
- [13] 吴琼, 杨以涵, 刘文颖. 基于最小二乘支持向量机的电力系统暂态稳定在线预测. *中国电机工程学报*, 2007, 27(25): 38-43.
WU Qiong, YANG Yihan, LIU Wenying. Electric power system transient stability on-line prediction based on least squares support vector machine. *Proceedings of the CSEE*, 2007, 27(25): 38-43.
- [14] 蒋志凯. 数字滤波与卡尔曼滤波. 北京: 中国科学技术出版社, 1993.
- [15] 毛英泰. 误差理论与精度分析. 北京: 国防工业出版社, 1982.

李 智(1983—), 男, 通信作者, 博士研究生, 主要研究方向: 电力系统运行与控制、风力发电。E-mail: zhongwawa1983@163.com

韩学山(1959—), 男, 教授, 博士生导师, 主要研究方向: 电力系统分析与控制。

韩 力(1979—), 男, 博士, 主要研究方向: 电力系统调度自动化。

An Ultra-short-term Wind Power Forecasting Method in Regional Grids

LI Zhi¹, HAN Xueshan¹, HAN Li², KANG Kai³

(1. Shandong University, Jinan 250061, China; 2. China International Engineering Consulting Corporation, Beijing 100044, China; 3. Yantai Power Supply Company, Yantai 264001, China)

Abstract: Considering a regional grid with several wind farms integrated, the total wind power has a better regularity comparing to that of a single wind farm. An ultra-short-term wind power forecasting method is proposed based on the concepts of total wind power and distribution factor. The least-square support vector machine (LS-SVM) and Kalman filter are adopted respectively to forecast the total wind power and distribution factor recursively, so that the good regularity of total wind power can be restored. Case studies show that the method not only improves the forecasting accuracy but also reduces the distribution range of the forecasting errors.

This work is supported by National Natural Science Foundation of China (No. 50377021, 50677036).

Key words: wind power; regional grid; ultra-short-term forecast; total wind power; distribution factor; LS-SVM; Kalman filter

附录A 系数矩阵递推求逆公式的推导

在 t 时刻令 $\mathbf{H}_t = \mathbf{Z}^T \mathbf{Z} + \mathbf{I} / \gamma$ ，则 \mathbf{H}_t 可以表示为：

$$\begin{aligned} \mathbf{H}_t &= \begin{bmatrix} K(\mathbf{V}_1, \mathbf{V}_1) + 1/\gamma & \cdots & K(\mathbf{V}_n, \mathbf{V}_1) \\ \vdots & \ddots & \vdots \\ K(\mathbf{V}_1, \mathbf{V}_n) & \cdots & K(\mathbf{V}_n, \mathbf{V}_n) + 1/\gamma \end{bmatrix} \\ &= \begin{bmatrix} f_t & \mathbf{F}_t \\ \mathbf{F}_t^T & \mathbf{W}_t \end{bmatrix} \end{aligned} \quad (\text{A1})$$

式中： $f_t \in \mathbf{R}$ ； $\mathbf{F}_t \in \mathbf{R}^{1 \times n}$ 和 $\mathbf{W}_t \in \mathbf{R}^{(n-1) \times (n-1)}$ 均为分块阵。

得到 $t+1$ 时刻的新样本 $(\mathbf{V}_{n+1}, p_{n+1})$ 后，新矩阵 \mathbf{H}_{t+1} 可以表示为：

$$\begin{aligned} \mathbf{H}_{t+1} &= \begin{bmatrix} K(\mathbf{V}_2, \mathbf{V}_2) + 1/\gamma & \cdots & K(\mathbf{V}_{n+1}, \mathbf{V}_2) \\ \vdots & \ddots & \vdots \\ K(\mathbf{V}_2, \mathbf{V}_{n+1}) & \cdots & K(\mathbf{V}_{n+1}, \mathbf{V}_{n+1}) + 1/\gamma \end{bmatrix} \\ &= \begin{bmatrix} \mathcal{W}_t & \mathbf{L}_{t+1} \\ \mathbf{L}_{t+1}^T & v_{t+1} \end{bmatrix} \end{aligned} \quad (\text{A2})$$

式中： $v_{t+1} \in \mathbf{R}$ ； $\mathbf{L}_{t+1} \in \mathbf{R}^{n \times 1}$ 为分块阵； \mathbf{W}_t 含义同上。

根据 Sherman-Woodbury 引理， \mathbf{H}_t^{-1} 和 \mathbf{H}_{t+1}^{-1} 可以表达为如下形式：

$$\begin{aligned} \mathbf{H}_t^{-1} &= \begin{bmatrix} s & -s\mathbf{F}_t^T \mathbf{W}_t^{-1} \\ -s\mathbf{W}_t^{-1} \mathbf{F}_t & \mathbf{W}_t^{-1} + s\mathbf{W}_t^{-1} \mathbf{F}_t \mathbf{F}_t^T \mathbf{W}_t^{-1} \end{bmatrix} \\ &= \begin{bmatrix} s & \mathbf{h}_t \\ \mathbf{h}_t^T & \mathbf{G}_t \end{bmatrix} \end{aligned} \quad (\text{A3})$$

$$\mathbf{H}_{t+1}^{-1} = \begin{bmatrix} \mathbf{W}_t^{-1} + t\mathbf{W}_t^{-1} \mathbf{L}_{t+1} \mathbf{L}_{t+1}^T \mathbf{W}_t^{-1} & -t\mathbf{W}_t^{-1} \mathbf{L}_{t+1} \\ -t\mathbf{L}_{t+1}^T \mathbf{W}_t^{-1} & t \end{bmatrix} \quad (\text{A4})$$

式中： $s = 1 / (f_t - \mathbf{F}_t^T \mathbf{W}_t^{-1} \mathbf{F}_t)$ ； $t = 1 / (v_{t+1} - \mathbf{L}_{t+1}^T \mathbf{W}_t^{-1} \mathbf{L}_{t+1})$ 。

由式(A3)推导可得 $\mathbf{W}_t^{-1} = \mathbf{G}_t - \mathbf{h}_t^T \mathbf{h}_t / s$ ，将该式代入式(A4)即可求解 \mathbf{H}_{t+1}^{-1} ，从而实现系数矩阵的递推求逆。

附录B 烟台主电网结构图




图 B1 烟台电网 220kV 网络结构
Fig.B1 Structure of Yantai 220kV power system