

# 基于人工神经网络的风电功率预测

范高峰, 王伟胜, 刘纯, 戴慧珠

(中国电力科学研究院, 北京市 海淀区 100192)

## Wind Power Prediction Based on Artificial Neural Network

FAN Gao-feng, WANG Wei-sheng, LIU Chun, DAI Hui-zhu

(China Electric Power Research Institute, Haidian District, Beijing 100192, China)

**ABSTRACT:** Wind power prediction is important to the operation of power system with comparatively large amount of wind power. The wind power prediction methods were classified into several kinds. An artificial neural network (ANN) model for wind power prediction was constructed according to the wind power influence factors. Then the impacts of real time measured power and the atmospheric data at different heights on prediction results were analyzed. Besides, another ANN model for error band prediction was also built. The results indicate that the ANN structure and the training sample have some impact on the prediction precision. The real time measured power as input will improve the precision of 30 min ahead prediction, however will decrease the precision of 1h ahead prediction. The results which using the atmospheric data at all different heights as input have a higher accuracy when compared with the results using hub height data only. The designed ANN can forecast the error band.

**KEY WORDS:** wind farm; power; prediction; artificial neural networks

**摘要:** 风电场输出功率预测对接入大量风电的电力系统运行有重要意义。对风速和风电场输出功率预测的方法进行了分类。根据风电场输出功率的影响因素,建立了风电功率预测的神经网络模型。分析了实测功率数据、不同高度的大气数据对预测结果的影响。建立了基于神经网络的误差带预测模型,实现了误差带预测。研究表明,神经网络的结构和输入样本对预测结果有一定的影响;实测功率数据作为输入可以提高提前量为30 min的预测精度,而对提前量为1 h的预测精度会降低;把不同高度的数据都作为神经网络的输入比只采用轮毂高度数据的预测精度高;设计的神经网络能够对误差带进行预测。

**关键词:** 风电场; 功率; 预测; 人工神经网络

## 0 引言

大规模并网风电场对电力系统的运行带来一

些新问题,其中很重要的一方面是对电力系统运行调度的影响<sup>[1-4]</sup>。风电功率预测对电力系统的功率平衡和经济调度具有非常重要的意义。国外风电装机容量较大的国家都进行了风电功率预测系统的研究与开发。风电功率预测方法根据预测的物理量来分类,可以分为2类:第1类为对风速的预测,然后根据风电机组或风电场的功率曲线得到风电场功率输出;第2类为直接预测风电场的输出功率。根据所采用的数学模型不同可分为持续预测法、自回归滑动平均(auto regressive moving average, ARMA)模型法、卡尔曼滤波法和智能方法等。持续预测方法<sup>[5]</sup>是最简单的预测模型,这种方法认为风速预测值等于最近几个风速值的滑动平均值,通常认为最近1点的风速值为下1点的风速预测值<sup>[6]</sup>,该模型的预测误差较大,且预测结果不稳定。改进的方法有ARMA模型<sup>[7-9]</sup>和向量自回归模型<sup>[10]</sup>、卡尔曼滤波算法<sup>[11-12]</sup>或时间序列法和卡尔曼滤波算法相结合<sup>[13]</sup>。另外还有一些智能方法,如神经网络方法<sup>[6,14-15]</sup>等。根据预测系统输入数据来分类也可以分为2类:1类不采用数值天气预报的数据,1类采用数值天气预报的数据。根据预测的时间尺度来分类,可分为超短期预测和短期预测。所谓的超短期并没有一致的标准,一般可认为不超过30 min的预测为超短期预测。而对于时间更短的数分钟内的预测,主要用于风力发电控制、电能质量评估及风电机组机械部件的设计等<sup>[16]</sup>。这种分钟级的预测一般不采用数值天气预报数据。短期预测一般可认为是30 min~72 h的预测,主要用于电力系统的功率平衡和调度、电力市场交易、暂态稳定评估等。对于更长时间尺度的预测,主要用于系统检修安排等。目前,中长期预测还存在较大的困难。因为风速、风向等天气情况是由大气运动决定的,不考虑

数值天气预报数据无法反映大气运动的本质,因此也难以得到较好的预测结果,所以现在研究的风电场输出功率预测都把数值天气预报数据作为 1 组重要输入数据。考虑了地形、粗糙度等信息,采用物理方程进行预测的方法则称之为物理方法,根据历史数据进行统计分析,找出其内在规律并用于预测的方法称之为统计方法(如神经网络方法、模糊逻辑方法等)。如果物理方法和统计方法都采用则称之为综合方法。

目前国内在该方面的研究较少。文献[8]探讨了风电场的短期风速预测,结合实例阐述了时间序列法在短期风速预测中的应用,但没有给出风电场输出功率的预测。文献[14]基于时间序列法和神经网络法对风速预测进行了研究,这种时序神经网络模型本质上还是以时间序列为基础的,对较长时间的预测效果会比较差。文献[17]研究了基于神经网络的风电场风速时间序列的预测,没有对风电场的输出功率进行预测。总之,目前国内的研究存在以下不足:1) 所做的研究工作主要集中在对风速时间序列的预测,主要方法是根据风速的历史数据预测将来的风速。其实风速的变化与大气运动紧密相关,由大气的牛顿第 2 定律、质量守恒定律、热力学能量守恒定律、气体实验定律和水汽守恒定律等物理定律决定,因此采用历史风速数据预测将来风速的方法存在明显的不足之处,模型的外推能力较差。2) 没有实现真正的风电场输出功率预测。风速是影响风电场输出功率的重要参量之一,除此之外,风向、温度、湿度、地表粗糙度等都对风电场输出功率有一定的影响,因此根据风速和风电机组的功率曲线预测风电场的输出功率也存在不足之处。3) 风电机组的功率曲线是通过测试数据拟合得到的,实际输出功率分布在 1 个较宽的区域之内,不是 1 条曲线,而是 1 簇曲线。采用风电机组功率曲线或风电场功率曲线进行预测都没有考虑功率的杂散分布。本文分析了风电场输出功率的影响因素;设计了基于数值天气预报的反向传播(back-propagation, BP)神经网络预测模型,分析了实测功率数据、不同高度的大气数据对预测结果的影响。分析了预测误差,用神经网络实现了对误差带的预测。

## 1 风电场输出功率的影响因素

### 1.1 风速与风电机组输出功率的关系

风力机捕获的风功率可以用式(1)来表示:

$$P = C_p A \rho v^3 / 2 \quad (1)$$

式中:  $P$  为风轮输出功率, kW;  $C_p$  为风轮的功率系数;  $\rho$  为空气密度,  $\text{kg/m}^3$ ;  $A$  为风轮扫掠面积,  $\text{m}^2$ ;  $v$  为风速,  $\text{m/s}$ 。

图 1 为某变速风电机组的功率曲线,在功率曲线较陡的区域,较小的风速变化会引起较大功率变化,如图中所示,风速变化  $2.5 \text{ m/s}$ ,功率变化  $200 \text{ kW}$  左右。图 2 是某风电机组实测的输出功率与风速的散点图,可以看出风电机组的输出功率有一定的分散性。这是由于受到机械湍流和热力湍流的影响,风速的空间分布并不完全遵守对数风廓线;另一方面,风电机组的偏航装置根据轮毂高度的风速计和风向标使风机对准来风方向,但可能有一定的滞后,风机并不能总是正对来风方向。这就导致在看似相似的风速下确有不同的输出功率。




图 1 某双馈变速风电机组的功率曲线

Fig. 1 Power curve of a variable speed wind turbine




图 2 某机组实测功率散点图

Fig. 2 Schematic plot of a wind turbine measurement power

### 1.2 风向与风电机组/风电场输出功率的关系

风电场由很多风电机组组成,由于风能被风电机组风轮吸收,风轮后面的风速降低,这就是尾流。由于上风向的风电机组尾流的影响,下风向风电机组捕获的风能减少,相应风电机组的出力也降低。

为了进一步定量分析风向对风电场输出功率的影响,定义风电场的效率系数:

$$\eta = P_m / P_f \quad (2)$$

式中:  $P_m$  为实测的风电场在一定风速和一定风向下的输出功率;  $P_f$  为风电场在一定风速和风向下的不受尾流影响的输出功率。某风电场的效率如图 3 所示。

从图中可以看出,风速较低时,由于尾流和粗糙度的影响,在某些风向下风电场效率较低,在风速为4 m/s时,效率最低为65%。同时可以看出,风速越大,风电场效率系数越高,风速超过额定风速一定量后,后面机组的风速也超过额定风速,此时尾流效应不影响输出功率,风电场在任何风向下效率系数都为100%。




图3 风电场在不同风速和风向下的效率

Fig. 3 Wind farm efficiency in different wind speed and wind direction

### 1.3 空气密度与风电机组输出功率的关系

空气密度 $\rho$ 也是影响输出功率的重要因素之一。某变速风电机组在不同空气密度下的功率曲线如图4所示。从图中可以看出,随着空气密度的增大,风电机组的输出功率也相应变大。空气密度和湿度、温度、压强密切相关。因此在风电功率预测中要考虑温度、湿度和压强。




图4 某风电机组在不同空气密度下的功率曲线

Fig. 4 A wind turbine power curve under different air density

## 2 BP神经网络算法

### 2.1 BP神经网络

BP神经网络是指基于误差反向传播算法的多层前向神经网络,采用有导师的训练方式<sup>[18-21]</sup>。能够以任意精度逼近任何非线性映射;可以学习和自适应未知信息;具有分布式信息存储与处理结构,具有一定的容错性,因此构造出来的系统具有较好的鲁棒性,适合处理复杂问题。

### 2.2 BP神经网络的学习算法

BP神经网络的学习算法图5所示。首先初始化网络的结构和权值,然后根据输入样本前向计算BP网络每层神经元的输入信号和输出信号,根据期望输出计算反向误差,对权值进行修正,如果误差小于给定值或迭代次数超过设定值结束学习。

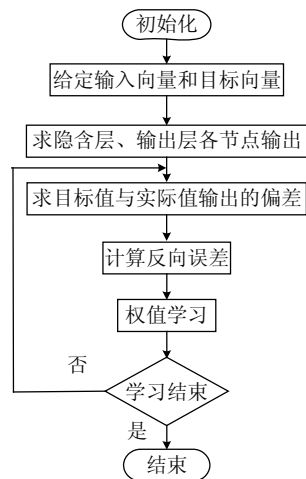


图5 BP网络的学习流程

Fig. 5 Flow chart of BP network learning

### 2.3 数据归一化

1) 风速归一化。可以采用多年统计的极限风速对风速数据归一化:

$$v_g = v_t / v_{\max} \quad (3)$$

式中: $v_g$ 为归一化后的风速值; $v_t$ 为数值天气预报系统预测的风速值; $v_{\max}$ 为气象观测的历史最大风速。

2) 风向归一化。风向指风的方向,是把圆周分成360°,正北方向是0°。为了区分所有的风向,需要取风向的正弦和余弦2个值作为输入。

3) 气温、气压、湿度的归一化采用和风速归一化类似的方法,取气象观测的最大值进行归一化。

神经网络的基本结构如图6所示。

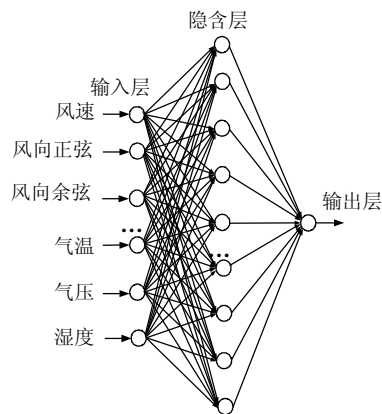


图6 BP神经网络结构

Fig. 6 Structure of BP networks

### 3 算例分析

#### 3.1 风电场基本情况

算例风电场包含 58 台 G58-850 kW 的机组，总装机容量为 49.3 MW。风电场共有 6 行风机，行间距为 480 m，行内每 2 台风机间距为 360 m。G52-850 kW 型风电机组是一种变速双馈风电机组，风轮直径 58 m，轮毂高度为 55 m。

#### 3.2 隐层节点数对预测结果的影响

训练数据为 3 个月数值天气预报数据和风电场出力数据，包含了不同风速段、不同风向的数据。取另一时间段的数据(3 个月)用于神经网络的测试。对于 BP 神经网络，3 层网络理论上就可以逼近任何非线性函数，因此选择包含 1 个隐含层的 3 层网络。网络隐层神经元传递函数采用 S 型正切函数，输出层神经元传递函数采用 S 型对数函数。隐层节点数会影响预测精度。经逐一筛选分析，当网络的隐层节点数为 19 时，训练样本误差最小，均方根误差为 8.9%；隐层节点数继续增加，出现过学习现象，网络外推能力变差，预测误差反而增大。

#### 3.3 输入数据对预测结果的影响

##### 3.3.1 实测功率对超短期预测的影响

对于超短期风电功率预测，前一时刻风电场的输出功率，表征了预测的起始值，可以作为风电场输出功率的一个重要参考量。风电场的输出功率可以通过 SCADA 系统得到。

下面分析提前 30 min 和提前 1 h 2 种情况下，考虑实测数据和不考虑实测数据的预测。经过分析，计算得到各种情况下的预测误差，如表 1 所示。

表 1 预测误差  
Tab. 1 Prediction error

| 时间尺度         | 预测均方根误差/%  |           |
|--------------|------------|-----------|
|              | 不考虑前一时刻测量值 | 考虑前一时刻测量值 |
| 提前 30 min 预测 | 10.3       | 8.7       |
| 提前 1 h 预测    | 11.5       | 11.7      |

从预测结果可以看出，对于提前 30 min 的预测，把上一时刻风电场实测的输出功率作为神经网络的输入，能够提高预测精度。对于提前 1 h 的预测，考虑前一时刻的测量值的神经网络的预测精度较低。这是因为 1 h 内风速可能发生很大的变化，前一时刻的风速与现在时刻的风速相关性不大。考虑前一时刻功率测量值反而对预测增加了干扰，会降低预测精度。对于提前 24 h 的预测，因为没有测量数据，所以这种方法是不适用的。

##### 3.3.2 不同高度数据对预测结果的影响

目前常用风电机组轮毂高度一般在 40~100 m 之间，风轮扫风的最低点在 14~50 m 之间，风轮扫风的最高点在 71.6~150 m 之间。因此这一段空间内的风速分布对风电机组的输出功率有较大的影响。

如果不考虑湍流的影响，风速随高度的升高而增加。风速和高度的关系可以用对数风廓线或指数风廓线近似描述。因此风轮各部分所感受到的风速是不同的，如图 7 所示。

如果风速分布总是按照对数风廓线或指数风廓线分布，就完全可以根据 1 个高度的风速确定其它高度的风速。但由于受地表粗糙度和大气热力层结的影响，风速的分布并不完全遵守对数风廓线或指数风廓线。有时甚至出现高空风速比低空风速低的现象。因此，选用不同高度的风速、风向作为神经网络的输入比只选 1 个高度的风速、风向能更好地表征风电场周围的大气特性。

分析 2 种情况的预测：1) 只考虑轮毂高度的气象数据；2) 考虑 20 m、轮毂高度的气象数据。对测试样本进行提前 24 h 的预测，第 1 种情况下，预测结果的均方根误差为 15%，第 2 种情况下预测结果的均方根误差为 11%，因此，考虑不同高度的数据可以减小预测误差。




图 7 风机迎风方向的风速分布

Fig. 7 Wind speed distribution of upwind direction of wind turbine

#### 3.4 误差带预测

风电场输出功率预测误差的原因较多，主要包括如下几个方面：1) 预测模型误差。预测数学模型考虑了影响风电场输出功率的几个主要因素，但并不全面；神经网络的学习可能陷入局部极小值。2) 模型的输入数据，即数值天气预报数据本身存在误差，与实际值不完全一致。3) 从图 2 可以看出，风电机组的输出功率具有一定的分散性。4) 风电机组故障停运具有不确定性，对风电场输出功率预测带来一定的困难。



根据前面所建立的预测模型,对风电场的输出功率进行预测,把预测值和实测值相比较就得到预测的逐点误差,如图 8 所示。对误差序列作进一步分析,得到误差分布图 9,误差基本上符合正态分布。从图 9 中可以看出,误差大于 30% 的概率小于 2%,误差大于 10% 的概率小于 5%。

可以根据误差出现的概率设置误差带。比如设置误差带为 $\pm 30\%$ ,这意味着误差带的置信区间为 98%,大约有 2% 的误差可能在误差带之外。




图 8 风电场输出功率预测及误差曲线

Fig. 8 Wind power prediction curve and error curve




图 9 误差概率分布图

Fig. 9 Error distribution

根据图 1 和图 2 可知,在风电机组功率曲线较陡的区域,较小的风速误差就可以导致较大的功率误差,而在功率曲线较平坦区域,风速的误差对功率的误差影响较小。基于统计分析的误差带没有考虑到这些因素。下面给出用神经网络预测误差带的方法,这种方法给出的误差带不是等间隔的。预测误差的神经网络结构如图 10 所示。与预测输出功率的神经网络相比,输入增加了预测的输出功率。因此,训练预测误差的神经网络前,必须先进行输出功率的预测,并得到预测的误差。图 11 给出了对输出功率和误差带的预测结果。可以看出,神经网络预测的误差带不是等宽度的,而且误差带的上面部分和下面部分也不一定对称。在这一段预测曲线中,误差带的上部最小误差带仅 0.5%,最大为 42%;误差带下部最小为 0.6%,最大为 40%。在这一段预测结果中,预测误差都包含在误差带之内,在实际中可能会有误差不在误差带之内的情况,可以根据历史数据做统计分析确定置信度。

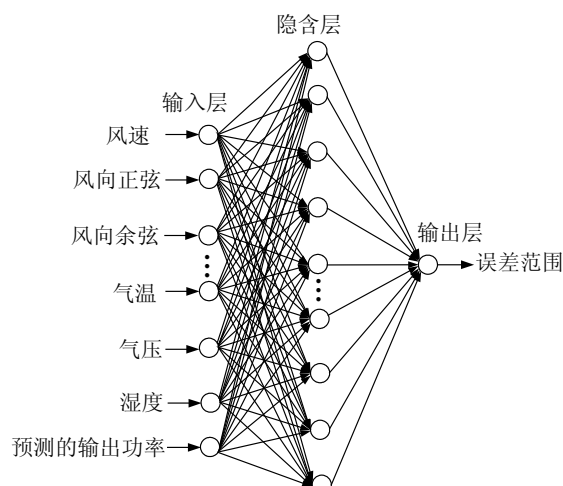


图 10 预测误差的神经网络

Fig. 10 ANN for prediction error




图 11 功率和误差带预测结果

Fig. 11 Predicting wind power and error band

## 4 结论

风电场输出功率预测对于保持电力系统的功率平衡和经济运行有重要意义。对基于神经网络的风电功率预测系统的研究结论有:

1) 风速、风向、气温、气压、湿度等因素对风电场的输出功率有影响,其中风速的影响最大;由于受到尾流和粗糙度的影响,在不同风向下,风电场效率不同。

2) BP 神经网络具有较强的非线性学习能力,可以用于风电场输出功率的预测。

3) 实测的输出功率作为神经网络的输出可以提高提前 30 min 的预测精度,但会降低提前 1 h 的预测精度;输入不同高度的数值天气预报数据可以更准确地描述风速场的状态,能够提高预测精度。

4) 对预测误差进行评估和预测有助于更好地使用预测结果,用神经网络对误差带进行预测是可行的。

## 参考文献

- [1] 孙涛,王伟胜,戴慧珠,等. 风力发电引起的电压波动和闪变[J]. 电网技术, 2003, 27(12): 63-70.  
Sun Tao, Wang Weisheng, Dai Huizhu, et al. Voltage fluctuation and

- flicker caused by wind power generation[J]. Power System Technology, 2003, 27(12): 63-70(in Chinese).
- [2] 迟永宁, 刘燕华, 王伟胜, 等. 风电接入对电力系统的影响[J]. 电网技术, 2007, 31(3): 77-81.  
Chi Yongning, Liu Yanhua, Wang Weisheng, et al. Study on impact of wind power integration on power system[J]. Power System Technology, 2007, 31(3): 77-81(in Chinese).
- [3] 张红光, 张粒子, 陈树勇, 等. 大容量风电场对电力系统小干扰稳定和阻尼特性的影响[J]. 电网技术, 2007, 31(13): 75-80.  
Zhang Hongguang, Zhang Lizi, Chen Shuyong, et al. Influence of large scale wind farms on power system small signal stability and damping characteristic[J]. Power System Technology, 2007, 31(13): 75-80(in Chinese).
- [4] 吴俊, 李国杰, 孙元章. 基于随机规划的并网风电场最大注入功率计算[J]. 电网技术, 2007, 31(14): 15-19.  
Wu Jun, Li Guojie, Sun Yuanzhang. Maximum injection power calculation of wind farms connected to power systems based on stochastic programming[J]. Power System Technology, 2007, 31(14): 15-19(in Chinese).
- [5] Brown B G, Katz R W, Murphy A H. Time series models to simulate and forecast wind speed and wind power[J]. Journal of Climate and Applied Meteorology, 1984(23): 1184-1195.
- [6] Lexiadis M A, Dokopoulos P, Samanoglou H S, et al. Short term forecasting of wind speed and related electrical power[J]. Solar Energy, 1998, 63(1): 61-68.
- [7] Andrew Boone. Simulation of short-term wind speed forecast errors using a multi-variate ARMA(1,1) time-series model[D]. Stockholm, Sweden: Royal Institute of Technology, 2005.
- [8] 吴国旸, 肖洋, 翁莎莎. 风电场短期风速预测探讨[J]. 吉林电力, 2005(6): 21-24.  
Wu Guoshang, Xiao yang, Weng Shasha. Discussion about short-term forecast of wind speed on wind farm[J]. Jilin Electric Power, 2005(6): 21-24(in Chinese).
- [9] 丁明, 张立军, 吴义纯. 基于时间序列分析的风电场风速预测模型[J]. 电力自动化设备, 2005, 25(8): 32-34.  
Ding Ming, Zhang Yijun, Wu Yichun. Wind speed forecast model for wind farms based on time series analysis[J]. Electric Power Automation Equipment, 2005, 25(8): 32-34(in Chinese).
- [10] 孙春顺, 王耀南, 李欣然. 小时风速的向量自回归模型及应用[J]. 中国电机工程学报, 2008, 28(14): 112-117.  
Sun Chunshun, Wang Yaonan, Li Xinran. A vector autoregression model of hourly wind speed and its application in hourly wind speed forecasting[J]. Proceedings of the CSEE, 2008, 28(14): 112-117(in Chinese).
- [11] Bossanyi E A. Short-term wind prediction using kalman filters[J]. Wind Engineering, 1985, 9(1): 1-8.
- [12] 王耀南, 孙春顺, 李欣然. 用实测风速校正的短期风速仿真研究[J]. 中国电机工程学报, 2008, 28(11): 94-100.  
Wang Yaonan, Sun Chunshun, Li Xinran. Short-term wind speed simulation corrected with field measured wind speed[J]. Proceedings of the CSEE, 2008, 28(11): 94-100(in Chinese).
- [13] 潘迪夫, 刘辉, 李燕飞. 基于时间序列分析和卡尔曼滤波算法的风电场风速预测优化模型[J]. 电网技术, 2008, 32(7): 82-86.  
Pan Difu, Liu Hui, Li Yanfei. A wind speed forecasting optimization model for wind farms based on time series analysis and kalman filter algorithm[J]. Power System Technology, 2008, 32(7): 82-86(in Chinese).
- [14] 杨秀媛, 肖洋, 陈树勇. 风电场风速和发电功率预测研究[J]. 中国电机工程学报, 2005, 25(11): 1-5.  
Yang Xiuyuan, Xiao Yang, Chen Shuyong. Wind speed and generated power forecasting in wind farm[J]. Proceedings of the CSEE, 2005, 25(11): 1-5(in Chinese).
- [15] Kariniotakis G N, Stavrakakis G S, Nogaret E F. Wind power forecasting using advanced neural networks models[J]. IEEE Transactions on Energy Conversion, 1996, 11(4): 762-767.
- [16] Potter C W, Negnevitsky M. Very short-term wind forecasting for Tasmanian power generation[J]. IEEE Transactions on Power Systems, 2006, 21(2): 965-972.
- [17] 肖永山, 王维庆, 霍晓萍. 基于神经网络的风电场风速时间序列预测研究[J]. 节能技术, 2007, 25(2): 106-108.  
Xiao Yongshan, Wang Weiqing, Huo Xiaoping. Study on the time-series wind speed forecasting of the wind farm based on neural networks[J]. Energy Conservation Technology, 2007, 25(2): 106-108(in Chinese).
- [18] Simon Haykin. 神经网络原理[M]. 叶世伟, 史忠植译. 北京: 机械工业出版社, 2004: 109-121.
- [19] Martin Hagan T, Howard Demuth B, Mark Beale H, et al. 神经网络设计[M]. 戴葵译. 北京: 机械工业出版社, 2002: 197-221.
- [20] 蒋宗礼. 人工神经网络导论[M]. 北京: 高等教育出版社, 2001: 97-106.
- [21] Hecht Nielsen R. Kolmogorov's mapping neural network existence theorem[C]. First IEEE International Conference of Neural Networks, San Diego, CA, 1987.



范高锋

收稿日期: 2008-09-01。

作者简介:

范高锋(1977—), 男, 博士研究生, 研究方向为风力发电对电力系统的影响, fangaofeng@epri.ac.cn;

王伟胜(1968—), 男, 博士, 教授级高级工程师, 博士生导师, 主要从事电力系统分析与风力发电领域的科研与教学工作;

刘纯(1968—), 男, 高级工程师, 研究方向为电力系统分析及风力发电;

戴慧珠(1939—), 女, 教授, 博士生导师, 长期从事电力系统分析与风力发电等领域的科研与教学工作。

(责任编辑 王剑乔)