

超短期风电功率预测的自适应指数动态优选组合模型

叶 林, 朱倩雯, 赵永宁

(中国农业大学信息与电气工程学院, 北京市 100083)

摘要: 风电功率预测对电力系统运行、调度计划具有重要意义。针对目前单体预测模型的局限性, 文中给出了基于可变向量遗忘因子的自适应指数动态优选组合预测模型。模型首先采用数值天气预报作为 3 种单体预测模型的主要输入, 所选模型结合物理和统计模型的优点, 同时兼有线性与非线性特点。然后, 在单体预测结果的基础上, 分别采用递归最小二乘方法、协方差优选组合方法及多层感知器网络对单体模型的预测结果进行组合。最后, 引入基于 Cook 距离的向量遗忘因子, 利用 Cook 距离评估新观测值对参数估计的影响, 采用基于可变向量遗忘因子的自适应指数组合模型动态分配模型权重系数, 对加权组合得到的 3 种组合预测结果进行再次组合, 在自适应过程中实现模型优选, 得到最终的预测结果。算例结果表明, 所述优选组合预测模型能够在超短期组合预测的过程中实现模型优选, 可有效提高风电功率预测精度。

关键词: 风电功率预测; 动态组合预测; Cook 距离; 自适应遗忘因子

0 引言

近年来, 风电场规模不断扩大, 穿透功率和装机容量不断增加, 由于风电具有间歇性及随机性的特点, 大规模的风电接入给电网调度运行带来了新的问题, 增加了电网调频的负担, 风电对电网安全运行的影响日益显现。对风电功率进行较为准确的预测, 可以使电力调度员及时调整调度计划及风电机组控制方案, 从而减少系统的备用容量, 降低电力系统运行成本, 保证电力系统的稳定运行和供电可靠性, 因此准确而有效的风电功率预测是实现风电常规划、规模化并网的关键^[1-8]。

风能的随机性导致风电场输出功率波动幅度较大且波动频繁, 给功率预测带来困难。现商用在线风电功率预测系统多采用基于数值天气预报(NWP)数据的预测模型, NWP 是风电功率预测的重要输入, 有效利用 NWP 的预报物理量(风速、风向、温度、湿度等)作为预测模型输入能得到较好的预测效果。目前采用的风电功率预测模型主要有物理模型^[9]、统计模型^[10]、人工智能模型^[11-12]等, 不同预测模型的不同输入变量从不同角度影响着模型的输出, 从预测效果来看不同模型各有优缺点。单体的预测模型可能在特定的预测环境下具有较好的预测效果, 但也会导致某些测量点出现较大的误差, 并

不能保证在所有情况下都能取得较好的预测结果。为了优化预测流程和提高预测精度, 针对各种单体预测方法在理论上存在的固有局限性, 采用综合多种预测模型的组合预测已经成为当前的研究趋势。

对适当的单体预测方法进行组合对提高预测精度有重要意义, 根据组合预测方法的建模差异可将其分为 4 类, 即结合数据预处理的组合方法、基于模型参数寻优的组合方法、结合误差处理的组合方法及基于权重系数的组合预测方法^[13]。结合数据预处理的组合方法通过在基本预测方法前加入小波分解、经验模态分解等方法对数据进行预处理, 从而改善预测效果^[14-16]; 基于模型参数寻优的组合方法通过寻优算法实现对预测模型参数的选择和优化, 如遗传算法^[17]; 结合误差处理的组合方法通过对历史残差的预测从而改善预测效果^[18]。以上 3 种组合方法的本质均是采用某种优化机制对一种单体预测方法进行改进, 从而提高预测精度。

基于权重系数的组合预测方法以参与组合的单体模型的预测效果为依据, 对几种预测方法得到的预测结果, 以适当的加权组合方法得到组合预测结果, 避免了某一个或多个因素对预测精度的集中影响。该方法通过利用一个附加的组合模型对若干种单体模型预测结果分配权重, 实现对预测结果的优化, 基于这一思路的组合方法现已成为组合模型领域的研究热点。从本质上来讲, 组合预测方法的加权组合过程就是要确定各单体模型的相对有效性,

并为其分配合适的权重系数以反映它们在组合模型中的重要程度,能充分利用各种单体预测方法的有用信息,克服单体预测模型的局限性,进而有效地减少较大误差的出现概率,消除单体预测方法可能存在的较大偏差,提高预测的准确性。其关键之处在于如何将各种预测方法进行适当的组合,并给出各种预测方法所对应的加权系数^[19-20]。

国内外已有专家学者开始研究基于权重系数的风电功率组合预测方法。文献[21]在6种单体风电功率预测方法的基础上采用等权平均组合预测法、均方差倒数法和多层感知器(MLP)智能算法作为组合方法的融合策略确定各单体模型所占权重。上述方法对提高风电功率预测精度较为有效,但在确定组合模型权重时,仅通过简单的定权重组合预测模型,难以准确地表征风电场复杂的功率波动特性。文献[22]通过最大信息熵原则确定每个单体模型的权重建立组合预测模型。该组合模型在多数预测点的预测精度优于单体模型,但在建模过程中仅对基于神经网络的同类型模型进行组合,由于组合预测旨在结合不同类型的单体模型(如线性模型与非线性模型),提取不同类型预测模型的有效信息,从而实现预测优化,因此采用同类型模型进行组合可能会在组合过程中造成信息冗余。文献[23]将风电功率组合预测看做一个信息融合问题,利用交叉熵理论按支撑度大小变化,动态设置各个预测模型的权值,建立风电功率组合预测模型。由于尚没有成熟的方法求解最大熵和交叉熵问题,此外,对于交叉度的识别,交叉熵方法只能识别不同预测方法之间的交叉度,无法识别相应单体预测方法的预测偏差。当某两种预测方法预测偏差均很大且交迭程度很高时,此时将赋予此两种方法较大的权值,对组合预测方法的精度产生不利影响。

组合预测权系数的计算能通过许多途径实现,组合模型通常以其权系数确定方法命名。比如等权重组合模型、回归组合模型等。但是由于风电场所处环境特点具有时变性,在前一时刻得到的模型最优权重值并不一定对下一时刻是最优的。因此,恒定权系数的风电功率组合预测模型并不能满足实际需要。有必要采用动态变权重组合优化模型来实时跟踪环境的变化。基于此,本文利用两步动态优选组合的思路,通过3种不同的基于权系数的组合方法实现对单体预测模型的加权组合,然后在3种加权组合结果的基础上,利用基于可变量遗忘因子的自适应指数组合模型动态确定上述各个组合预测模型的权重系数,对加权组合预测结果再次组合,建立以加权组合为基础的优选组合模型,优化预测结

果,实现组合模型的优选,从而实时跟踪风电的动态变化,确保预测模型的效果始终保持较高的有效性和稳定性。

1 计及可变量遗忘因子的自适应指数风电功率动态优选组合预测模型

基于权重系数的组合预测模型的通用表达式为:

$$\hat{F}_t^C = \sum_{i=1}^M \phi_i \hat{f}_t^{(i)} \quad (1)$$

式中:上标 \cdot^C 表示相应量的预测值; \hat{F}_t^C 为 t 时刻风电功率的组合预测结果; $\hat{f}_t^{(i)}$ 为第 i 种模型 t 时刻的预测值; ϕ_i 为对第 i 种预测模型所赋权重; M 为组成组合预测模型的模型个数。

1.1 基于Cook距离的自适应向量遗忘因子

遗忘因子 λ_t 是自适应过程的主要特点,对算法的动态跟踪能力起到决定性作用,对预测结果有重要影响,在应用于自适应过程中时,需要预先确定 λ_t 的值。

通过引入式(2)的损失函数来解决式(1)的回归问题。

$$S_t^2(\Phi_j) = \sum_{j=1}^t \kappa(t, j) (p_j - \Phi_j^T f_j)^2 \quad (2)$$

式中: p_j 为 j 时刻的实测功率; $\kappa(t, j) = \prod_{i=j+1}^{t-1} \lambda_i$ 为损失函数中第 j 组残差在 t 时刻的权系数,其中 $j < t$; Φ_j 为 M 维列向量,其元素为 ϕ_i ; f_j 为 M 维行向量,其元素为 $\hat{f}_t^{(i)}$ 。

利用 t 时刻得到的新观测数据,使算法能够合理跟踪输入数据统计特性的变化,引入遗忘因子 λ_t , $0 < \lambda_t \leq 1$ ^[24]。遗忘因子 λ_t 主要用于决定新旧数据的权重, λ_t 越小,加强新数据弱化历史数据的程度就越强,系统的跟踪能力越强; λ_t 越大,加强新数据弱化历史数据的程度就相对弱,系统跟踪能力越弱^[25]。式(3)和式(4)给出了参数向量估计的迭代运算过程。

$$\hat{\Phi}_t = \hat{\Phi}_{t-1} + \hat{\Gamma}_t^T \hat{f}_t^T \hat{e}_t^C \quad (3)$$

$$\hat{\Gamma}_t^{-1} = \lambda_t \hat{\Gamma}_{t-1}^{-1} + \hat{f}_t \hat{f}_t^T \quad (4)$$

式中: $\hat{e}_t^C = p_t - \hat{\Phi}_{t-1}^T f_t$ 为预测误差; $\hat{\Gamma}_t$ 为增益矩阵预测值。

由式(3)和式(4)可知, $\hat{\Phi}_t$ 的递归估计值与 λ_t 有关,适当的遗忘因子序列的选择对自适应过程有重要影响。在递归过程中,引入Cook距离有效评估新观测值对参数估计的影响^[26]:

$$D_t = \frac{(\hat{\Phi}_{t|1} - \hat{\Phi}_{t-1})^T \hat{\Gamma}_{t|1}^{-1} (\hat{\Phi}_{t|1} - \hat{\Phi}_{t-1})}{M \hat{\sigma}_{t-1}^2} = \frac{f_t^T \hat{\Gamma}_{t|1} f_t (e_t^C)^2}{M \hat{\sigma}_{t-1}^2} = \frac{f_t^T \hat{\Gamma}_{t-1} f_t (e_t^C)^2}{M \hat{\sigma}_{t-1}^2 (1 + f_t^T \hat{\Gamma}_{t-1} f_t)} \quad (5)$$

式中： $\hat{\Phi}_{t|1}$ 为未将遗忘因子应用于递归过程中时 $\hat{\Phi}_t$ 的值； $\hat{\Gamma}_{t|1}$ 为未将遗忘因子应用于递归过程中时 $\hat{\Gamma}_t$ 的值，即 t 时刻 $\lambda_t=1$ 时，权系数矩阵从 $\hat{\Phi}_{t-1}$ 到 $\hat{\Phi}_{t|1}$ 的变化受 t 时刻得到的新观测值的影响； $\hat{\sigma}_{t-1}^2$ 为利用完全数据算得的单位权方差^[26]。

Cook 距离 D_t 利用非线性刻度来表示自适应遗忘因子 λ_t^{Cook} ，通过 Cook 距离与卡方分布概率进行估计，即

$$H_t = \Pr(\chi_M^2 > MD_t) \quad (6)$$

式中： H_t 为 Cook 距离利用卡方分布计算得到的值； χ_M^2 为自由度为 M 的卡方分布。

如果新观测数据的 Cook 距离较大，则表明参数估计值会发生较大变化，因此 λ_t^{Cook} 应随之减小以实现递推过程更快的自适应；反之如果新观测值的 Cook 距离较小，则表明参数估计是合理的，因此 λ_t^{Cook} 保持接近于 1 的值以提高自适应效率。

由式(6)可知，随着参数的不断变化， D_t 增加， H_t 减小。通过对其设置上、下限使其能够适应于递归过程的需要以及遗忘参数的要求，在自适应递推过程中减轻异常值的负面影响，从而确保自适应过程的稳定性，基于 Cook 距离的遗忘因子表达式为：

$$\lambda_t^{\text{Cook}} = \lambda_{\min} + (\lambda_{\max} - \lambda_{\min}) H_t \quad (7)$$

式中： λ_{\min} 和 λ_{\max} 分别为 Cook 距离的最小和最大值。

然而，上述递归过程是根据参数变化的整体信息来决定一个适用于整个系统的遗忘因子从而达到跟踪时变参数的目的。但是对于参数变化各不相同的时变系统，需要针对系统中参数变化率的不同而采用相应的遗忘因子 $(\lambda_{1t}^{\text{Cook}}, \lambda_{2t}^{\text{Cook}}, \dots, \lambda_{Mt}^{\text{Cook}})$ ，以适用于不同的参数变化率。

将基于 Cook 距离的自适应向量遗忘因子 $\lambda_{kt}^{\text{Cook}}$ 引入增益矩阵得到：

$$\hat{\Gamma}_t^{-1} = \mathbf{A}_t \hat{\Gamma}_{t-1}^{-1} \mathbf{A}_t + f_t f_t^T \quad (8)$$

式中： $\mathbf{A}_t = \text{diag}(\sqrt{\lambda_{1t}^{\text{Cook}}}, \sqrt{\lambda_{2t}^{\text{Cook}}}, \dots, \sqrt{\lambda_{Mt}^{\text{Cook}}})$ 为一个由向量遗忘因子组成的对角矩阵。

$\lambda_{kt}^{\text{Cook}}$ 将新观测数据的 Cook 距离分解到每种加权组合预测模型中，由新观测值得到的第 k 种模型的 Cook 距离是：

$$D_{kt} = \frac{g_{it} (\hat{e}_t^C)^2}{\hat{\sigma}_{t-1}^2 x_{it}} \quad (9)$$

式中： $x_{it} = \mathbf{u}_i^T \hat{\Gamma}_{t|1} \mathbf{u}_i$ ，其中 \mathbf{u}_i 为一个 N 维列向量，其第 i 个位置为 1，其他位置为 0， $\hat{\Gamma}_{t|1} = (\hat{\Gamma}_{t-1}^{-1} + f_t f_t^T)^{-1}$ ； $g_{it} = \mathbf{u}_i^T \hat{\Gamma}_{t|1} f_t f_t^T \hat{\Gamma}_{t|1} \mathbf{u}_i$ 。

最后，通过 $H_{kt} = \Pr(\chi_1^2 > D_{kt})$ 将 D_{kt} 的值转换为遗忘因子，将式中的 H_{kt} 应用于不同的参数估计。

1.2 自适应指数动态优选组合模型

通过 AFTER (aggregated forecast through exponential reweighting) 算法^[27-28]对不同预测模型进行组合可以得到较好的预测结果。该算法在权重系数的计算中，新近数据和历史数据同等重要，且对历史信息分配相等权重。因此，为适应组合预测模型中不同单体预测模型权系数变化率的时变特性，在 AFTER 模型的基础上，将基于 Cook 距离的自适应向量遗忘因子引入组合权系数的递归估计。通过自适应指数动态模型动态更新权系数矩阵，得到最终的功率预测值。该动态优选组合方法的具体步骤如下。

步骤 1：初始化权系数矩阵 Φ 、增益矩阵 Γ 及向量遗忘因子 $\lambda_i, i=1, 2, \dots, M$ 。

步骤 2：分别求得 M 种组合方法加权预测结果的误差序列 $\mathbf{e}^{(i)} = [e_1^{(i)}, e_2^{(i)}, \dots, e_t^{(i)}], i=1, 2, \dots, M$ 。

步骤 3：由 t 时刻得到的新观测信息，根据所得的 $t-1$ 时刻的实际功率 p_{t-1} 及加权组合方法 i 的预测值 $f_{t-1}^{(i)}, i=1, 2, \dots, M$ ，算得 $t-1$ 时刻的误差 $e_{t-1}^{(i)}$ ，并根据式(8)更新增益矩阵 Γ 。

步骤 4：在新信息更新的时刻 t ，根据式(10)至式(12)算得各模型在组合预测中的权重系数 $\phi_{j,t}$ 。

$$\phi_{j,t} = \frac{G_{j,t}}{\sum_{i=1}^M G_{i,t}} \quad (10)$$

$$G_{j,t} = I_{j,t-1} G_{j,t-1}^{\lambda_{j,t-1}} = I_{j,t-1} I_{j,t-2}^{\lambda_{j,t-1}} G_{j,t-2}^{\lambda_{j,t-1} \lambda_{j,t-2}} = \dots = \prod_{i=1}^{t-1} I_{j,i}^{\kappa(j,i)} \quad (11)$$

$$I_{j,t-1} = \hat{v}_{j,t-1}^{-\frac{1}{2}} \exp \left\{ -\frac{(p_{t-1} - f_{t-1}^{(j)})^2}{2 \hat{v}_{j,t-1}} \right\} \quad (12)$$

其中 $I_{j,t-1}$ 的计算中利用 EWMA (exponentially weighted moving average) 估计得到的条件方差为：

$$\hat{v}_{k,t} = \frac{S_t^{(k)}}{N_{k,t}} \quad (13)$$

$$S_t^{(k)} = e_t^{(k)} e_t^{(k)'} + \lambda_{kt}^{\text{Cook}} S_{t-1}^{(k)} \quad (14)$$

$$N_{k,t} = 1 + \lambda_{kt}^{\text{Cook}} N_{k,t-1} \quad (15)$$

权重系数的计算过程中,针对不同权重系数参数估计采用不同的遗忘因子,其取值由新观测信息确定。在自适应过程中,当某种组合算法表现出持续稳定优越的预测效果时,该最优方法的权重趋于1,实现模型的优选。

步骤 5:将 t 时刻更新的权重系数矩阵记为 Φ_t ,应用于优选组合预测。

步骤 6:根据新观测信息更新误差序列,重复步骤 3 至 5 动态更新 Φ_t ,直至完成预测目标。

2 自适应指数动态优选组合模型基本思路

利用两步加权组合的思路,在第一步组合预测结果的基础上通过基于自适应可变向量遗忘因子的风电功率预测优选组合模型动态确定模型权重,实现对预测精度的优化,其求解步骤如下。

步骤 1:采用单体预测算法进行风电功率预测。
利用基于回归功率曲线优化(ORPC)模型^[29]、最小二乘支持向量机(LSSVM)模型和极端学习机(ELM)模型的 3 种单体预测方法对某时间段内风电场输出功率序列进行预测。以上 3 种单体预测方法既有线性方法,又有非线性方法,并且综合利用了物理信息和统计信息。

步骤 2:利用组合方法确定单体模型的权重系数,得到加权组合预测结果。

在历史数据的基础上,分别采用递归最小二乘(RLS)组合方法、协方差优选组合方法及 MLP 网络通过对单体预测结果分配其权系数实现对单体预测模型的组合,作为动态优选组合模型的基础。

步骤 3:通过优选组合预测模型为加权预测结果动态分配权重系数,实现模型优选,得到最终结果。

由于无法预知步骤 2 中 3 种加权组合模型的有效性,因此利用 Cook 距离评估新观测值对参数估计的影响,将向量遗忘因子引入组合权系数的递归估计,根据新观测信息动态分配权系数,实现模型优选,从而得到最终的预测结果。

计及可变遗忘因子的自适应指数动态权重优选组合模型的算法流程如图 1 所示。

3 算例分析

本文以国内某风电场 2014 年 6 月的 NWP 数据和风电场实际出力数据为研究对象,采用本文给出的两步组合预测模型对单体预测结果进行动态加权组合。模型采用的 NWP 数据来自丹麦某气象公司,时间分辨率为 15 min,并每隔 1 h(每 4 个采样时间间隔)利用新观测数据进行变权重计算。算例

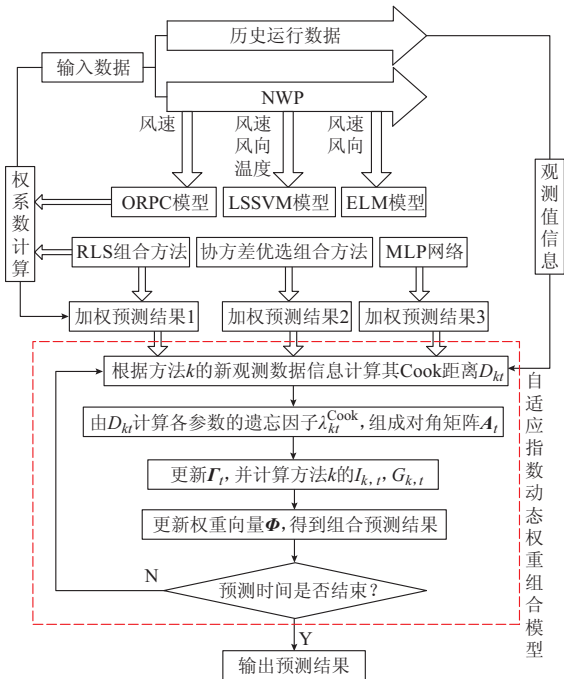


图 1 算法流程图
Fig.1 Algorithm flow chart

风电场的总装机容量为 297 MW,图 2 是采用 3 种单体预测方法所得到的 2014 年 6 月某日的预测结果,风速和风电功率在该时段内波动幅度较大且波动次数较频繁。3 种预测方法都能较好地预测出风电功率变化趋势,但某些点预测值与实际功率仍存在较大偏差,尤其是在 5~9 h 输出功率突变到高水平阶段时,风电出力几乎达到了其额定功率,单体预测方法的预测结果较实际功率有明显偏差。




图 2 单体预测方法的风电输出功率结果
Fig.2 Wind power forecasting results with single prediction method

采用 Q/GDW 588—2011《风电功率预测功能规范》给出的均方根误差和平均绝对误差计算方法对预测结果进行误差分析,各预测模型的误差分析结果如表 1 所示。

ELM 作为较新的网络预测算法,其预测最大误差发生在风电出力最低的时刻;ORPC 的预测稳定性较好,其最大误差发生在风电功率剧减的时刻;

LSSVM 引入了风速、风向和温度作为模型的输入,其平均绝对误差较 ELM 和 ORPC 有显著降低,但其最大误差较大,发生在风电功率剧增的时刻。NWP 作为风电功率预测系统的重要输入,在不同天气状况下预测能力差异较大,影响了单体预测模型的预测精度,由图 2 可知,采用不同的建模方法和输入变量的模型预测效果在不同时刻有较大差异。

表 1 单体预测方法预测误差

Table 1 Forecasting errors of single prediction method

方法	绝对误差 最小值/%	绝对误差 最大值/%	平均绝对 误差/%	均方根 误差/%
ELM	0.49	17.88	12.06	13.69
ORPC	0.80	25.40	11.98	13.14
LSSVM	0.29	33.05	11.01	12.32

组合预测中,首先分别采用 3 种加权组合方法得到对单体预测模型第一步组合预测的结果。图 3 中的 3 条曲线给出了第一步组合预测的绝对误差。

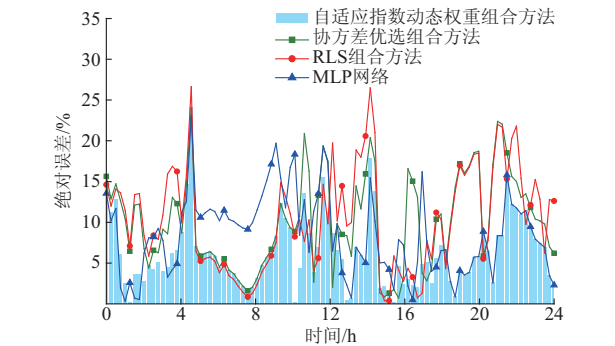


图 3 各组合预测模型绝对误差
Fig.3 Absolute errors of each combination forecast model

图 3 显示,并不存在某一种组合方法在整个预测时间尺度上均优于其他方法。例如在 5~9 h 通过 RLS 组合方法对单体预测方法的组合能够得到较好的预测效果,在 3~4 h 及 15~17 h 采用协方差优选组合方法更贴近功率的变化曲线,而在大多数时刻采用 MLP 网络的预测误差较低,表现出最优的预测效果。而这些都是能够事先预知的,因此需要一种二次优选组合算法,通过对预测结果动态分配权系数使得组合预测结果能够尽量贴近最优结果,实现模型优选。

在二次优选组合中,采用基于可变遗忘因子的自适应指数动态权重组合模型对第一步组合得到的 3 种预测结果进行再次组合,得到最终的预测结果。计算得到的自适应指数动态权重组合方法预测结果的绝对误差及预测结果曲线分别如图 3 和图 4 所示;两步组合预测的误差分析结果如表 2 所示。

由图 3 和图 4 可知,采用自适应指数动态权重

组合方法得到的最终预测结果与第一步得到的最优组合结果十分接近,其绝对误差曲线在大多数时刻贴近第一步组合中最优组合方法的误差曲线,甚至优于最优组合方法的预测结果。在该日共 96 个预测点中,共有 92 个点的绝对预测误差在 15% 以内,占总数的 95.83%,其中误差在 10% 以内的点共 80 个,占总数的 83.33%,误差在 5% 以内的点共 43 个,占总数的 44.79%。因此,本文给出的优选组合预测模型能够通过动态分配组合预测模型的权系数实现对模型的优化组合,从而有效降低点预测误差。

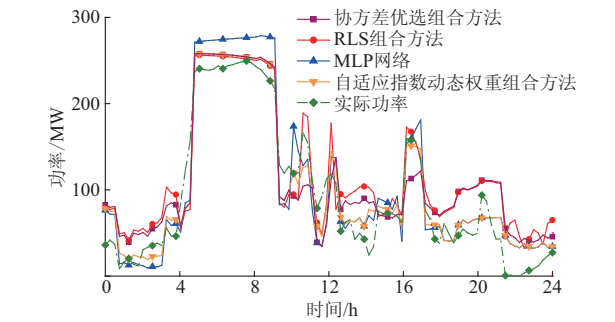


图 4 各组合预测模型预测结果
Fig.4 Forecasting results of each combination forecast model

表 2 组合预测方法预测误差

Table 2 Forecasting errors of combination forecast method

方法	绝对误差 最小值/%	绝对误差 最大值/%	平均绝对 误差/%	均方根 误差/%
协方差优选组合方法	0.72	24.04	10.04	11.55
RLS 组合方法	0.36	26.64	10.39	12.13
MLP 网络	0.32	23.04	8.50	9.82
自适应指数动态权重组合方法	0.21	24.08	6.33	7.65

单体预测模型是组合预测模型的基础,算例分析给出了当个别单体模型预测效果较差时,组合预测的误差分析,如附录 A 表 A1 所示。以其中的算例三为例,3 种单体预测方法中,ELM 和 ORPC 预测效果较差,LSSVM 的预测效果最好。经过第一步组合,由于不同组合方法存在的差异性,无法保证 3 种组合方法均优于 3 种单体方法,如协方差优选组合方法的预测效果虽然优于 ELM 和 ORPC,但比单体预测精度最高的 LSSVM 的预测效果要差。但是经过第二步的优选组合,预测误差不仅明显小于 3 种单体模型的预测误差,而且与第一步组合方法中最优组合模型的预测结果贴近,甚至能够进一步减小第一步组合中最优模型的预测误差,从而较好地解决了传统单步组合方法对单体预测模型的精度过于敏感的问题。

算法的执行效率是工程实际应用中必须考虑的因素之一。各预测方法对该风电场某日预测执行时间如附录 A 表 A2 所示,考虑到即使是相同条件下算法的执行时间也会有小的波动,表中的执行时间取各方法 5 次执行时间的平均值。可以看出,本文提出的优化组合算法经过二次组合虽然较单体方法和一次组合方法所需时间更多,但仍能保证在 0.5 s 内实现预测,保证预测的实时性。

4 结语

风电场的输出功率在一定程度上呈现随机性和波动性的特点。单体预测模型会导致某些测量点出现较大的误差,组合预测模型可有效地减少较大误差的出现。

1) 单体预测方法是组合预测的基础,其结果对组合预测效果有较大影响。本文将不同的 NWP 信息作为 3 种单体预测模型的输入,并综合利用了不同模型的预测优势,有效避免了采用相似的单体预测方法进行组合所造成的模型信息冗余。

2) 本文基于两步组合的思想首先采用 RLS 组合方法、协方差优选组合方法及 MLP 网络对单体模型的预测结果进行组合,然后采用自适应指数动态权重组合模型对上一步组合得到的 3 种预测结果进行第二步优选组合,得到最终的预测结果。

3) 基于可变遗忘因子的自适应指数动态权重组合模型将基于 Cook 距离的自适应向量遗忘因子引入组合权系数的递归估计。通过算例验证,二次优选组合得到的最终预测结果在大多数时刻与最优的预测结果相似,甚至优于最优的预测结果,具有一定的自适应能力,预测效果较为理想,可以减少较大误差的出现,提高预测精度。

附录见本刊网络版 (<http://www.aeps-info.com/aeps/ch/index.aspx>)。

参考文献

- [1] 张丽英,叶廷路,辛耀中,等.大规模风电接入电网的相关问题及措施[J].中国电机工程学报,2010,30(25):1-9.
ZHANG Liying, YE Tinglu, XIN Yaozhong, et al. Problems and measures of power grid accommodating large scale wind power[J]. Proceedings of the CSEE, 2010, 30(25): 1-9.
- [2] 薛峰,常康,汪宁渤.大规模间歇式能源发电并网集群协调控制框架[J].电力系统自动化,2011,35(22):45-53.
XUE Feng, CHANG Kang, WANG Ningbo. Coordinated control frame of large-scale intermittent power plant cluster[J]. Automation of Electric Power Systems, 2011, 35(22): 45-53.
- [3] YUAN Xiaoming. Overview of problems in large-scale wind integrations[J]. Journal of Modern Power Systems and Clean Energy, 2013, 1(1): 22-25.

- [4] 薛禹胜,郁琛,赵俊华,等.关于短期及超短期风电功率预测的评述[J].电力系统自动化,2015,39(6):141-151.
XUE Yusheng, YU Chen, ZHAO Junhua, et al. A review on short-term and ultra-short-term wind power prediction [J]. Automation of Electric Power Systems, 2015, 39(6): 141-151.
- [5] CHEN Zhe. Wind power in modern power systems[J]. Journal of Modern Power Systems and Clean Energy, 2013, 1(1): 2-13.
- [6] 徐曼,乔颖,鲁宗相.短期风电功率预测误差综合评价方法[J].电力系统自动化,2011,35(12):20-26.
XU Man, QIAO Ying, LU Zongxiang. A comprehensive error evaluation method for short-term wind power prediction [J]. Automation of Electric Power Systems, 2011, 35(12): 20-26.
- [7] 王成山,孙玮,王兴刚.含大型风电场的电力系统最大输电能力计算[J].电力系统自动化,2007,31(2):17-21.
WANG Chengshan, SUN Wei, WANG Xinggang. Total transfer capability calculation of power system including large-scale wind farm [J]. Automation of Electric Power Systems, 2007, 31(2): 17-21.
- [8] 陈颖,孙荣富,吴志坚,等.基于统计升尺度方法的区域风电场群功率预测[J].电力系统自动化,2013,37(7):1-5.
CHEN Ying, SUN Rongfu, WU Zhijian, et al. A regional wind power forecasting method based on statistical upscaling approach [J]. Automation of Electric Power Systems, 2013, 37(7): 1-5.
- [9] 冯双磊,王伟胜,刘纯,等.风电场功率预测物理方法研究[J].中国电机工程学报,2010,30(2):1-6.
FENG Shuanglei, WANG Weisheng, LIU Chun, et al. Study on the physical approach to wind power prediction [J]. Proceedings of the CSEE, 2010, 30(2): 1-6.
- [10] EL-FOULY T H M, EL-SAADANY E F, SALAMA M M A. Improved grey predictor rolling models for wind power prediction[J]. IET Generation, Transmission & Distribution, 2007, 1(6): 928-937.
- [11] 丁志勇,杨苹,杨曦,等.基于连续时间段聚类的支持向量机风电功率预测方法[J].电力系统自动化,2012,36(14):131-135.
DING Zhiyong, YANG Ping, YANG Xi, et al. Wind power prediction method based on sequential time clustering support vector machine [J]. Automation of Electric Power Systems, 2012, 36(14): 131-135.
- [12] 范高峰,王伟胜,刘纯,等.基于人工神经网络的风电功率预测[J].中国电机工程学报,2008,28(34):118-123.
FAN Gaofeng, WANG Weisheng, LIU Chun, et al. Wind power prediction based on artificial neural network [J]. Proceedings of the CSEE, 2008, 28(34): 118-123.
- [13] TASICARAAGLU A, UZUNOGLU M. A review of combined approaches for prediction of short-term wind speed and power[J]. Renewable and Sustainable Energy Reviews, 2014, 34: 243-254.
- [14] 张学清,梁军,张熙,等.基于样本熵和极端学习机的超短期风电功率组合预测模型[J].中国电机工程学报,2013,33(25):33-40.
ZHANG Xueqing, LIANG Jun, ZHANG Xi, et al. Combined model for ultra short-term wind power prediction based on sample entropy and extreme learning machine [J]. Proceedings of the CSEE, 2013, 33(25): 33-40.
- [15] 叶林,刘鹏.基于经验模态分解和支持向量机的短期风电功率组合预测模型[J].中国电机工程学报,2011,31(31):102-108.
YE Lin, LIU Peng. Combined model based on EMD-SVM for

short-term wind power prediction [J]. Proceedings of the CSEE, 2011, 31(31): 102-108.

[16] 师洪涛,杨静玲,丁茂生,等.基于小波-BP 神经网络的短期风电功率预测方法[J].电力系统自动化,2011,35(16):44-48.
SHI Hongtao, YANG Jingling, DING Maosheng, et al. A short-term wind power prediction method based on wavelet decomposition and BP neural network [J]. Automation of Electric Power Systems, 2011, 35(16): 44-48.

[17] LI Xingpei, LIU Yibing, XIN Weidong. Wind speed prediction based on genetic neural network[C]// 4th IEEE Conference on Industrial Electronics and Applications, May 25-27, 2009, Xi'an, China: 2448-2451.

[18] 茆美琴,曹雨,周松林.基于误差叠加修正的改进短期风电功率预测方法[J].电力系统自动化,2013,37(23):34-38.
MAO Meiqin, CAO Yu, ZHOU Songlin. Improved short-term wind power forecasting method based on accumulative error correction[J]. Automation of Electric Power Systems, 2013, 37(23): 34-38.

[19] 刘纯,范高峰,王伟胜,等.风电场输出功率的组合预测模型[J].电网技术,2009,33(13):74-79.
LIU Chun, FAN Gaofeng, WANG Weisheng, et al. A combination forecasting model for wind farm output power[J]. Power System Technology, 2009, 33(13): 74-79.

[20] 张国强,张伯明.基于组合预测的风电场风速及风电机功率预测[J].电力系统自动化,2009,33(18):92-95.
ZHANG Guoqiang, ZHANG Boming. Wind speed and wind turbine output forecast based on combination method [J]. Automation of Electric Power Systems, 2009, 33(18): 92-95.

[21] BOUZGOU H, BENOUDJIT N. Multiple architecture system for wind speed prediction[J]. Applied Energy, 2011, 88(7): 2463-2471.

[22] HAN S, LIU Y, LI J. Wind power combination prediction based on the maximum information entropy principle[C]// World Automation Congress, June 24-28, 2012, Puerto Vallarta, Mexico: 4p.

[23] 陈宁,沙倩,汤奕,等.基于交叉熵理论的风电功率组合预测方法[J].中国电机工程学报,2012,32(4):29-34.
CHEN Ning, SHA Qian, TANG Yi, et al. A combination method for wind power prediction based on cross entropy theory[J]. Proceedings of the CSEE, 2012, 32(4): 29-34.

[24] 何子叙,夏威.现代数字信号处理及其应用[M].北京:清华大学出版社,2009.

[25] 韩伟,王立志,刘震.基于可变遗忘因子 RLS 算法的谐波电流检测方法[J].电工技术学报,2013,28(12):70-74.
HAN Wei, WANG Dazhi, LIU Zhen. A harmonic current detection method based on variable forgetting factor RLS algorithm[J]. Transactions of China Electrotechnical Society, 2013, 28(12): 70-74.

[26] SÁNCHEZ I. Recursive estimation of dynamic models using Cook's distance, with application to wind energy forecast[J]. Technometrics, 2006, 48(1): 61-73.

[27] ZOU H, YANG Y. Combining time series models for forecasting[J]. International Journal of Forecasting, 2004, 20(1): 69-84.

[28] SÁNCHEZ I. Adaptive combination of forecasts with application to wind energy [J]. International Journal of Forecasting, 2008, 24(4): 679-693.

[29] SIEBERT N. Development of methods for regional wind power forecasting[R]. France: Ecole des Mines de Paris, 2008.

叶 林(1968—),男,通信作者,教授,博士生导师,德国洪堡学者,主要研究方向:电力系统自动化、新能源发电与超导电力应用。E-mail: yelin@cau.edu.cn

朱倩雯(1991—),女,硕士研究生,主要研究方向:电力系统运行与控制、新能源发电技术。

赵永宁(1990—),男,博士研究生,主要研究方向:电力系统运行与控制、新能源并网技术。

(编辑 万志超)

Dynamic Optimal Combination Model Considering Adaptive Exponential for
Ultra-short Term Wind Power Prediction

YE Lin, ZHU Qianwen, ZHAO Yongning

(School of Information and Electrical Engineering, China Agricultural University, Beijing 100083, China)

Abstract: Wind power prediction plays a very important role in the dispatching and operation to maintain power system safety and stability. Due to the limitation of single prediction model with large errors at some individual points, a novel two-step dynamic optimal combination model of wind power prediction based on variable adaptive vector forgetting factor is proposed, which takes the numerical weather prediction (NWP) data as inputs. Three single prediction models are adopted considering advantages of physical and statistical models. Recursive least square (RLS), covariance optimization combination and multi-layer perceptron (MLP) network are proposed to calculate the weights of each single prediction model. Effect of new observations on parameter estimation is further evaluated based on Cook's distance, and the weight coefficients of three combined prediction models are calculated through adaptive exponential dynamic combination model by use of variable vector forgetting factor. The proposed model is used to combine the results from the first step to obtain the optimal model in the adaptive process. Case studies show that the optimal forecasts can be obtained in ultra-short term wind power prediction using the proposed model, which improves the accuracy of prediction effectively.

This work is supported by National Natural Science Foundation of China (No. 51477174, No. 51077126).

Key words: wind power prediction; dynamic combination forecast; Cook's distance; adaptive forgetting factors